Parte I: Regresión Lineal Bayesiana

1. Planteamiento del modelo

En esta primera parte del taller se propone un modelo de regresión lineal bayesiana para analizar la variable `total driver payout` dentro del experimento de UBER Pool en Bogotá.

La pregunta de análisis es la siguiente:

> *¿Qué factores están asociados con el pago total a los conductores en el experimento de UBER Pool en Bogotá?*

2. Selección de la variable objetivo

Se eligió `total driver payout` como variable objetivo porque nos permite analizar si la implementación de UBER Pool puede resultar costosa desde el punto de vista operativo para la plataforma. En otras palabras, esta variable muestra cuánto se les paga a los conductores en cada periodo y por eso sirve como una aproximación al costo operativo del servicio.

Además, esta elección también tiene sentido metodológicamente, ya que `total driver payout` es una variable numérica continua y por eso se ajusta mejor a un modelo de regresión lineal bayesiana que otras variables de la base que son de conteo o categóricas.

3. Selección de variables explicativas

Como variables explicativas se seleccionaron `treat`, `commute` y `total matches`, porque entre todas ayudan a describir condiciones importantes del experimento.

La variable `treat` es importante porque permite estudiar si cambiar el tiempo de espera del algoritmo de emparejamiento, pasando de 2 a 5 minutos, influye sobre el costo total del servicio.

La variable `commute` se incluyó porque las horas pico pueden cambiar bastante las condiciones de operación, generar mayor presión sobre el sistema y afectar los pagos realizados a los conductores.

Finalmente, `total matches` se eligió porque refleja el nivel de emparejamiento entre pasajeros. Si el sistema logra más emparejamientos, eso podría indicar una operación más eficiente y, en principio, una posible reducción del costo para la aplicación.

4. Especificación inicial del modelo

La formulación inicial propuesta es:

$$\texttt{total driver payout}_i = \beta_0 + \beta_1 \texttt{treat}_i + \beta_2 \texttt{commute}_i + \beta_3 \texttt{total matches (miles)}_i + \varepsilon_i$$

donde $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$.

En este modelo:

- β_0 representa el valor esperado base del pago total a conductores.
- β_1 mide el cambio esperado en el pago total cuando el tratamiento corresponde a un tiempo de espera de 5 minutos.
- β_2 mide el cambio esperado en el pago total durante hora pico.
- β_3 mide la asociación entre 1000 emparejamientos adicionales y el pago total a conductores.

5. Carga y revisión de la base

Se cargó la base `bases/Copia de BaseUBER.csv` y se verificó su estructura antes de ajustar el modelo. Los principales resultados de revisión fueron:

- número de observaciones: 126.
- variables disponibles: 10.
- valores faltantes: no se encontraron faltantes en ninguna variable.
- codificación de tratamiento: `FALSO/VERDADERO` con 63 observaciones por grupo.

- codificación de hora pico (`commute`): 20 observaciones en hora pico y 106 fuera de hora pico.

Para evitar problemas de escala en la estimación, `total matches` se reescaló en miles.

6. Ajuste del modelo y calibración de la prior

La especificación bayesiana del modelo requiere definir distribuciones previas para los coeficientes y para la variabilidad del error. En este trabajo se propone usar priors no informativas (o débilmente informativas) para todos los coeficientes.

La decisión de usar priors débilmente informativos se tomó para dejar que los datos del experimento pesen más en la estimación final. Así evitamos imponer creencias a priori que pudiesen alterar el efecto medido de forma subjetiva.

En cambio, para `commute` y `total matches` se asume una postura más conservadora. Aunque ambas variables podrían influir sobre el costo operativo, no tenemos una idea previa tan clara sobre la magnitud exacta de ese efecto, así que se usan priors débilmente informativas con varianzas grandes.

La calibración de la prior se hizo con la escala real de la base:

- media de `total driver payout`: 28237,22.
- desviación estándar de `total driver payout`: 5450,95.
- diferencia simple de medias por tratamiento (`5 mins` menos `2 mins`): −2108,04.

Con esta referencia, la especificación utilizada fue:

$$\beta_0 \sim \mathcal{N}(28000, 10000^2)$$

$$\beta_1 \sim \mathcal{N}(0, 10000^2)$$

$$\beta_2 \sim \mathcal{N}(0, 10000^2)$$

$$\beta_3 \sim \mathcal{N}(0, 10000^2)$$

además de una prior Inverse-Gamma para σ^2 con hiperparámetros $a_0 = 2$ y $b_0 = 4000^2$.

donde β_1 representa el efecto de `treat`. Decidimos configurar esta prior centrada en cero y con una varianza alta (10000^2). Esto permite que los datos dominen el ajuste final; de esta forma, no encasillamos el modelo a una expectativa inicial sobre el verdadero impacto financiero de la política.

7. Resultados bayesianos iniciales

A partir del ajuste bayesiano con la base completa ($n = 126$), se obtuvo el siguiente resumen posterior:

Parámetro	Media posterior	CrI 95 % inferior	CrI 95 % superior
β_0 (Intercepto)	16882.71	13201.05	20558.09
β_1 (`treat`)	-1253.44	-2357.83	-159.40
β_2 (`commute`)	5457.89	3015.19	7873.58
β_3 (`total matches` en miles)	4383.55	2902.14	5867.78

Cuadro 1: Resumen posterior de coeficientes del modelo lineal bayesiano.

Adicionalmente, la probabilidad posterior de que el efecto del tratamiento sea negativo fue:

$$P(\beta_1 < 0 \mid \text{datos}) = 0{,}9873$$

Este resultado respalda la hipótesis de trabajo: con alta probabilidad posterior, el esquema de espera de 5 minutos se asocia con una reducción del pago total a conductores, controlando por hora pico y nivel de emparejamiento.

8. Diagnóstico y chequeo de ajuste

Para el chequeo de ajuste empírico del modelo, calculamos las predicciones usando el vector de medias posteriores y sacamos los residuos contra los datos reales Y. La Figura 2 contiene el gráfico de dispersión obtenido.

El gráfico evidencia que los residuos se distribuyen de manera más o menos simétrica por encima y por debajo del cero, sin que se observe un error sistemático claro o patrones evidentes de no linealidad. Aunque es claro que la dispersión global de los datos es grande, algo que concuerda con la altísima variabilidad de los viajes en una ciudad como Bogotá, el modelo

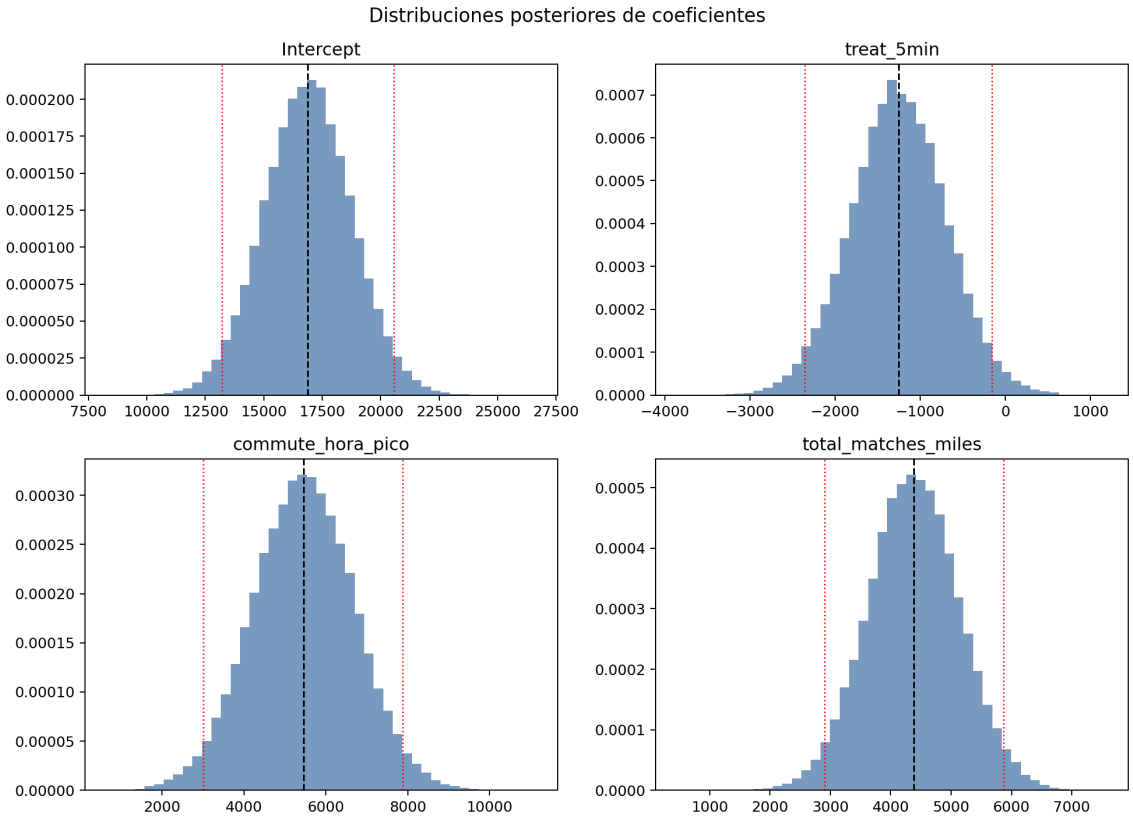

Figura 1: Distribuciones posteriores de los coeficientes del modelo.

lineal logra capturar bien el efecto medio en los pagos a conductores. Esto nos da un punto de apoyo válido para evaluar y sustentar la idea de ampliar el tiempo de espera.

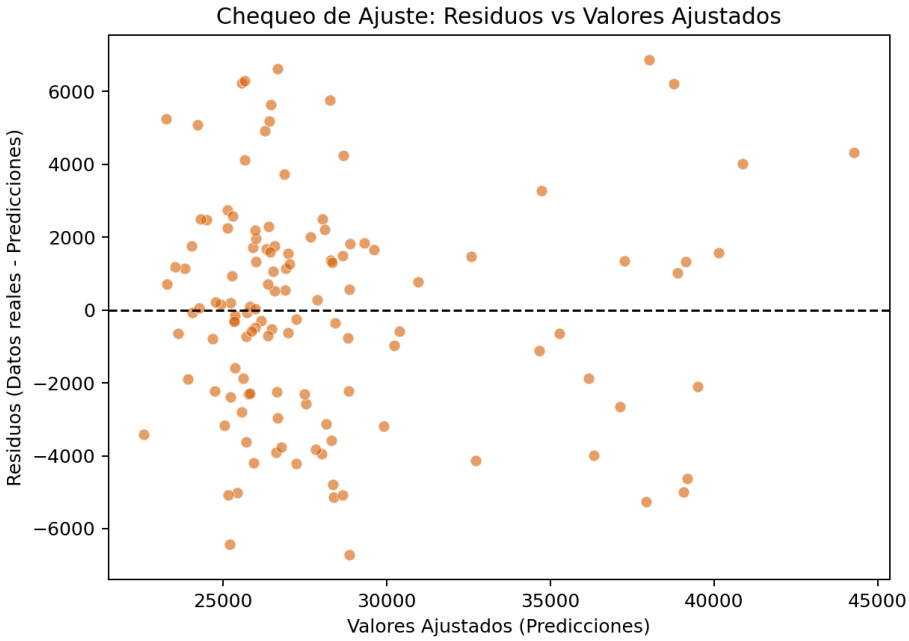

Figura 2: Chequeo de ajuste: Residuos vs. Valores ajustados.