Estadística Bayesiana

Pregrado en Ciencia de Datos

Universidad Externado

Andrés Martínez

MSc Stochastic Engineering

Universidad Externado

Índice general

1 Introducción **3**

1.1 Conceptos de Probabilidad 3

1.2 Distribuciones de Probabilidad 5

1.2.1 Valor Esperado y Varianza 6

1.2.2 Distribuciones discretas 7

1.2.3 Distribución Continua 8

1.2.4 Parámetros 15

1.3 Familias exponenciales 16

1.4 Muestreo 17

1.5 Teoría de la estimación de máxima verosimilitud 20

1.5.1 Estimación por máxima verosimilitud 21

1.5.2 Información de Fisher 22

1.6 Exchangeability(intercambiabilidad) 23

1.7 Teorema de Finetti 24

1.8 Ejercicios Adicionales 25

2 Conceptos Fundamentales **29**

2.1 Elementos Frecuentistas 29

2.2 Elementos Bayesianos 30

2.2.1 Definición de la prior 31

2.2.2 Prior no informativas 32

2.2.3 Jeffrey prior 32

2.3 Distribuciones Discretas 33

2.3.1 Distribución Uniforme previa 34

2.3.2 Distribución predictiva $\tilde{y}$ de Y 35

2.3.3 Distribución Conjugada caso de Beta 39

2.4 Modelo Poisson 43

2.4.1 Familias exponenciales 46
2.5 Predicción 47
2.5.1 Regiones de confidencia 51
2.5.2 Inferencia sobre la distribución posterior 52
2.5.3 Regiones HPD *Highest posterior density* 52
2.6 Distribuciones Continuas 54
2.6.1 Distribución Normal con varianza conocida 54
2.6.2 Predicción de la distribución normal con varianza conocida . . 60
2.6.3 Distribución Normal con varianza desconocida 61
2.6.4 Elección del modelo 66
2.7 Distribuciones Multivariadas 67
2.7.1 Distribución Multinomial 67
2.7.2 Distribución Dirichlet 68
2.7.3 Derivación 69
2.7.4 Aproximación mediante la distribución beta 70
2.7.5 Valor Esperado 70
2.7.6 Varianza 70
2.7.7 Dirichlet-Multinomial 71
2.7.8 Distribución Normal Multivariada con Varianza Conocida 73
2.7.9 Una distribución semiconjugada previa de la media 75
2.7.10 Distribución Normal Multivariada con Varianza no Conocida . . 77
2.7.11 Distribución Wishart 77
2.7.12 Distribución Wishart Inversa 77
2.7.13 Distribución condicional completa (Full Conditional) 79
2.7.14 Resumen 81
2.8 Conclusión 81

3 Métodos de Simulación **83**
3.1 Transformación de las distribuciones 83
3.1.1 Aceptación-Rechazo 84
3.2 Modelos Montecarlo 85
3.3 Cadena de Markov 87
3.3.1 Cadenas de Markov 88
3.3.2 Algoritmo EM 90
3.3.3 Importance Sampling 92

3.3.4 Importance sampling y resampling 93
3.3.5 Movimiento Browniano 95
3.3.6 Movimiento Geométrico Browniano 95
3.4 Muestreo de Gibbs 96
3.4.1 Dos pasos muestreo de Gibbs 96
3.5 Metropolitan y Metropolitan Hastings 100
3.5.1 Algoritmo Metropolitan Hastings Independiente 102
3.5.2 Algoritmo Metropolitan Hastings Aleatoria 103
3.6 Hamiltoniano Monte Carlo (HMC) 104
3.6.1 Introducción a Métodos Monte Carlo 104
3.6.2 Motivación para Hamiltoniano Monte Carlo 105
3.6.3 Dinámica Hamiltoniana 105
3.6.4 Del Física a la Estadística: El Método Leapfrog 105
3.6.5 Algoritmo HMC: Integración y Aceptación 106
3.6.6 El Papel de la Energía en HMC 106
3.6.7 Ajuste y Consideraciones Prácticas 109
3.7 Resumen de Métodos de Simulación 109
3.8 Métodos Monte Carlo 110
3.8.1 Ventajas 110
3.8.2 Desventajas 110
3.9 Método de Aceptación-Rechazo 110
3.9.1 Ventajas 110
3.9.2 Desventajas 110
3.10 Métodos MCMC (Cadena de Markov Monte Carlo) 111
3.10.1 Ventajas 111
3.10.2 Desventajas 111
3.11 Hamiltoniano Monte Carlo (HMC) 111
3.11.1 Ventajas 111
3.11.2 Desventajas 111
3.12 Algoritmo EM (Expectation-Maximization) 112
3.12.1 Ventajas 112
3.12.2 Desventajas 112
3.13 Conclusión 112

4 Aplicaciones **113**

4.1 Regresión Lineal Múltiple 114
4.1.1 Versión frequentista 114
4.1.2 Supuestos 114
4.1.3 Derivación de los Estimadores 115
4.1.4 Propiedades de los Estimadores 115
4.1.5 Enfoque Bayesiano 116

Prólogo

Doctores y Doctoras (Científicos y Científicas)

Este documento es una herramienta que contiene cada uno de los temás que se abordarán a lo largo del semestre. Siendo ustedes estudiantes del pregrado de Ciencia de Datos, deben saber que el diseño, las competencias y los objetivos de aprendizaje se construyeron con los estándares que giran alrededor de la profesión de la docencia universitaria y adaptándolo a las necesidades de un cientifico de datos, una profesión en donde adivinar e improvisar son un hábito destructivo que choca con la lógica de los problemas que deben resolver.

Siguiendo con la linea anterior, las cosas deben hacerse decentemente y con orden. Por lo tanto, debo recalcar que se encuentran en una estación intermedia que requiere del conocimiento de materias básicas como, cálculo 1 y 2, álgebra lineal, matemática discreta, programación 1, probabilidad y estadística inferencial. Una vez definido lo anterior, se puede dividir el curso en dos partes; la primera estadística bayesiana inferencial, en donde encontrarán el camino de la medición y predicción a través de otro paradigma que se aleja de la estadística frecuentista. La segunda parte se concentra en el modelamiento bayesiano, en donde conocerán las principales herramientas que les permitirán resolver aquello que solo es posible a través de la tecnología.

En cuanto a lo que se espera de ustedes, deben saber que al momento en que iniciamos esta carrera, la competencia entre personas que se hacen llamar cientificos de datos con quienes realmente lo son crece. No obstante, esa no debería ser una preocupación para ustedes, dado que deben aprender a diferenciarse en cada una de las etapas que pueden definir a un científico de datos. Eso significa que mientras unos solo pueden aplicar, ustedes aprenden a crear y por eso la mediocridad no conoce nada más alto que sí misma y es impulasada por el afan de conocer sin aprender; pero el talento

instantáneamente reconoce el genio, quien se forma con un tiempo prolongado y paciente de estudio y trabajo.

Desde una perspectiva académica aprenderán a observar y razonar, dos constantes indispensables en la ciencia de datos, pues mientras cada individuo puede ser un enigma insoluble, un conjunto de ellos se comporta con exactitud matemática. También entenderán como adaptar las teorías a los hechos en vez de los hechos a las teorías y aunque el mundo está lleno de cosas obvias, estas los ayudarán a comprender que lo que está fuera de lo común suele ser una guía más que un estorbo.

Si logran formarse con los mejores estándares, las personas pensarán que ustedes resuelven los enigmas de manera brillante. Pero la verdad es que lo único que harán, es seguir un razonamiento analizando todas las pistas, pues ustedes serán cientificos de datos y es su negocio saber lo que otras personas no saben, logrando que los problemas parescan infantiles después de que los hayan explicado.

Confieso que he nunca le había dedicado tanto tiempo a la preparación de un curso y aunque puede parecer la versión final, seguramente tendrá cambios a lo largo del semestre.La evolución de este curso se refleja en los trabajos de sus compañeros y en los resultados en diferentes conferencias y concursos. Esto demuestra que tanto la ciencia como la enseñanza no pueden ser elementos estáticos que se ejecutan como un proceso de capacitación sinsentido, alejados por completo de cualquier significado que nos dejó la ilustración y que por el contrario, necesitan de una constante actualización que surge de los procesos de investigación. También les pido el favor de revisar este texto que será de ustedes, si ven algún error me lo pueden indicar para entregarles la mejor versión (del momento).

Bienvenido/as al curso de Estadística Bayesiana del pregrado en Ciencia de Datos de la Universidad Externado, espero que disfruten este curso tanto como he disfrutado yo preparandolo.

Un saludo.

Andrés Martínez.

Capítulo 1

Introducción

1.1. Conceptos de Probabilidad

Definición: Siendo Ω un conjunto no vacío con una colección de subconjuntos $\mathcal{F}$. Se dice que $\mathcal{F}$ es una σ álgebra con las siguientes propiedadesLlinás Solano (2015):

- El conjunto vacío $\emptyset$ pertenece a $\mathcal{F}$
- Como sea que un conjunto $\mathcal{A}$ pertenece a $\mathcal{F}$, $\mathcal{A}^c$ también pertenece a $\mathcal{F}$.
- Como sea que unos conjuntos $\mathcal{A}_1, \mathcal{A}_2, ...\mathcal{A}_n$ pertenecen a $\mathcal{F}$, la unión $\cup$ de $\mathcal{A}_1, \mathcal{A}_2, ...\mathcal{A}_n$ también pertenece a $\mathcal{F}$.

Propiedades: Siendo Ω un conjunto no vacío con una colección de subconjuntos $\mathcal{F}$. Una medida de probabilidad $\mathbb{P}$ es una función que para cada conjunto de $\mathcal{A} \quad \mathcal{F}$ asigna un número entre $[0, 1]$ llamado probabilidad de $\mathcal{A}$ y escrito como $\mathbb{P}(\mathcal{A})$ Llinás Solano (2015):

- $\mathbb{P}(\Omega) = 1$
- Como sea que $\mathcal{A}_1, \mathcal{A}_2, ...\mathcal{A}_n$ es una secuencia de conjuntos disyuntos en $\mathcal{F}$
- $$\mathbb{P}\big(\cup_{n=1}^{\infty} \mathcal{A}_n\big) = \sum_{n=1}^{\infty} \mathbb{P}(\mathcal{A}_n)$$

Por lo tanto, cualquier variable aleatoria dentro de un proyecto financiero se mide a partir del espacio de probabilidad triple $(\Omega, \mathcal{F}, \mathbb{P})$.Llinás Solano (2015)
Teorema: Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Para A, B $(A_n)_{n\in\mathbb{N}}$ y $(B_n)_{n\in\mathbb{N}} \in \mathcal{F}$

- $\mathbb{P}(\emptyset) = 0$
- $P(A^c) = 1 - P(A)$
- Si $A \subseteq B$ entonces $P(A) \leq P(B)$
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

σ **algebra**: La dupla $(\Omega, \mathcal{F})$ se llama espacio medible si$\Omega \neq \emptyset$ y $\mathcal{F}$ una σ álgebra, es decir, un sistema de subconjuntos de un conjunto que posee las siguientes propiedades:Llinás Solano (2015)

a $\Omega \in \mathcal{F}$

b Si $A \in \mathcal{F}$, entonces $\overline{A} := \Omega\ A \in \mathcal{F}$.

c Si $A_1, A_2, ... \in \mathcal{F}$ entonces $\cup_{n=1}^{\infty} A_n \in \mathcal{F}$

Experimento de Laplace
El experimento de laplace está compuesto por la probabilidad del conjunto A que es igual a los elementos de A dividido en los elementos de Ω. Llinás Solano (2015)

$$P(A) = \frac{\mid A \mid}{\mid \Omega \mid}$$

Probabilidad condicionada Llinás Solano (2015)Para $P(A) \neq 0$ existe una probabilidad condicionada de dos subconjuntos en Ω por lo tanto la probabilidad condicionada de B con respecto a A es igual:

$$P_A(B) \equiv P(B \mid A) = \frac{P(B \cap A)}{P(A)} para P(A) > 0$$

Independencia de Resultados
Dos conjuntos A y B son independientes siempre que:

$$P(A \cap B) = P(A)P(B)$$

Probabilidad Total
Llinás Solano (2015)Si no hay independencia en los resultados se dice que el evento la probabilidad del evento B $P(B)$ es la suma de todos los eventos que sueceden en $A_1, ..., A_n$ de esta forma:

$$P(B) = \sum_{i}^{n} P(A_i)P(B \mid A_i)$$

Teorema de Bayes
Los métodos bayesianos son herramientas de análisis de datos que se derivan de los principios de inferencia bayesiana Llinás Solano (2015).

- Estimaciones de parámetros con buenas propiedades estadísticas
- Descripciones parsimoniosas de los datos observados
- Predicciones para datos faltantes y pronósticos de datos futuros
- Un marco computacional para la estimación, selección y validación de modelos

$$P(A_i \mid B) = \frac{P(A_i)P(B \mid A_i)}{\sum_i^n P(A_i)P(B \mid A_i)}$$

Definición Sean (Ω, P) un espacio de probabilidad finito. Una variable es una función real definida en y Ω dos espacios medibles Llinás Solano (2015).

a Una función $f : \Omega \to \Omega'$ se llama $\mathcal{F}$ medible.

b Si, además, está definida una probabilidad P sobre$(\Omega, \mathcal{F})$ entonces X se mide en un espacio de probabilidad $(\Omega, \mathcal{F}, P)$.

1.2. Distribuciones de Probabilidad

Una función de densidad $f(x)$ de una variable aleatoria X tiene las siguientes propiedades:

a $f(x) \geq 0$

b $\int_{-\infty}^{\infty} f(x)dx = 1$

c $P(a \leq X \leq b) = \int_a^b f(x)dx$

Llinás Solano (2015) Si se quiere obtener la distribución acumulada de una variable aleatoria X discreta o continua, se puede usar la función de distribución acumulada que tiene las siguientes propiedades:

a $0 \leq F(x) \leq 1$

b $F(x_1) \leq F(x_2)$

c $lim_{t \to -\infty} F(x) = 0$

d $lim_{t \to \infty} F(x) = 1$

e $F(x)$ es continua por la derecha

1.2.1. Valor Esperado y Varianza

Definición Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y X una variable aleatoria numérica Llinás Solano (2015).
Si X es una variable aleatoria discreta con valores $x_1, x_2, ...$ se dice que la esperanza de X existe si $\sum_{k=1}^{\infty} \mid x_k \mid = P(\{X = x_k\}) < \infty$.
El valor esperado de una variable aleatoria se obtiene sumando todos sus resultados y multiplicándolo por la probabilidad

$$\mathbb{E}(X) = \sum_x x\mathbb{P}(x) \tag{1.1}$$

Si X es una variable aleatoria continua con una función de densidad $f(x)$, se dice que la esperanza de X existe si $\int_{-\infty}^{\infty} |x| f(x) dx < \infty$

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f(x) dx \tag{1.2}$$

Si $E[X] < \infty$, entonces $Var[X] := E([X - E(X)]^2)$ y $\sigma = \sqrt{Var(X)}$
Propiedades del Valor Esperado: Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y X una variable aleatoria real Llinás Solano (2015).

- $E(a) = a$ para todo $a \in \mathbb{R}$.
- si $X_1 \leq X_2$, entonces $E(X_1) \leq E(X_2)$
- $E(aX_1 + bX_2) = aE(X_1) + bE(X_2)$ para todo $a, b \in \mathbb{R}$
- $|E(X)| \leq E(|X|)$

Propiedades de la Varianza: Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y X una variable aleatoria real.

- $Var(X) = E(X^2) - (E(X))^2$
- $Var(aX + b) = a^2 Var(X)$ para $a, b \in \mathbb{R}$

$$STD[X] = \sqrt{V[X]} \equiv \sigma_X$$

1.2.2. Distribuciones discretas

Distribución Binomial Es una distribución para una variable aleatoria discreta, la probabilidad se obtiene con

$$P(X = x) = \binom{n}{x} p^x q^{n-x} \tag{1.3}$$

Donde p y q son probabilidades n el número de escenarios y x el valor que se desea obtener.
El valor esperado y la varianza son:

$$\mathbf{E}(X) = np$$

$$\mathbf{Var}(X) = np(1 - p)$$

Distribución Poisson
Su función de probabilidad es:

$$P(x) = \frac{\lambda^x}{x!} e^{-\lambda}$$

Mientras que la función de densidad se define como:

$$F(x) = \sum_{x=0}^{n} P(x) = e^{-\lambda} \sum_{x=0}^{n} \frac{\lambda^x}{x!}$$

Con un valor esperado y una varianza de:

$$\mathbf{E}(X) = \lambda$$

$$\mathbf{Var}(X) = \lambda$$

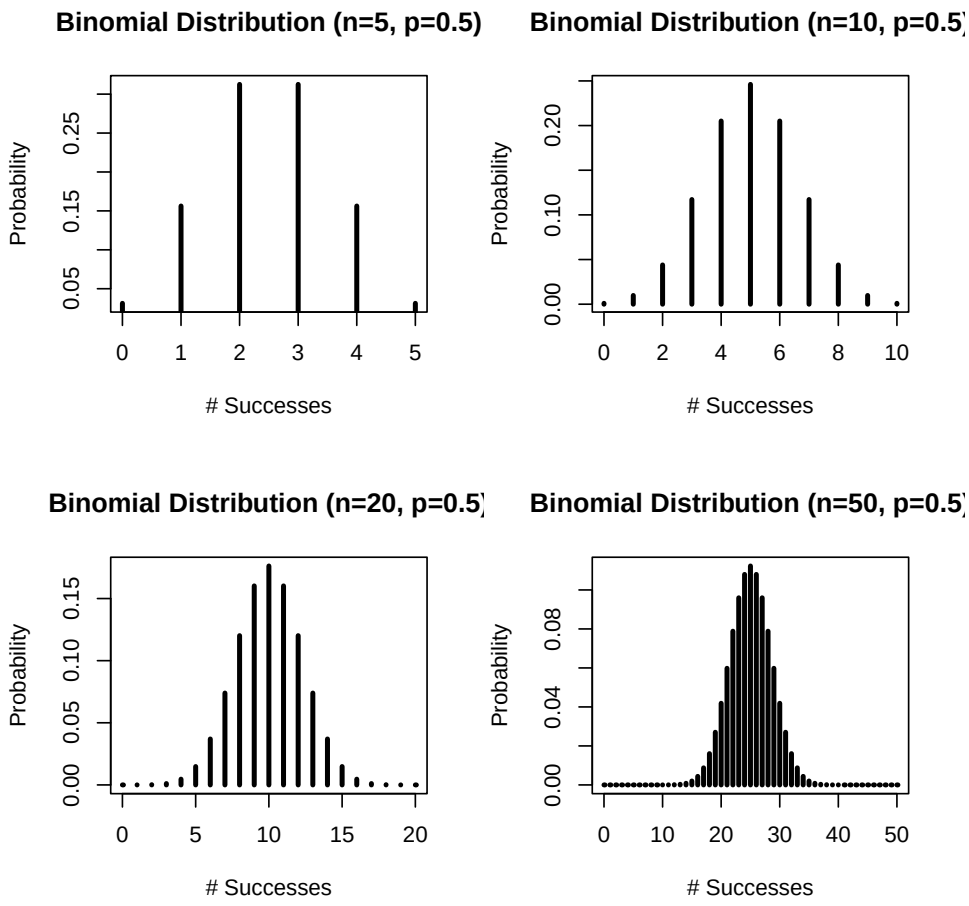

Figura 1.1: Distribución Binomial

1.2.3. Distribución Continua

Distribución Uniforme

La distribución mas sencilla de la teoría de probabilidad, se encuentra entre dos intervalos $[a, b]$ y su distrubición igual se denota de la forma $X \sim \mathbb{U}(a, b)$ lo que quiere decir que esta función se distribuye de forma uniforme con parámetros a y b que son constantes en el espacio cartesiano.

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{para} \quad a \leq x \leq b \\ 0 & \text{de otra forma} \end{cases}$$

El valor esperado y la varianza son:

$$\mathbf{E}(X) = \frac{b+a}{2}$$

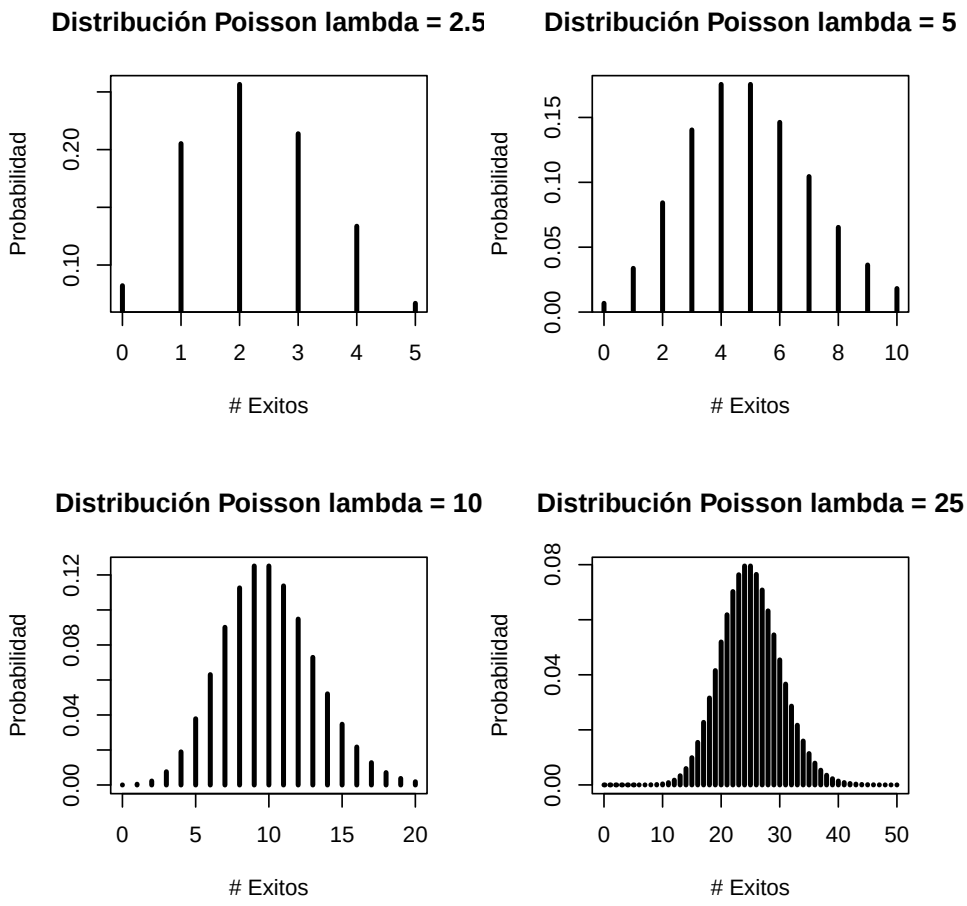

Figura 1.2: Distribución Poisson

$$\textbf{Var}(X) = \frac{(b-a)^2}{12}$$

Distribución Normal

Es la más importante de las distribuciones continuas. Su característica principal es la simetría, ya que la media, la mediana y la moda tienen el mismo valor; su sesgo es cero y su curtosis es 3, lo que significa que es poco probable que presente escenarios extremos.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \ (\mu \in (-\infty, \infty), \sigma > 0)$$

$$X \sim N(\mu; \sigma^2)$$

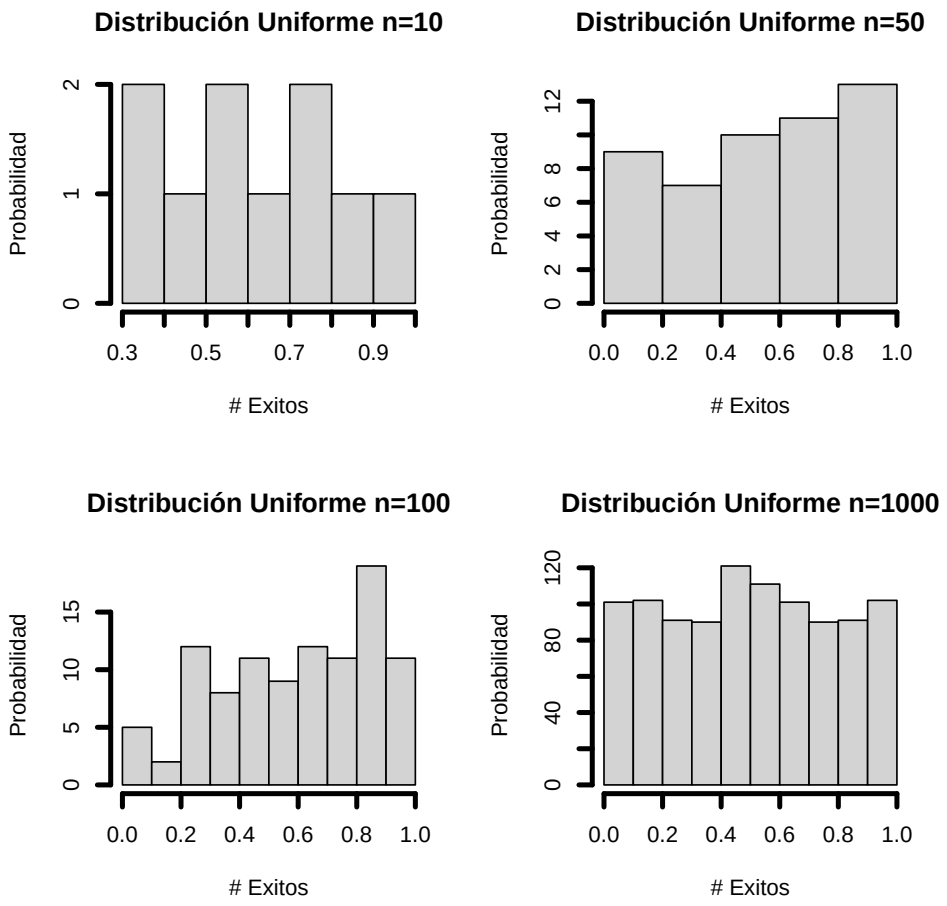

Figura 1.3: Distribución Uniforme

Distribución normal estándar

Función de distribución acumulada

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} exp\left(\frac{-(x-\mu)^2}{2\sigma^2}\right) du$$

$\mu = 0$, $\sigma = 1$: $X \sim N(0;1)$.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} exp\left(-\frac{(x)^2}{2}\right) (\mu \in (-\infty, \infty), \sigma > 0)$$

$$X \sim Z(0;1)$$

Función de distribución acumulada

$$F(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} exp\left(\frac{-(x)^2}{2}\right) du$$

$$Z = \frac{x-\mu}{\sigma}$$

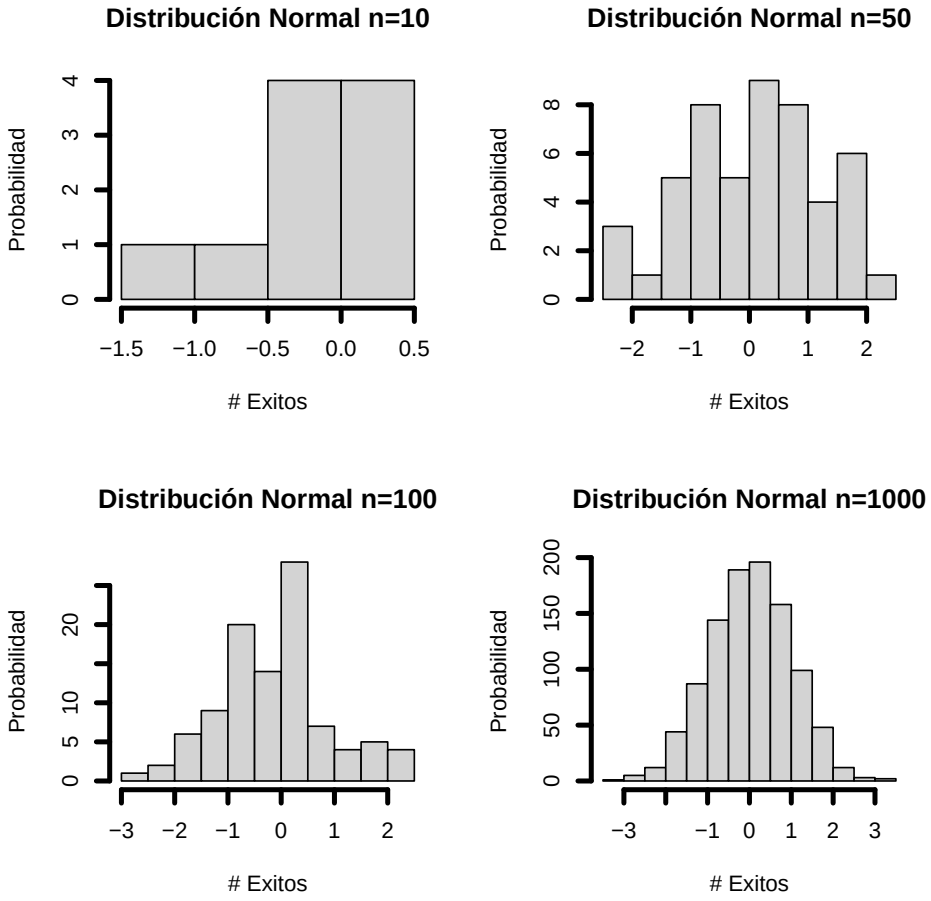

Figura 1.4: Distribución Normal

Distribución Log-Normal

Los precios de los instrumentos financieros tendrán este tipo de distribución, y esta es una de las razones por las cuales se trabaja mejor con rendimientos dado que este tipo de medición es más complejo.El resultado de la variable siempre es positivo como en los precios de los activos $x > 0$ y la variable aleatoria se distribuye $X \sim LN(0;1)$.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}\frac{1}{x}exp\left(-\frac{(ln(x)-\mu^2)}{2\sigma^2}\right)$$

Para toda variable aleatoria que se distribuye de forma normal, $X \sim LN(\mu;\sigma^2) \leftrightarrow exp(Y) = X \sim LN(\mu;\sigma^2)$.

$$\mathbf{E}(X) = e^{\mu+\frac{\sigma^2}{2}},$$

$$\mathbf{Var}(X) = e^{2\mu+\sigma^2}(e^{\sigma^2-1}),$$

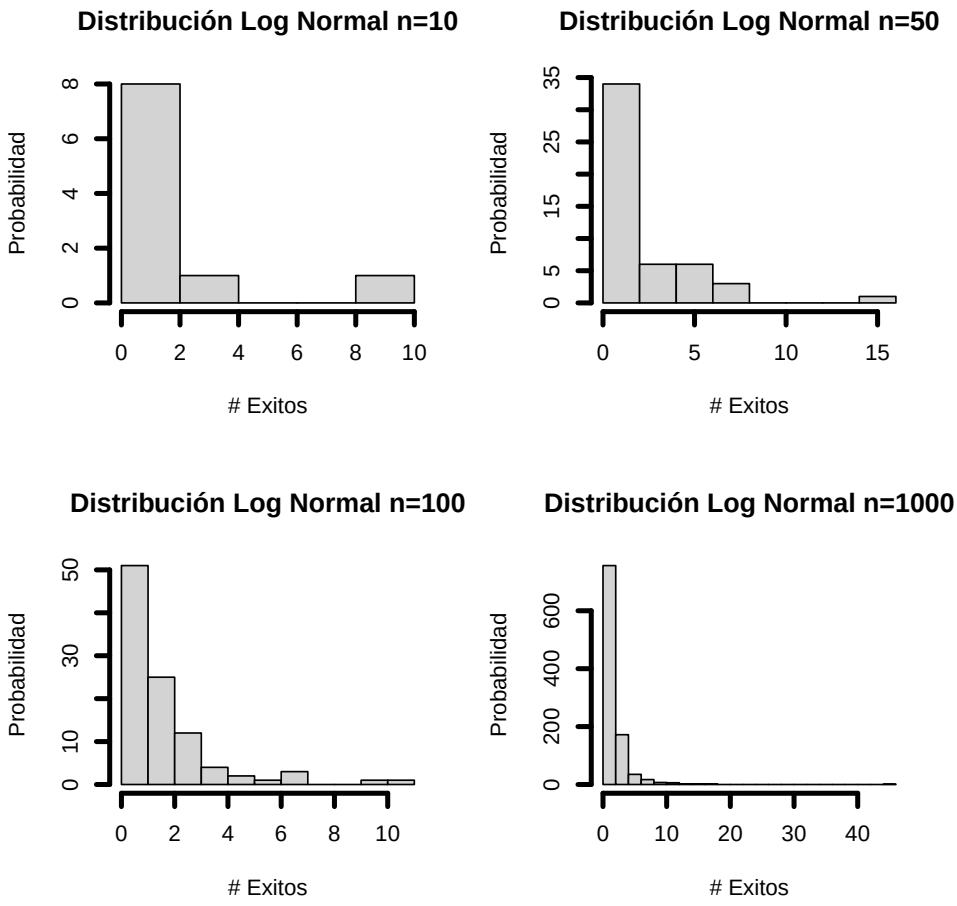

Figura 1.5: Distribución Log-Normal

Forma de la distribución

Este curso parte del suspuesto de normalidad para medir, desde la estadística des-

criptiva se puede evaluar de de la siguiente forma

$$Sesgo = \frac{\sum_{i=1}^{n}(x_i - \mu)^3}{(n-1)\sigma^3} \tag{1.4}$$

$$Kurtosis = \frac{\sum_{i=1}^{n}(x_i - \mu)^4}{(n-1)\sigma^4} \tag{1.5}$$

El estadístico se obtiene con ayuda de la ecuación 1.4 y 1.5

$$LM = N\left[\frac{Sesgo^2}{6} + \frac{(Kurtosis - 3)^2}{24}\right] \tag{1.6}$$

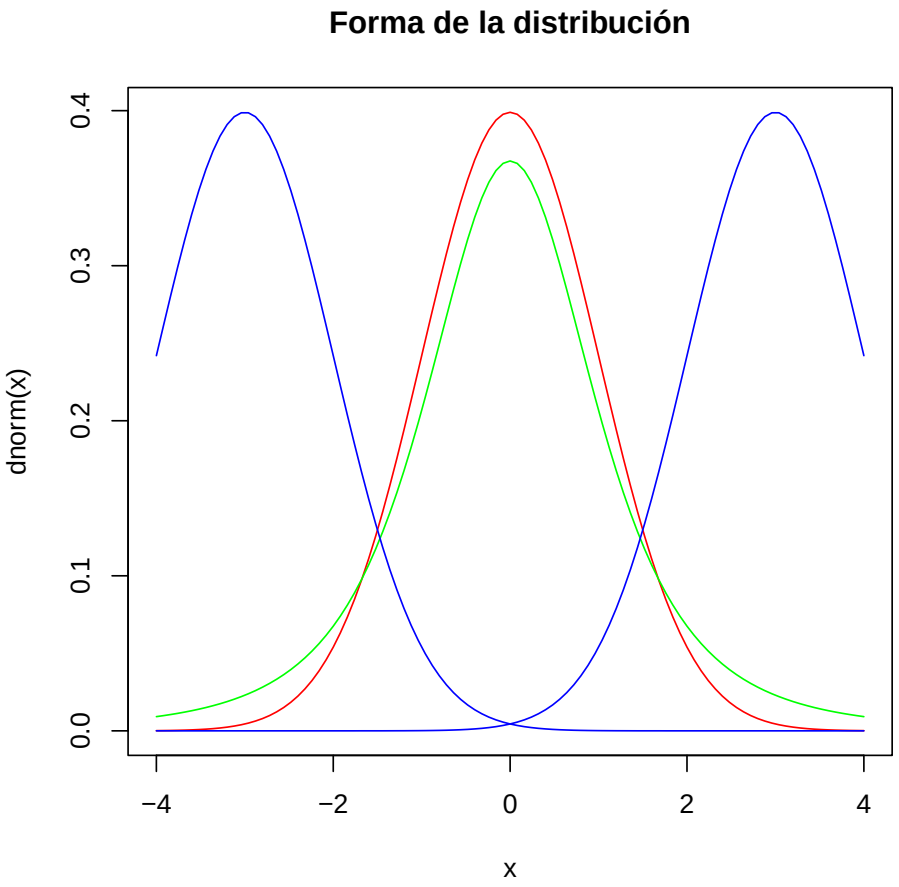

Figura 1.6: Forma de la distribución

Distribución marginal: Usando una función de densidad $f(\cdot)$ se puede representar la ecuación 2.2 y obtener la distribución marginal que es la probabilidad de un evento

específico.

Ejemplo:

Siendo X y Y variables aleatorias con distribución conjunta $f(x, y)$. La distribución marginal de Y, $f(y)$ es la función de densidad conjunta promedio sobre todos los posibles valores de X.

$$f(y) = \int_X f(x, y)dx \tag{1.7}$$

Si Y es univariada y $X = (X_1, X_2)$ donde X_1 y X_2 son univariadas entonces

$$f(y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x_1, x_2, y)dx_1dx_2 \tag{1.8}$$

Dada la distribución condicionada de Y dado $X = x$

$$f(y \mid x) = \frac{f(x, y)}{f(x)} \tag{1.9}$$

Sustituyendo 1.9 en 1.7 entonces

$$f(y) = \int_X f(y \mid x)f(x)dx \tag{1.10}$$

Usando probabilidad total Y y X son independientes si $f(x, y) = f(x)f(y)$ por lo tanto la probabilidad marginal de y es:

$$f(y \mid x) = f(y) \tag{1.11}$$

El resultado se debe a que la actualización de X no genera información adicional de Y y viceversa, como relaciona este resultado con la proporción?.

Como conclusión se puede definir la distribución marginal de los datos para pmf o pdf sobre una muestra de datos Y siendo no condicional a los parámetros θ.

$$m(y) = \sum_{\theta} f(y \mid \theta)\pi(\theta) \tag{1.12}$$

Para distribuciones discretas previas π

$$m(y) = \int_{\theta} f(y \mid \theta)\pi(\theta)d\theta \tag{1.13}$$

Para distribuciones continuas previas π

Ejercicio

Ahora incluya Z como una tercera variable aleatoria, donde Y y X son condicionalmente independientes dado Z, encuentre la probabilidad marginal de $f(y \mid z)$.

1.2.4. Parámetros

Los parámetros de **escala**, **forma** y **posición** se utilizan para describir las características de una distribución de probabilidad. El parámetro de escala determina la dispersión de la distribución, mientras que el parámetro de forma determina la altura o sesgo de la distribución. El parámetro de posición determina la ubicación de la distribución en el eje horizontal. Comprender el papel de cada parámetro es importante para seleccionar una distribución adecuada para un conjunto de datos determinado.

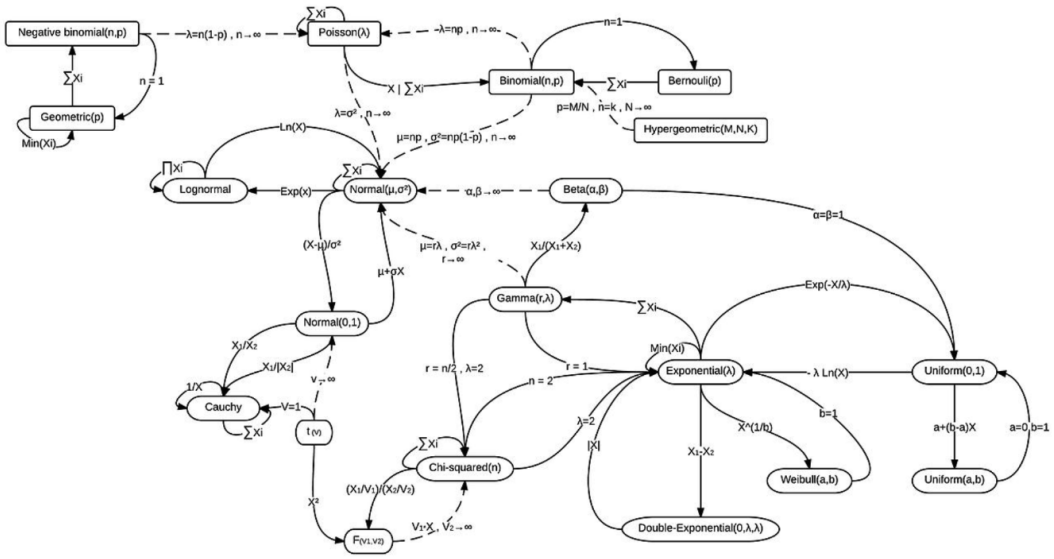

Figura 1.7: Las distribuciones y su relación a través de los parámetros

Cuando tenga dudas de como obtener un parámetro de una distribución, puede revisar la figura 1.7. Inicie con la distribución normal y trate de determinar de acuerdo a su relación con las demás los parámetros de la que usted necesite. En el caso en que no se encuentre una relación directa, puede despejar el valor esperado directamente de una media y varianza y conseguir los parámetros deseados de una distribución.

1.3. Familias exponenciales

La familia Exponencial es una familia unificada de distribuciones en espacios euclidianos de dimensión finita y ampliamente utilizada. Especializada al caso de la línea real, la familia Exponencial contiene como casos especiales la mayoría de las distribuciones discretas y continuas estándar que utilizamos para la modelización práctica, como la normal, Poisson, Binomial, exponencial, Gamma, normal multivariante, etc.

La distribución de una familia exponencial se define como:

$$p(y \mid \eta) = h(y)exp(\eta^T t(y) - a(\eta)) \tag{1.14}$$

Donde el parametro que se transforma es η, $t(y$ cumple con la condición de suficiencia, $h(y)$ es la medida subyacente y $a(\eta)$ es el normalizador logarítmico.

$$a(\eta) = log \int h(y)exp(\eta^T t(y)) \tag{1.15}$$

Integrado sobre el espacio muestral, se obtiene el resultado de 1. El estadístico $t(y)$ se denomina suficiente porque la verosimilitud de η solo depende de y.

Ejemplo

Hallar la familia exponencial de una distribución gaussiana para una variable aleatoria y.

$$p(y \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} exp\Big\{\frac{(y-\mu)^2}{2\sigma^2}\Big\} \tag{1.16}$$

$$p(y \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} exp\Big\{\frac{\mu}{\sigma^2}y - \frac{1}{2\sigma^2}y^2 - \frac{1}{2\sigma^2}\mu^2 - log\sigma\Big\} \tag{1.17}$$

A partir de 1.17 se puede observar que los parámetros se representan por $\eta = \langle \mu/\sigma^2, -1/2\sigma^2 \rangle$. La función de verosimilitud $t(y) = \langle y, y^2 \rangle$, el normalizador es $a(\eta) = \mu^2/2\sigma^2 + log\sigma = -\nu_1^2/4\nu_2 - (1/2)log(2\nu_2)$ y finalmente $h(y) = 1/\sqrt{2\pi}$.

Si se desea hallar el valor esperado y la varianza de la distribución normal, se pueden obtener los primeros dos momentos y usar las definiciones de valor esperado y varianza.

Derivando con respecto a η_1

$$\begin{aligned}\frac{da(\eta)}{d\eta_1} &= -\tfrac{\eta_1}{2\eta_2} \\ &= \mu \\ &= E[Y]\end{aligned}$$

Si se deriva con respecto a η_2

$$\begin{aligned}\frac{da(\eta)}{d\eta_2} &= -\tfrac{\eta_1^2}{4\eta_2^2} - \tfrac{1}{2\eta_2} \\ &= \sigma^2 + \mu \\ &= E[Y^2]\end{aligned}$$

Lo que implica que la varianza es $Var(Y) = -\frac{1}{2\eta_2}$.

1.4. Muestreo

Métodos de muestreo

La distribución de probabilidad asociada con la población (de la cual muestra) se llama distribución de población y distribución de probabilidad asociado con nuestra estadística se llama distribución muestral; claramente, los dosestán interrelacionados. Para conocer la distribución de la población, es imperativo saber todo lo que podamos sobre la distribución muestral. Por lo tanto, nos enfocamos en lo que sucede en el caso especial del muestreo del distribución normal, y en particular, cumplimos con la distribución muestral de $\overline{x}$ y s^2. Wackerly et al. (2010)

Muestreo

Usualmente cuando se lleva a cabo una investigación de forma cuantitativa, es necesario contar con variables que permitan generar las pruebas de contraste de hipótesis. Estas variables provienen de observaciones que se obtienen de una muestra dado que es muy difícil trabajar con una población. Peña (2014)

- Población - Parámetros
- Muestra - Estadístico
- error de muestra: Diferencia entre el estadístico y el parámetro

Muestreo de acuerdo a:

- Objeto de estudio
- Método utilizado (Paramétricos - No paramétricos)
- Información considerada (Clásico - Bayesiano)

Procedimientos de Inferencia Peña (2014)

Objetivo	¿Cómo se distribuye y?	¿Influye x en y?
Datos	Muestreo $(y_1, .., y_n)$	Diseño $x_1 : (y_{1,1}, ..., y_{1,n})$
Método	Paramétrico	No paramétrico
Información	Clásico - Bayesiano	
Resultados	$\hat{\theta} \in (a, b)$ - $\theta \hat{\mid} y$	Distribución empírica

- Muestreo aleatorio simple:
  - Cada elemento de la población tiene la misma probabilidad de ser elegido.
  - Las observaciones se realizan con reemplazamiento, de esta manera la poblaciüon es identica en todas las observaciones.
- Muestreo estratificado: Los elementos de la población se dividen en clases o estratos, pero de forma interna las información es homogénea.
- Muestreo por Conglomerados: En los conglomerados no hay diferencias entre los grupos, pero la información interna de cada grupo es heterogénea.
- Muestreo sistemático: Variación del aleatorio simple. N/n con k como su entero más próximo.

Distribuciones muestrales

Teorema 1 Para cualquier población, el valor promedio de todas las posibles medias muestrales calculado a partir de todas las posibles muestras aleatorias de un tamaño dado de la la población será igual a la media de la población, $\mu_{\overline{x}} = \mu$

Estimador insesgado: característica de ciertas estadísticas en las que promedio de todos los valores posibles de la estadística de muestra es igual al parámetro

Teorema 2 Para cualquier población, la desviación estándar de las posibles medias muestrales calculado a partir de todas las muestras aleatorias posibles de tamaño n es igual al desviación estándar de la población dividida por la raíz cuadrada del tamaño de la muestra. También llamado error estándar, $\sigma_{\overline{x}} = \sqrt{\frac{\sigma^2}{n}}$
Teorema 3 Si una población tiene una distribución normal, con media μ y una desviación estándar σ, la distribución muestral de la media muestral $\overline{x}$ también es normalmente distribuida con una media igual a la media de la población $(\mu_{\overline{x}} = \mu)$ y una desviación estándar muestral igual a la desviación estándar de la población dividida por la raíz cuadrada del tamaño de la muestra $\sigma_{\overline{x}} = \sqrt{\frac{\sigma^2}{n}}$
Ley de los grandes números
La ley de los grandes números es una propiedad que explica como el incremento del número de experimentos permite que el valor esperado de las simulaciones, se acerque al valor esperado real. Peña (2014)

Definición: Sea X_n para $n \in N$ unsa suceción de variables aleatorias reales e integrables sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$.Se dice que esta sucesión satisface la ley débil de los grandes números si

$$\frac{1}{n}\sum_{j=1}^{n}[X_j - E(X_j)] \xrightarrow[n\to\infty]{\mathbb{P}} 0 \tag{1.18}$$

Teorema del Límite Central: Si $X_1, X_2, ...,$ son variables aleatorias reales, idependientes e identicamente distribuidas iid con $E(X_n^2) < \infty$.Sean $\mu := E(X_n)$ z $\sigma^2 := Var(X_n)$. Si $\sigma > 0$ entonces Llinás Solano (2016)

$$Z_n := \frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow[n\to\infty]{d} N(0,1) \tag{1.19}$$

Sin embargo, hay muchas poblaciones que no son normales. Estadístico a menudo se encuentran tomando muestras de esas poblaciones. ¿Qué se puede decir en este caso? La sorprendente respuesta está contenida en el Teorema del límite central

- El tamaño de la muestra debe ser "suficientemente grande"
- Si la población es simétrica, entonces tamaños de muestra tan pequeños como 2 o 3 puede proporcionar una distribución de muestreo normalmente distribuida
- Si la población está muy sesgada o tiene una forma irregular, el tamaño de muestra requerido será mayor

- Una definición conservadora de un tamaño de muestra suficientemente grande es $n \geq 30$

Ejercicio

Un experimento de 20 pacientes con cancer arrojó que en promedio el tiempo en que recaen los pacientes después de una quimioterapia es de 3 meses con una variación media de 1 mes. Usando esta información:

- Genere un gráfico de densidad normal para 100 posibles candidatos.
- Implemente los dos algoritmos que están a continuación.
- Compare los tres gráficos resultantes y explique el papel de cada uno desde la perspectiva del muestreo estadístico.

Algorithm 1 Simulation of Sample Mean with 100 Observations

Require: Number of Observations n, Mean μ, Standard Deviation σ, Confidence Level α

Ensure: Sample Mean $\bar{x}$, Histogram of Sample Data, Confidence Interval for μ

1: Generate n random numbers from a Normal Distribution with mean μ and standard deviation σ
2: Calculate the Sample Mean $\bar{x}$
3: Calculate the Sample Standard Deviation s
4: Calculate the Standard Error of the Mean $SE = \frac{s}{\sqrt{n}}$
5: Calculate the Margin of Error $ME = z_{\alpha/2} \cdot SE$, where $z_{\alpha/2}$ is the critical value from the standard normal distribution for the specified confidence level
6: Calculate the Confidence Interval for the Mean: $(\bar{x} - ME, \bar{x} + ME)$
7: Generate n random numbers from a Normal Distribution with mean $\bar{x}$ and standard deviation $SE = \frac{s}{\sqrt{n}}$
8: Plot a density of the sample data with a line of each interval.

1.5. Teoría de la estimación de máxima verosimilitud

La "verosimilitud"de un modelo estadístico se define mediante la misma fórmula que la densidad,sin embargo el papel de los datos x y el parámetro θ se intercambian.

$$L_x(\theta) = f_\theta(x). \tag{1.20}$$

Algorithm 2 Simulation of Sample Variance with 100 Observations

Require: Number of Observations n, Mean μ, Standard Deviation σ, Confidence Level α

Ensure: Sample Variance s^2, Confidence Interval for σ^2

1: Generate n random numbers from a Normal Distribution with mean μ and standard deviation σ
2: Calculate the Sample Mean $\bar{x}$
3: Calculate the Sample Variance s^2
4: Calculate the Degrees of Freedom $df = n - 1$
5: Calculate the Lower and Upper Bound of the Chi-Square Distribution: $\chi^2_L = \frac{(df)s^2}{\chi^2_{\alpha/2,df}}$ and $\chi^2_U = \frac{(df)s^2}{\chi^2_{1-\alpha/2,df}}$, where $\chi^2_{\alpha/2,df}$ and $\chi^2_{1-\alpha/2,df}$ are the critical values from the chi-square distribution for the specified confidence level and degrees of freedom
6: Calculate the Confidence Interval for the Variance: $(\frac{(df)s^2}{\chi^2_U}, \frac{(df)s^2}{\chi^2_L})$
7: Generate n random numbers from a Chi-Square Distribution with Degrees of Freedom $df = n - 1$.
8: Plot a density of the sample data with a line of each interval.

Así, la verosimilitud se considera una función de θ para datos fijos x, mientras que la densidad se considera una función de x. En realidad, la verosimilitud es un concepto general que se define como:

$$L_x(\theta) = h(x) f_\theta(x) \tag{1.21}$$

Una verosimilitud para el modelo cuando $h(x)$ es cualquier función de valor estrictamente positivo de x que no contenga el parámetro θ. La razón de esta extensión de la noción es que todos los usos de la función de verosimilitud no se verán afectados en modo alguno por la presencia o ausencia de $h(x)$.

1.5.1. Estimación por máxima verosimilitud

El llamado método de máxima verosimilitud utiliza como estimador del verdadero valor desconocido del parámetro, el punto $\hat{\theta}_x$ que maximiza la verosimilitud L_x. Este estimador se denomina denomina estimador de máxima verosimilitud (MLE). No es realmente un método, siendo bastante impreciso en lo que se considera un maximizador. La función de verosimilitud L_x no necesita tener un maximizador, e incluso si lo tiene, el maximizador no tiene por qué ser único. A menudo maximizador global o local. La gente suele considerar el maximizador global, pero la teoría dice que un

"buen" maximizador local puede tener mejores propiedades que el maximizador global. Así que no sólo son maximizadores globales muy difíciles de encontrar, ni siquiera son deseables.

Así que lo que se hace generalmente es iniciar un buen algoritmo de optimización local en un buen punto de partida y tomar la solución producida por el algoritmo como el MLE (si el algoritmo converge a una solución). Técnicamente, lo que se requiere del punto de partida que obedezca la ley de la raíz cuadradaen el que su error de estimación va a cero como una constante dividida por la raíz cuadrada del tamaño de la muestra. Por lo general, se utiliza el mejor estimador que se pueda calcular como punto de partida.

1.5.2. Información de Fisher

Como la función logarítmica es monótona, maximizar la probabilidad es lo mismo que maximizar la probabilidad logarítmica.

$$l_x(\theta) = \log L_x(\theta). \tag{1.22}$$

Por muchas razones, es más conveniente utilizar la probabilidad logarítmica que la probabilidad. que la verosimilitud.
Las derivadas de la función de log-verosimilitud (1.22) son muy importantes en la teoría de la verosimilitud. Los momentos de las derivadas satisfacen algunas identidades importantes. Obsérvese que si la verosimilitud viene dada por (1.21), entonces la log-verosimilitud viene dada por

$$l_x(\theta) = \log h(x) + \log f_\theta(x) \tag{1.23}$$

Las derivadas (son derivadas con respecto a θ) no implican el término $\log h(x)$ porque no contiene θ. Así que estas derivadas están bien definidas y son las mismas independientemente de lo que se use en $h(x)$. El maximizador de (1.23) no importa cómo se define (maximizador local o global) porque no depende de $h(x)$. Por lo tanto el MLE es el mismo (si está definido) independientemente de qué $h(x)$ se use.

La primera derivada se iguala a cero.

$$E_\theta\big\{\nabla l_x(\theta)\big\} = 0, \tag{1.24}$$

Donde ∇f denota el vector de derivadas parciales de una función escalar f de una variable vectorial, a menudo llamada *gradiente* de f, y $\nabla f(x)$ denota el valor del gradiente en el punto x.

En segundo lugar, la varianza de la primera derivada es menos la expectativa de la segunda

$$var_\theta\{\nabla l_x(\theta)\} = -E_\theta\{\nabla^2 l_x(\theta)\}, \tag{1.25}$$

Donde $\nabla^2 f$ denota la matriz de segundas derivadas parciales derivadas parciales de una función escalar f de una variable vectorial *hessiana* de f, y $\nabla^2 f(x)$ denota el valor de la hessiana en el punto x.

Cualquiera de los lados de (1.25) se denomina información Fisher esperada (o simplemente información Fisher) y se denota $I(\theta)$.

Ejercicio:

Obtenga el estimador de máxima verosimilitud de la media y la varianza de la distribución normal.

Ejercicio:

Obtenga el estimador de máxima verosimilitud de los parámtros de las distribuciones, binomial y poisson.

1.6. Exchangeability(intercambiabilidad)

Suponga que tiene una variable aleatoria y para $(p(y_1, ..., y_n)$ con una densidad conjunta $Y_1, ..., Y_n$, si $(p(y_1, ..., y_n) = (p(y_{\pi_1}, ..., y_{\pi_n})$ para todas las permutaciones de $\pi\{1, ..., n\}$ entonces todos los conjuntos $Y_1, ..., Y_n$ son intercambiablesHoff (2009).

Con la densidad conjunta $p(y_1, ..., y_n)$, se debe especificar, cómo encapsular el tipo de dependencia asumida entre las cantidades aleatorias individuales y_i. En general, hay un gran número de supuestos posibles sobre la forma que pueden adoptar estas dependencias, pero hay algunas formas particularmente simples que describen con precisión una gran clase de configuraciones experimentales.

Suponga que al considerar $p(y_1, ..., y_n)$ el científico juzga que los subguiones, las .etiquetas"que identifican las cantidades aleatorias individuales son "no informativas", en el sentido de que la información que proporcionan las y_i es independiente del orden en que se recogen. Este juicio de "similitud.º "simetría"se capta exigiendo que

$$p(y_1, ..., y_n) = (p(y_{\pi_1}, ..., y_{\pi_n})$$

para todas las permutaciones π definidas en el conjunto $\{1, ..., n\}$. Se dice que una secuencia de cantidades aleatorias intercambiable si esta propiedad se cumple para cada subconjunto finito de ellas.

1.7. Teorema de Finetti

Definición: Una secuencia de variables aleatorias $(y_1, ..., y_n)$ es infinitamente intercambiable si para todo n,

$$p(y_1, ..., y_n) = \int \prod_{i=1}^{n} p(y_i \mid \theta) P(d\theta) \tag{1.26}$$

Para medida de P en θ. Si la distribución tiene una densidad, se puede remplazar $P(d\theta)$ cpm $p(\theta)d\theta$.

Mientras que $\prod_{i=1}^{n} p(y_i \mid \theta) P(d\theta)$ sea invariante al reordenamiento de los datos, se puede tener cualquier secuencia de distribución re escrita de la siguiente forma:

$$\int \prod_{i=1}^{n} p(y_i \mid \theta) p(\theta) d\theta$$

Donde n sera infinitamente intercambiable. Para poder aplicar el teorema, debe exitir un parámetro θ, debe haber una fucnión de verosimilitud $p(y \mid \theta)$, debe haber una distribución P sobre θ y finalmente los datos deben ser condicionalmente independientes.
La distribución de probabilidad $p(\theta)$ representa las creencias sobre los resultados de $\{Y_1, ..., Y_n\}$, incluyendo las creencias que se obtienen de $p(y_1, ..., y_n)$ Hoff (2009), por lo tanto

- $p(\theta)$ representa las creencias sobre el $lim_{n\to\infty} \sum Y_i/n$ para casos binarios.

- $p(\theta)$ representa las creencias sobre el $lim_{n\to\infty} \sum Y_i \leq c$ para c en cualquier otro caso.

Independencia condicional: Si $\theta \sim p(\theta)$ y $Y_1, ..., Y_n$ son condicionales i.i.d dado θ, entonces $Y_1, ..., Y_n$ son marginalmente independientes.

Para aclarar la diferencia entre las secuencias iid y las infinitamente intercambiables, considere que los motores de búsqueda han utilizado históricamente modelos de "bolsa de palabras"para modelar los documentos. Es decir, por el momento, se supone que el orden de las palabras en un documento no importa. Aun así, las palabras no son definitivamente iid. Si vemos una palabra y es una palabra alemana, esperamos que el resto del documento esté probablemente en alemán. Si vemos las palabras alemanas Reise (viaje), Flugzeug (avión) y Grenze (frontera), esperamos que el resto del documento esté en alemán y sea sobre el tema del viaje. Puesto que se supone intercambiabilidad infinita, hay un θ que rige estas intuiciones. Así, que θ puede tener muchos valores, y parece inverosímil que θ sea siempre finito. De hecho, se da el caso de que θ puede ser de dimensión infinita. Por ejemplo, en el trabajo bayesiano no paramétrico, θ puede ser un proceso estocástico.

1.8. Ejercicios Adicionales

1. Siendo $E[X] = \sum_{i=0}^{n} P(x_i)X_i$ y la varianza igual a $Var[X] = E[X^2] - (E[X]^2$ Investigue cuál es el valor esperado y la varianza y proponga un ejemplo de su campo.

$$f(x) = \binom{n}{x} p^x (1-p)^{n-x}$$

2. Obtenga el valor esperado y la varianza de la siguiente función que se distribuye de forma uniforme $U \sim (a, b)$:

   $f(y) = \begin{cases} \frac{1}{b-a} & a \leq y \leq b \\ 0 & \end{cases}$

   Cree un ejemplo desde su campo y encuentre el valor esperado y la varianza.

3. La experiencia ha demostrado que 30 % de todas las personas afectadas por cierta enfermedad se recuperan. Una empresa fabricante de medicamentos ha

inventado una nueva medicina. Diez personas con la enfermedad se seleccionaron al azar y recibieron la medicina; nueve se recuperaron al poco tiempo. Suponga que la medicina no es eficaz en absoluto. ¿Cuál es la probabilidad de que se recuperen al menos nueve de entre diez que recibieron la medicina?

4. Suponga que Y tiene función de densidad:

$$f(y) = \begin{cases} ky(1-y) & 0 \leq x \leq 1 \\ 0 & \end{cases}$$

   - Encuentre el valor de k que haga de f(y) una función de densidad de probabilidad.
   - Encuentre $P(0{,}4 \leq Y \leq 1)$.
   - Obtenga el Valor esperado y la varianza
   - Muestre que

5. Si un punto se localiza al azar en un intervalo (a, b) y si Y denota la ubicación del punto, entonces se supone que Y tiene una distribución uniforme en (a, b). Una experta en eficiencia de la planta selecciona al azar un lugar a lo largo de una línea de ensamble de 500 pies, desde el cual observa hábitos de los trabajadores de la línea. ¿Cuál es la probabilidad de que el punto que ella seleccione se encuentre

   - a menos de 25 pies del final de la línea?
   - a no más de 25 pies del principio de la línea?

6. En la bolsa de valores se negocian hasta 20000 acciones por año. El número de acciones negociadas se puede leer como una variable continua X en miles y se puede representar con la siguiente función de densidad:

$$f(x) = \begin{cases} ax^2 & 0 \leq x \leq 20 \\ 0 & \end{cases}$$

   - si $\int_0^{20} f(x)dx = 1 = \int_0^{20} ax^2 dx$ entonces obtenga a Tip a es una constante
   - Dado que el valor esperado es $E[X] = \int_0^{20} xf(x)dx$ Obtenga el valor esperado promedio de acciones tranzadas al año
   - Con que probabilidad se venden más de 18000 acciones al año.

7. Encuentre la media $\mu = E(X)$, la varianza $\sigma^2 = var(X)$ y la desviación estándar $\sigma = \sigma_x$ de la distribución

X	1	3	5	7
P	0,3	0,1	0,4	0,2

8. Al estudiar bajas cotizaciones para contratos de embarques, una empresa fabricante de microcomputadoras encuentra que los contratos interestatales tienen bajas cotizaciones que están uniformemente distribuidas entre 20 y 25, en unidades de miles de dólares. Encuentre la probabilidad de que la baja cotización en el siguiente contrato interestatal

   - Esté por debajo de $\$22,000$.
   - Sea de más de $\$24,000$.

9. Se lanza una moneda dos veces, los posibles resultados son:

$$\Omega = (\{C, C\}, \{C, S\}, \{S, C\}, \{S, S\})$$

   Si $P(A) = (\{C, C\}, \{C, S\})$ y $P(B) = (\{C, S\}, \{S, C\})$

   Entonces probar que $P(A \cap B) = P(A)P(B)$ (Independencia)

10. Usando el anterior ejercicio proponer uno que no tenga independencia o que tenga independencia en caso de que en el anterior no se pueda probar independencia.

11. Suponga que los pronósticos de tasa de interés preferencial de enero de 1996 de todos los analistas económicos están distribuidos normalmente en forma aproximada con media de 7 % y desviación estándar de 2.6 %. Si un solo analista se selecciona al azar entre este grupo, ¿cuál es la probabilidad de que el pronóstico del analista de la tasa de interés preferencial

    - exceda de 11 %?
    - sea menor que 9 %?

Para las siguientes distribuciones conjuntas que describen las variables aleatorias Y y X, encuentre la distribución marginal y la condicional. Determine si estas son independientes.

12. Encuentre la distribución marginal de Y condicionada a $X = 0$.

	X=0	X=1
Y=0	0.14	0.26
Y=1	0.21	0.39

13. Encuentre la distribución marginal de X condicionada a $Y = 2$.

	X=0	X=1	X=2
Y=1	0.05	0.04	0.01
Y=2	0.1	0.08	0.02
Y=3	0.35	0.28	0.07

14. Suponga que solo se pueden distinguir dos valores de T, $T > 0$ y $T \leq 0$, y dos valores de N , $N \leq 1$ y $N > 1$. Encuentre la distribución conjunta de estos eventos

	T=-1	T=0	T=1	T=2
N=0	0.02	0.04	0.01	0.06
N=1	0.04	0.08	0.02	0.10
N=2	0.09	0.28	0.07	0.11
N=3	0.06	0.02	0.09	0.01

Capítulo 2

Conceptos Fundamentales

Las secciones de este capítulo inician con los conceoptos relacionados con la regla bayesiana y sus principales propiedades. Luego se inicia con los modelos univariados discretos y continuos para comprender el papel de las distribuciones previas y posteriores. En la siguiente parte este documento profundiza en los modelos multivariados en donde se analisan los mismos procesos teniendo en cuenta la relación entre las variables y su distribución y finalmente se abordan el concepto de jerarquia necesario para la estimación de los parámetros de los modelos usando inferencia bayesiana.

2.1. Elementos Frecuentistas

Considere un problema en el que se desea hacer inferencias sobre un parámetro θ dados los datos x. En un entorno clásico, los datos se tratan como si fueran aleatorios, incluso después de haber sido observados, y el parámetro se considera una constante fija desconocida. En consecuencia, no se puede atribuir al parámetro ninguna distribución de probabilidad.

Por el contrario, en un enfoque bayesiano, los parámetros, al no haber sido observados, se tratan como aleatorios y, por tanto, poseen una distribución de probabilidad, mientras que los datos, al haber sido observados, se tratan como fijos.

Se realizan n ensayos Bernoulli independientes en los que se observa x, el número de veces que ocurre un suceso. La idea es hacer inferencias sobre θ buscando la probabilidad de que el suceso ocurra en un solo ensayo.

El enfoque clásico se puede describir usando la siguiente función de distribución para

resolver un problema que está directamente relacionado con hallar la probabilidad de exito de un suceso:

$$P(X = x \mid \theta) = \binom{n}{x} \theta^x (1-\theta)^{n-x} \tag{2.1}$$

Es una función de lo que puede pasar con x, suponiendo que se conoce θ. Si se conoce x pero no se conoce θ, se puede tratar 2.1 como una función de probabilidad , $P(\theta)$. Entonces se elige el valor que maximiza esta probabilidad usando por ejemplo la estimación de máxima verosimilitud que define una proporción como $\frac{x}{n}$ con el correspondiente estimador $\frac{X}{n}$.

En el caso general, el enfoque clásico utiliza una estimación $T(x)$ para θ. La justificación de la estimación depende de las propiedades del estimador correspondiente $T(X)$ (sesgo, consistencia, . . .) utilizando su distribución muestral (dado θ). Es decir, se tratan los datos como si fueran aleatorios aunque sean conocidos. Este enfoque puede conducir a respuestas sin sentido.

Ejercicio:

Obtenga la estimación de θ^2, cuando el estimador de máxima verosimilitud es $\left(\frac{X}{n}\right)^2$. Determine si es un estimador sesgado.

2.2. Elementos Bayesianos

La palabra "bayesiano"tiene su origen en el siglo XVIII y en el reverendo inglés Thomas Bayes, quien, junto con Pierre-Simon Laplace, fue uno de los primeros pensadores en considerar las leyes del azar y la aleatoriedad de forma cuantitativa y científica.

El teorema de Bayes se define de la siguiente forma:

$$p(\theta \mid x) = \frac{p(x \mid \theta)p(\theta)}{p(x)} \propto p(x \mid \theta)p(\theta) \tag{2.2}$$

Donde $\propto$ significa proporcional: La ecuación 2.2 se puede re escribir de esta forma, gracias a que $1/p(x)$ es un factor constante que se puede ignorar cuando se obtiene $P(\theta \mid x)$ como función de un parámetro cualquiera θ.

La figura 2.1 presenta los elementos de teorema de bayes que son los mismos de la ecuación 2.2. Se puede observar que la distribución posterior donde se estima el valor

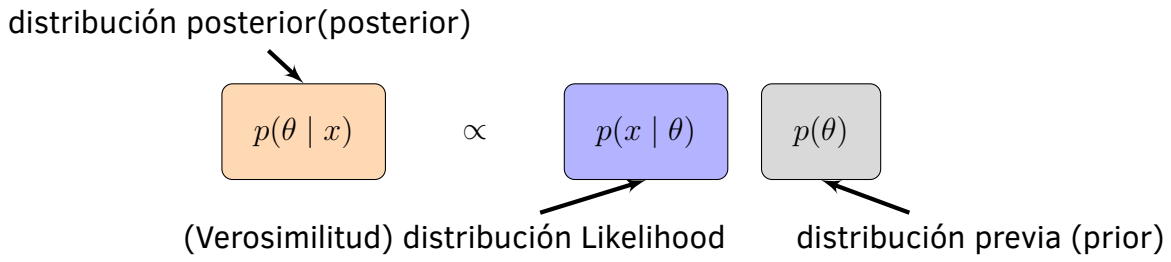

Figura 2.1: Teorema de Bayes

de un parámetro, es el resultado de es el resutado de las creencias o información previa que se tiene en una función de una distribución previa y que se actualiza con los datos que se obtiene a través de la distribución likelihood.

2.2.1. Definición de la prior

La información previa puede obtenerse a partir de la probabilidad o mediante algún tipo de argumento de invarianza. Las priores subjetivas se obtienen normalmente mediante un proceso que implica entrevistas con expertos en el campo y una reflexión muy intensa; de hecho, podría decirse que hay más filosofía y psicología en el estudio de las priores subjetivas que en el de las matemáticas. En este curso se inicia con las priores conjugadas. La principal justificación para el uso de las priores conjugadas es que son computacionalmente convenientes y tienen propiedades asintóticamente deseables.

Subjetiva Una probabilidad a priori puede ser subjetiva, basada en la información que una persona pueda tener debido a su experiencia pasada, a consideraciones científicas o al simple sentido común. Por ejemplo, se desea estimar la probabilidad de que una mujer seleccionada al azar tenga cáncer de mama. Se podría formar una simple información previa basada en la incidencia nacional o mundial del cáncer de mama. Un enfoque más sofisticado podría tener en cuenta la edad, el origen étnico y los antecedentes familiares de la mujer. Ninguno de los dos enfoques podría clasificarse necesariamente como correcto o incorrecto: de nuevo, es subjetivo.

Objetiva Una información previa objetiva (también llamada predeterminada, vaga, no informativa) también puede utilizarse en una situación determinada incluso en ausencia de información suficiente. Ejemplos de priorobjetivas son las prior planas, como las referencias de Laplace, Haldane, Jeffreys y Bernardo

2.2.2. Prior no informativas

La distribución posterior combina la información proporcionada por los datos con la información previa. En muchas situaciones, la información previa disponible puede ser demasiado vaga para formalizarla como una distribución de probabilidad o demasiado subjetiva para utilizarla en la toma de decisiones públicas.

Se han buscado distribuciones a priori que garanticen un papel mínimo en la distribución posterior. Estas distribuciones a priori se denominan a veces "distribuciones a priori de referenciaz se dice que la densidad a priori es "plana.º "no informativa". El argumento propuesto es "dejar que los datos hablen por sí solos".

Otra variación son las previas impropias que se terminan comviertiendo en distribuciones planas o uniformes a medida que los hiperparámetros tienden a infinito.

2.2.3. Jeffrey prior

El subjetivismo se ha convertido en el fundamento filosófico dominante de la inferencia bayesiana. Sin embargo, en la práctica, la mayoría de los análisis bayesianos se realizan con las llamadas priors "no informativas", es decir, información previa construida mediante alguna regla formal. La regla de Jeffrey en su intzerpretación se aleja de la representación única de la ignorancia y se acercq a la noción de que la información de la distribución previa debe elegirse por convención. Cuando el tamaño de las muestras es pequeño, es peligroso confiar en cualquier solución "por defecto"; pero cuando la asintótica se impone, la regla de Jeffreys y sus variantes siguen siendo opciones razonables Kass and Wasserman (1996).

La Jeffrey prior se define en términos de la información de Fisher:

$$\pi_j(\theta) \propto I(\theta)^{1/2} \tag{2.3}$$

Donde la información de Fisher es la segunda derivada con respecto a θ.

$$I(\theta) = -E_\theta\Big[\frac{d^2 \log p(Y \mid \theta)}{d\theta^2}\Big] \tag{2.4}$$

Las Jeffreys prior se utilizan mucho en el análisis bayesiano. En general, no son priors conjugados. Por ejemplo, con un modelo gaussiano $X \sim N(\mu, \sigma^2)$, se puede demostrar que $\pi_j(\mu) = 1$ y $\pi_j(\sigma) = \frac{1}{\sigma}$, que no se parecen en nada a una gaussiana o a una gamma inversa, respectivamente. Sin embargo, puede demostrarse que las Jeffreys priors

son límites de densidades a priori conjugadas. Por ejemplo, una densidad gaussiana $N(\mu_0, \sigma_0^2)$ se aproxima a una distribución previa plana a medida que $\sigma_0^2 \to \infty$, mientras que la gamma inversa $\sigma^{-(a+1)}e^{-b/\sigma} \to \sigma{-}1$ mientras que $a, b \to 0$.
Una distribución prior no informativa o impropia es una distribución prior que no transmite ninguna información específica sobre el parámetro que se está estimando. A menudo se utiliza cuando hay poco o ningún conocimiento previo sobre el parámetro. Una prioridad impropia es una distribución a priori que no se integra en un valor finito en el espacio de parámetros. Las distribuciones prior impropias se utilizan a menudo cuando no hay una elección natural para una distribución prior apropiada, o cuando los datos son lo suficientemente fuertes como para abrumar a la distribución prior. Sin embargo, las distribuciones prior inadecuadas pueden dar lugar a distribuciones posterior inadecuadas, que no son integrables y no pueden utilizarse para la inferencia.

Por otro lado, la conjugación es una propiedad de algunas distribuciones prior que permite que la distribución posterior tenga la misma forma funcional que la distribución prior. Esto facilita el cálculo de la distribución posterior, ya que puede obtenerse de forma cerrada. Las distribuciones a priori conjugadas se utilizan a menudo cuando la función de verosimilitud pertenece a una determinada familia de distribuciones, y la distribución prior se elige para que sea conjugada con esa familia. Por ejemplo, la distribución normal es conjugada consigo misma, por lo que se puede utilizar una distribución prior normal con una función de verosimilitud normal para obtener una distribución a posteriori normal

En resumen, las distribuciones prior no informativas o impropias se utilizan cuando hay poco o ningún conocimiento previo sobre el parámetro que se está estimando, mientras que las distribuciones prior conjugadas se utilizan cuando la función de verosimilitud pertenece a una determinada familia de distribuciones y la distribución prior se elige para que sea conjugada con esa familia.

2.3. Distribuciones Discretas

En esta sección se abordan los primeros modelos paramétricos discretos en distribuciones binomial y poisson. Estos modelos son de probabilidad de masa pmf y se caracterizan porque las variables que se miden a través de sus parámetros son discretas. Primero usando una combinación entre una distribución uniforme discreta y una binomial cuando no se tiene información previa, luego usando un poco más

de información adaptando una distribución beta. También se abordan la distribución poisson y gamma, así como sus respectivas familias exponenciales. Esto se ve más adelante cuando se use una distribución uniforme como distribución previa.

Antes de continuar se presenta la forma general de la regla de bayes que afecta directamente a la distribución likelihood cuando se generan n ensayos:

$$f(y_1, ..., y_n) = \int_\theta \Big\{ \prod_{i=1}^{n} f(y_i \mid \theta) \Big\} f(\theta) d\theta \tag{2.5}$$

2.3.1. Distribución Uniforme previa

En un escenario en el que no se tiene información acerca del problema que se desea analizar, se puede suponer que todos los eventos ocurren con la misma probabilidad Hoff (2009). Para un evento en el que la probabilidad se puede medir con ayuda de una distribución binomial, se puede generar un modelo en el que para una variable dicotómica o un evento discreto permita determinar una nueva distribución posterior para estimar la proporción de un evento. Esta proporción debería cambiar dependiendo de la información previa y la información que provienen de los datos.

Marco Estadístico

En un experimiento que se mide con un parámetro θ desconocido, se puede tener un vector de parámetros k que corresponden a los elementos que identifican a la distribución y al número de distribuciones que se desean usar. Para esta sección se tiene un parámetro $k = 1$ con un vector de datos $y = (y_1, y_2, .., y_n)$ que tiene información sobre θ.

Usando la distribución de verosimilitud $f(y \mid \theta)$ y la distribución previa θ, se trata θ como una variable aleatoria para calcular la distribución posterior $p(\theta \mid y) \propto f(y \mid \theta)p(\theta)$.

De esta forma se calcula:

$$p(\theta \mid y) \frac{f(y \mid \theta)p(\theta)}{\int_\Theta f(y \mid \theta)p(\theta)d\theta} \tag{2.6}$$

Para un modelo binomial se los parámetros de la distribuciónse proponen como n el tamaño de la muestra conocido y p la proporción que puede esta entre $0 < \theta < 1$.

La función de distribución es:

$$f(y \mid \theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y} \tag{2.7}$$

Usando una distribución previa uniforme sobre θ, $\theta \sim U(0,1)$ de $p(\theta) = 1$ para $0 < \theta < 1$. Donde la distribución posterior es:

$$p(\theta \mid y) \propto \binom{n}{y} \theta^y (1-\theta)^{n-y} \propto \theta^{y+1-1}(1-\theta)^{n-y+1-1} \tag{2.8}$$

Cuando se eliminan los datos que no dependen los parámetros se obtiene una distribución $Beta(y+1, n-y+1)$)(Ya miraremos con más detalle esto en clase). Donde un estimador bayesiano para θ puede ser $\frac{y+1}{n-y+1}$ que es el promedio de la distribución.

Por lo tanto, mienstras que $\theta \mid y \sim Beta(y+1, n-y+1)$ entonces el valor esperado $E(\theta \mid y)\frac{y+1}{n-y+1}$. Vale la pena pensar que sucede con los estimadores si n es grande.

2.3.2. Distribución predictiva $\tilde{y}$ de Y

Suponga que $y_i \sim Benoulli(\theta)$; $y_i = 0$, $y_i = 1$ y $\theta \sim U(0,1)$ con una distribución previa (prior) predictiva de probabilidad de $y_i = 1$.

$$P(y_i = 1) = \int_0^1 f(y_i = 1 \mid \theta)\pi(\theta)d\theta = \int_0^1 \theta d\theta = 1/2 \tag{2.9}$$

Donde π hace referencia a la distribución previa y $f(y \mid \theta)$ la función de verosimilitud.

Si y sigue una distribución $Bin(n, \theta)$ entonces:

$$p(y) = \int_0^1 f(y = 1 \mid \theta)\pi(\theta)d\theta = \binom{n}{y}\theta^y(1-\theta)^{n-y} \tag{2.10}$$

$$= \binom{n}{y}\frac{\Gamma(y+1)\Gamma(n-y+1)}{\Gamma(n+2)} \tag{2.11}$$

Esto indica que la distribución uniforme es discreta y para cualquier $Beta(a, b)$ la distribución es:

$$\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \int_0^1 \theta^{a-1}(1-\theta)^{b-1}d\theta = 1 \tag{2.12}$$

Si z es un entero positivo $\Gamma(z) = (z-1)!$(Definición función gamma) entonces se aplican los mismos resultados para $a = y+1$ y $b = n+1$.

Por lo tanto, si $\tilde{y}$ tiene resultados de la distribución Bernoulli:

$$P(\tilde{y} = 1 \mid y) = \int_0^1 P(\tilde{y} = 1 \mid \theta, y) f(\theta \mid y) = \int_0^1 \theta f(\theta \mid y) d\theta \tag{2.13}$$

$$= E(\theta \mid y) \tag{2.14}$$

Donde $E(\theta \mid y)$ es el valor esperado de la distribución posterior. Este valor se calcula usando la distribución prior $\theta \sim U(0,1)$ y la distribución posterior $\theta \mid y \sim Beta(y + 1, n + 1 - y)$ entonces $E(\theta \mid y) = \frac{y+1}{n+1}$.

Ejercicio

Suponga que desea estimar el riesgo de impago en un banco, no obstante aunque tiene la información histórica de algunos clientes que no han realizado los pagos, la pandemia cambio la situación económica de muchas familias y la información previa de su situación es muy difícil de definir. Por lo tanto, como el parámetro θ es desconocido, la distribución previa sigue una distribución uniforme $p(\theta) = 1$ para todo $\theta \in [0, 1]$.

	mean	sd
income	45331.60	14326.33
age	40.81	13.62
loan	4444.37	3045.41
default	0.14	0.35

Cuadro 2.1: Información impagos

La tabla 2.1 muestra que de 2000 clientes, el $14\,\%$ ha entrando en impagos. Para obtener la probabilidad de que un cliente no genere un pago es necesario calcular la distribución posterior usando los datos actuales y la información previa que en este caso es 1, porque no se conoce nada acerca de la situación.

$$\begin{aligned} p(\theta \mid y_1, ..., y_{2000}) &= \frac{p(y_1,...,y_{2000}|\theta)p(\theta)}{p(y_1,...,y_{2000})} \\ &= p(y_1, ..., y_{2000} \mid \theta) \times \frac{1}{p(y_1,...,y_{2000})} \\ &\propto p(y_1, ..., y_{2000} \mid \theta) \end{aligned}$$

La probabilidad de los datos dado el valor θ es:

$$p(y_1, ..., y_{2000} \mid \theta) \propto \theta^{1720}(1-\theta)^{280} \tag{2.15}$$

Figura 2.2: Distribución Likelihood

La figura 2.2 presenta el resultado de la función de verosimilitud para diferentes valores de θ, se observa que la probabilidad de que un cliente no pague una deuda es muy baja, mientras que la probabilidad de que un cliente cumpla con sus obligaciones es alta. Sin embargo se debe buscar la distribución posterior para encontrar el parámetro θ después de observar los datos y tener la información previa. Pregunta: Cómo es la gráfica de la distribución posterior?.

Ejercicio

Si se escala o normaliza la constante, se puede obtener el valor de $p(y_1, ..., y_{2000})$ usando la función gamma (ojo no distribución). Cuál es el resultado para el ejemplo anterior y las implicaciones para el cálculo de la distribución posterior.

$$\int_0^1 \theta^{a-1}(1-\theta)^{b-1} d\theta = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)} \tag{2.16}$$

Recuerde que:

- $\int_0^1 p(\theta \mid y_1, ..., y_{2000}) d\theta = 1$
- $p(\theta \mid y_1, ..., y_{2000}) = \theta^{1720}(1-\theta)^{280}/p(y_1, ..., y_{2000})$

Ejemplo

Jeffreys prior para la distribución binomial $Y \sim Bin(n, \theta), \quad 0 \leq \theta \leq 1$

$$p(y \mid \theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y} \tag{2.17}$$

Implementando 2.3 y 2.4 se escoge una prior $\pi(\theta)$ que sea invariante. Si se toma en cuenta que $\pi(\theta) \propto 1$ no tiene esta propiedad, entonces se deriva la prior de Jeffreys para θ.

$$\log p(y \mid \theta) = y \log \theta + (n-y)\log(1-\theta) \tag{2.18}$$

$$\frac{d}{d\theta}\log p(y\theta) = \frac{y}{\theta} - \frac{n-y}{1-\theta} \tag{2.19}$$

$$\frac{d^2}{d\theta^2}\log p(y\theta) = -\frac{y}{\theta^2} - \frac{n-y}{(1-\theta)^2} \tag{2.20}$$

Desde $E_\theta Y = n\theta$ para $Bin(n, \theta)$ entonces:

$$I(\theta) = -E_\theta\Big[\frac{d^2 \log p(Y \mid \theta)}{d\theta^2}\Big] \tag{2.21}$$

$$= \frac{n\theta}{\theta^2} + \frac{n - n\theta}{(1-\theta)^2} \tag{2.22}$$

$$= \frac{n}{\theta} + \frac{n}{(1-\theta)} \tag{2.23}$$

$$= \frac{n}{\theta(1-\theta)} \tag{2.24}$$

Ejercicio:

Genere en una gráfica el siguiente algoritmo, usted es libre de escoger los parámetros de las distribuciones.

Algorithm 3 Simulation of Uniform Beta distribution

Input: n trials, k successes
Prior: Uniform distribution with parameters a and b: $f(\theta) = 1$
Likelihood: Binomial distribution with parameter p: $L(\theta|y) = \binom{n}{k} p^k (1-p)^{n-k}$
Posterior: Beta distribution with parameters $\alpha + 1$ and $\beta + 1$.
Output: Plot of prior, likelihood, and posterior distributions
procedure PlotDistributions
    $p \leftarrow$ sequence of values from 0 to 1
    $prior \leftarrow$ Value equal to 1
    $likelihood \leftarrow$ sequence of binomial values with parameter p
    $posterior \leftarrow$ sequence of beta values with parameters $\alpha + 1$ and $\beta + 1$
    plot $prior$, $likelihood$, and $posterior$ on the same graph
end procedure

2.3.3. Distribución Conjugada caso de Beta

En esta sección se introduce el término de distribución previa conjugada en el que tanto la distribución posterior como previa son la misma función de distribución. La mayor ventaja de este elemento es que se puede tener una solución cerrada en el que la aplicación numérica es más eficiente.

Distribución beta-binomial El caso de la beta-binomial es un caso de proceso conugado ya que la distribución previa y posterior siguen una distribución beta.

Por otra parte como los valores constantes de una función de distribución son iguales a 1 y se pueden hallar proporciones aplicando la regla de bayes, el término kernel se refiere a la parte de la función de distribución que depende de la variable aleatoria. (Recuerde que en estadística bayesiana la variable aleatoria es el párametro θ)

Por lo tanto para una variable aleatoria $Y \mid \theta \sim Bin(n, \theta)$ se puede considerar una distribución previa en el que el parámetro $\theta \sim Beta(a, b)$ para $a, b > 0$ conocidos. La distribución beta se define de la siguiente forma para $0 \leq \theta \leq 1$:

$$f(\theta) = \frac{1}{Beta(a,b)} \theta^{a-1}(1-\theta)^{b-1} \tag{2.25}$$

Donde $Beta(a, b) = \frac{\Gamma(a)+\Gamma(b)}{\Gamma(a+b)}$ y en donde la suma de las probabilidades de todos los escenarios es igual a 1.

$$\int_0^1 f(\theta) d\theta = 1 \tag{2.26}$$

Para datos binarios $Y_1, \ldots, Y_n$ el resultado es:

$$p(\theta \mid y) = \frac{p(y \mid \theta)p(\theta)}{p(y)} \tag{2.27}$$

$$= \frac{\theta^{\sum y_i}(1-\theta)^{n-\sum y_i} p(\theta)}{p(y)} \qquad \text{(Since i.i.d.)} \tag{2.28}$$

$$\tag{2.29}$$

La cantidad $\sum_{i=1}^{n} Y_i$ es el único estadístico que es necesario para calcular la probabilidad posterior de θ. Esto la hece un elemento suficiente para realizar el proceso de inferencia sobre θ. El estadístico $Y = \sum Y_i$ tiene una distribución binomial con parámetros (n, θ).

$$p(y \mid \theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y} \tag{2.30}$$

Una uniforme previa es también un Beta(a, b). Para calcular la probabilidad posterior $p(\theta \mid y)$ cuando $p(\theta)$ es *no* uniforme; en particular, cuando la distribución previa sobre θ es una distribución Beta ($\theta \sim$ Beta(a, b)):

$$\begin{aligned}
p(\theta \mid y) &= \frac{p(\theta)p(y \mid \theta)}{p(y)} && (2.31)\\
&= \frac{1}{p(y)} \times \underbrace{\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1}(1-\theta)^{b-1}}_{\text{PDF of Beta}(a,b)} \times \underbrace{\binom{n}{y} \theta^y (1-\theta)^{n-y}}_{p(y \mid \theta) \text{ above}} && (2.32)\\
&= c \times \theta^{a+y-1}(1-\theta)^{b+n-y-1} && \text{(Combine } \theta\text{s)} \quad (2.33)
\end{aligned}$$

donde $c = f(n, y, a, b)$ es sólo comprimir las otras cosas en la ecuación en una constante, ya que no depende de θ. Ahora, el término con Γs en el anterior es la PDF de $\theta \sim$ Beta(a, b), que también puede expresarse con una constante $c = f(a, b)$: $p(\theta) = c\theta^{a-1}(1-\theta)^{b-1}$. Esto se parece a la ecuación anterior: por lo tanto, $p(\theta)$ y $p(\theta \mid y)$ son proporcionales a $\theta^{a-1}(1-\theta)^{b-1}$ por alguna constante c.
Como se sabe las distribuciones de probabilidad, $\int p(\theta) = \int p(\theta \mid y)\, d\theta = 1$,comparten la misma escala, lo que significa que $p(\theta \mid y)$ es en realidad una PDF Beta.

$$(\theta \mid y) \sim \text{Beta}(a + y, b + n - y).$$

Por lo tanto la distribución beta es una distribución conjugada previa para la distribución binomial. Donde el valor esperado de θ es $\frac{a}{a+b}$.

Ejercicio

Calcule el valor esperado y la varianza de la distribución beta prior.

Ejercicio

Encuentre la distribución posterior aplicando la regla de bayes, usando la forma beta-binomial.

Los parámetros de la distribución beta posterior son $\theta \mid Y \sim Beta(a+y, b+n-y)$

Ejercicio

Realice el ejemplo del crédito default usando la distribución beta posterior, grafique la distribución previa, likelihood y posterior para diferentes θ en una sola figura.

Ejercicio

Calcule el valor esperado y la varianza de la distribución beta posterior.

Ejercicio:

Genere en una gráfica el siguiente algoritmo, usted es libre de escoger los parámetros de las distribuciones.

Algorithm 4 Simulation of Conjugate Beta distribution

```
Input: n trials, k successes
Prior: Beta distribution with parameters α and β
Likelihood: Binomial distribution with parameter p
Posterior: Beta distribution with parameters α + k and β + n − k
Output: Plot of prior, likelihood, and posterior distributions
procedure PlotDistributions
    p ← sequence of values from 0 to 1
    prior ← sequence of beta values with parameters α and β
    likelihood ← sequence of binomial values with parameter p
    posterior ← sequence of beta values with parameters α + k and β + n − k
    plot prior, likelihood, and posterior on the same graph
end procedure
```

Ejercicio

Supongamos que vamos a tomar una muestra de 100 individuos de un barrio (de tamaño muy superior a 100) y preguntamos a cada persona de la muestra si apoya la política Z o no. Sea $Y_i = 1$ si la persona i de la muestra apoya la política, y $Y_i = 0$ en caso contrario.

a Suponga que $Y_1, ..., Y_100$ son, condicionadas a θ, variables aleatorias binarias i.i.d. con expectativa θ. Escriba la distribución conjunta de $Pr(Y_1 = y_1, ..., Y_100 = y_100 \mid \theta)$ de forma compacta. Escriba también la forma de $Pr(Y_i = y \mid \theta)$.

b De momento, suponga que cree que $\theta \in \{0{,}0, 0{,}1, ..., 0{,}9, 1{,}0\}$. Dado que los resultados de la encuesta fueron $\sum_{i=1}^{100} Y_i = 57$, calcule $Pr(Y_i = 57 \mid \theta)$ para cada uno de estos 11 valores de θ y grafique estas probabilidades en función de θ.

c Suponga que originalmente no se disponía de información previa para creer y por tanto $Pr(\theta = 0{,}0) = Pr(\theta = 0{,}1) = ... = Pr(\theta = 0{,}9) = Pr(\theta = 1{,}0)$. Utilice la regla de Bayes para calcular $p(\theta \mid \sum_{i=1}^{n=1} Y_i = 57)$ para cada valor de θ. Cree un gráfico de esta distribución posterior en función de θ.

d Suponga ahora que permite que θ sea cualquier valor del intervalo $[0, 1]$. Utilizando la densidad a priori uniforme para θ, de modo que $p(\theta) = 1$, trace la densidad posterior $p(\theta) \times Pr(\sum_{i=1}^{n} Y_i = 57 \mid \theta)$ en función de θ.

e Como se ha comentado en clase, la distribución posterior de θ es $beta(1 + \alpha, 1 + n - \beta)$. Represente gráficamente la densidad posterior en función de θ. Discuta las relaciones entre todos los gráficos que ha hecho para este ejercicio.

Ejercicio

Análisis de sensibilidad: A veces resulta útil expresar los parámetros a y b de una distribución beta en términos de $\theta_0 = a/(a + b)$ y $n_0 = a + b$, de forma que $a = \theta_0 n_0$ y $b = (1 - \theta_0)n_0$. Reconsiderando los datos de la encuesta por muestreo del anterior ejercicio, para cada combinación de $\theta_0 \in \{0{,}1, 0{,}2, ..., 0{,}9\}$ y $n_0 \in 1, 2, 8, 16, 32$ encuentre los valores correspondientes de a, b y calcule $Pr(\theta > 0{,}5 \mid \sum Y_i = 57)$ utilizando una distribución prior $beta(a, b)$ para θ. Muestre los resultados con un gráfico de contorno y discuta cómo se podría utilizar el gráfico para explicar a alguien de una forma u otra debería creer que $\theta > 0{,}5$, basados en que $\sum_{i=1}^{100} Y_i = 57$.

Ejercicio

Establecimiento de parámetros para una distribución a priori beta para θ, la proporción de californianos que apoyan la pena de muerte, es beta con media 0,6 y desviación típica 0,3.

a Determine los parámetros α y β de su distribución a priori. Esboce la función de densidad a priori.

b Se toma una muestra aleatoria de 1000 californianos, y el 65 % apoya la pena de muerte. ¿Cuáles son su media y varianza posteriores para θ? Dibuje la función de densidad posterior.

c Examine la sensibilidad de la distribución posterior a diferentes medias y amplitudes a priori, incluida una a priori no informativa.

2.4. Modelo Poisson

Esto es para mediciones que tienen valores que son números enteros donde la PDF de una distribución de Poisson. Si $Y \sim$ Poisson(θ) entonces

- $p(Y = y \mid \theta) = \theta^y e^{-\theta}/y!$
- $\mathbb{E}(Y) =$ Var$(Y) = \theta$

Como $Y = \sum Y_i$ es un estadístico suficiente para n ensayos Bernoulli independientes, existe un estadístico suficiente para una muestra de n i.i.d.

$$P(Y_1 = y_1, \ldots, Y_n = y_n \mid \theta) = \prod_i p(y_i \mid \theta) \tag{2.34}$$

$$= \prod_i \frac{\theta^{y_i} e^{-\theta}}{y_i!} \tag{2.35}$$

$$= \theta^{\sum_i y_i} e^{-n\theta} \prod_i \frac{1}{y_i!} \tag{2.36}$$

$$\tag{2.37}$$

Donde se comparan dos valores de θ,

$$\frac{p(\theta_a \mid y_1, \ldots, y_n)}{p(\theta_b \mid y_1, \ldots, y_n)} = \ldots \tag{2.38}$$

Tenga en cuenta que el $\prod_i 1/y_i!$ término es el mismo en esa relación, y por lo tanto cancela. Entonces el término $\theta_{a,b}^{\sum_i y_i}$ son los únicos términos que quedan en la fracción, y por tanto $\sum_i y_i$ estadístico suficiente. Este estadístico estadístico es un poco más

interesante que el caso Bernoulli - considere que no importa cuáles sean los valores individuales de y_i la inferencia sobre θ es posible sólo con la suma agregada.

Utilizando la regla de Bayes y el modelo de muestreo anterior:

$$
\begin{aligned}
p(\theta \mid y) &= \frac{p(\theta)p(y \mid \theta)}{p(y)} && (2.39)\\
&\propto p(\theta)p(y \mid \theta) && (2.40)\\
&\propto p(\theta) \times \theta^{\sum y_i} e^{-n\theta} && (2.41)\\
& && (2.42)
\end{aligned}
$$

Buscando alguna distribución de $p(\theta)$ que haga que la posterior como calculada usando la anterior la misma distribución que $p(\theta)$ misma. Esa familia de distribuciones es la familia Gamma. Si $\theta \sim$ Gamma(a, b), entonces
- $p(\theta) = \frac{b^a}{\Gamma(a)}\theta^{a-1}e^{-b\theta}$ - $\mathbb{E}(\theta) = a/b$ - Var$(\theta) = a/b^2$
La conjugada se obtiene:

$$
\begin{aligned}
p(\theta \mid y) &= \frac{p(\theta)p(y \mid \theta)}{p(y)} && (2.43)\\
&= \underbrace{\left(\frac{b^a}{\Gamma(a)}\theta^{a-1}e^{-b\theta}\right)}_{p(\theta)} \underbrace{\left(\theta^{\sum y_i} e^{-n\theta} \prod_i \frac{1}{y_i!}\right)}_{p(y|\theta)} \left(\frac{1}{p(y)}\right) && (2.44)\\
&= c \times \left(\theta^{a-1+\sum y_i} e^{-(b+n)\theta}\right) && (2.45)
\end{aligned}
$$

Donde $c = f(y, a, b)$ es eliminar todas las cosas que no dependen de θ en alguna constante normalizadora tal que $\int p(\theta \mid y)\, d\theta = 1$. Al igual que el modelo binomial, se reconoce a partir de la proporcionalidad a $\theta^{a-1}e^{-b\theta}$ que la distribución posterior de θ se distribuye Gamma. En concreto

$$
\theta \mid y_1, \ldots, y_n \sim \text{Gamma}(a + \sum_i y_i, b + n) \tag{2.46}
$$

Donde la esperanza es

$$\mathbb{E}(\theta \mid y_1, \ldots, y_n) = \frac{a + \sum y_i}{b + n} \tag{2.47}$$

$$= \frac{b}{b+n}\frac{a}{b} + \frac{n}{b+n}\frac{\sum y_i}{n} \tag{2.48}$$

$$\tag{2.49}$$

Ejercicio

Encuentre la distribución posterior para una variable aleatoria $X \sim Poisson(\theta)$ con una tasa $\theta > 0$ que tiene como función de probabalidad de masa pmf:

$$p(x \mid \theta) = Poisson(x \mid \theta) = e^{-\theta}\theta^x/x! \tag{2.50}$$

Para $x \in \{0, 1, 2, ...\}$: Suponga $X_1, ..., X_n \sim Poisson(\theta)$ dado θ. Donde la distribución prior es:

$$p(\theta) = Gamma(\theta \mid a, b) = \frac{b^a}{\Gamma(a)} e^{-b\theta} \mathbf{1}(\theta > 0) \tag{2.51}$$

una cercana aθ_A.

Ejercicio

Las poblaciones, n_i, y el número de casos, x_i, de una enfermedad en un año en cada uno de los seis distritos se indican en el cuadro siguiente:

Población n	Casos x
120342	2
235967	5
243745	3
197452	5
276935	3
157222	1

Suponemos que el número X_i en un distrito con población n_i es una variable aleatoria de Poisson con media $n_i\lambda/100000$. El número en cada distrito es independiente de los números en otros distritos, dado el valor de λ. Nuestra distribución a priori para λ es una distribución gamma con media 3.0 y desviación típica 2.0.

a Encuentre los parámetros de la distribución prior.

b Hallar la probabilidad prior de que $\lambda < 2{,}0$.

c Hallar la verosimilitud.

d Hallar la distribución posterior de λ.

e Hallar la media posterior y la desviación típica posterior de λ.

f Trace una gráfica que muestre las funciones de densidad de probabilidad prior y posterior de λ en los mismos ejes.

g Encuentre la probabilidad posterior de que $\lambda < 2{,}0$.

Ejercicio

Se registran los números de ventas de un artículo concreto de un sitio de venta por Internet en cada una de 20 semanas. Supongamos que, dado el valor de un parámetro λ, estos números son observaciones independientes de la distribución $Poisson(\lambda)$. Si la distribución prior es una $gamma(a, b)$.

a La media y la desviacón estandar de λ son 16 y 8 respectivamente, encuentre los valores de a y b.

b Los datos de ventas son: 14 19 14 21 22 33 15 13 16 19 27 22 27 21 16 25 14 23 22 17. Encuentre la distribución posterior de λ.

c Grafique la prior y posterior de las funciones de densidad para λ.

d Encuentre el percentil $95\,\%$.

2.4.1. Familias exponenciales

Usando la información de 1.15 se puede obteber la familia exponencial

$$
\begin{aligned}
p(y \mid \theta) &= \frac{1}{y!}\theta^y e^{-\theta} && (2.52)\\
&= \frac{1}{y!}e^{y\log\theta}\text{exp}(-e^{\log\theta}) && (2.53)\\
&= h(y)c(\phi)e^{\phi t(y)} && (2.54)\\
& && (2.55)
\end{aligned}
$$

Donde

- $\phi = \log\theta$
- $h(y) = \frac{1}{y!}$
- $t(y) = y$
- $c(\phi) = \text{exp}(-e^{\phi})$.

Donde la distribución previa es $p(\phi \mid n_0, t_0) = \text{exp}(n_0 e^{-\phi})e^{n_0 t_0 \phi}$.

Ejercicio

Encuentre la distribución posterior de la distribución beta-binomial usando la definición de familias exponenciales.

2.5. Predicción

Esta sección se centran en el paso siguiente del proceso de estimación. Este es la predicción. Es decir, dados unos datos y y una nueva observación $\tilde{y}$, se puede buscar la distribución condicional de $\tilde{y}$ dada y. Esta distribución se denomina distribución predictiva posterior. Es decir, nuestro objetivo es encontrar $p(\tilde{y} \mid y)$. Este estimador minimizador se denomina estimador empírico de Bayes.

$$p(\tilde{Y} \mid y) = \frac{p(\tilde{y}, y)}{p(y)} \tag{2.56}$$

$$= \frac{\int_\theta p(\tilde{Y}, \theta, y) d\theta}{p(y)} \tag{2.57}$$

$$= \frac{\int_\theta p(\tilde{Y} \mid \theta, y) p(y, \theta) d\theta}{p(y)} \tag{2.58}$$

$$= \int_\theta p(\tilde{Y} \mid \theta, y) p(y, \theta) d\theta. \tag{2.59}$$

En la mayoría de los contextos, si θ está dado, entonces $\tilde{y} \mid \theta$ es independiente de y, es decir, el valor de θ determina la distribución de $\tilde{y}$, sin necesidad de conocer también y. Cuando éste es el caso, decimos que $\tilde{y}$ e y son condicionalmente independientes dado θ. Si θ es continua y $\tilde{y}$ y y son condicionalmente independientes dado θ, entonces la distribución posterior de la predicción es

$$f(\tilde{y} \mid y) = \int_\theta f(\tilde{y} \mid \theta) p(\theta \mid y) d\theta \tag{2.60}$$

Si θ es discreta y $\tilde{y}$ y y son condicionalmente independientes dado θ, entonces la distribución posterior de la predicción es:

$$p(\tilde{y} \mid y) = \sum_\theta p(\tilde{y} \mid \theta) p(\theta \mid y) \tag{2.61}$$

Ejemplo

Suponga que se desean hacer predicciones sobre los valores de observaciones futuras de datos. La distribución de los datos futuros Z dados los datos observados y es la distribución predictiva $f(z \mid y)$. Esta distribución sólo depende de z y y. Con un modelo paramétrico, entonces

$$f(z \mid y) = \int_\theta f(z \mid \theta, y) f(\theta \mid y) d\theta \tag{2.62}$$

Si se obtiene que Y y Z son condicionalmente independientes dado θ entonces $f(z \mid \theta, y) = f(z \mid \theta)$ de modo que se obtiene de 2.62.

$$f(z \mid y) = \int_\theta f(z \mid \theta) f(\theta \mid y) d\theta \tag{2.63}$$

Ejemplo

Asumiendo que ya se estimaron los parámetros de las distribuciones, se genera la predicción de las posibles observaciones. Si se conocen los datos $y_1, \dots y_n$ y se desea predecir el valor las siguientes observaciones $\tilde{Y}$. Por lo tanto si el resultado es binario se debe predecir $\tilde{Y} = 1$ con una probabilidad esperada al valor θ dado los datos en donde :

$$
\begin{aligned}
p(\tilde{Y} = 1 \mid y) &= \int p(\tilde{Y} = 1, \theta \mid y)\, d\theta && \text{(LTP)} && (2.64)\\
&= \int p(\tilde{Y} = 1 \mid \theta, y) p(\theta \mid y)\, d\theta && \text{(Chain rule)} && (2.65)\\
&= \int \theta p(\theta \mid y)\, d\theta && \text{(Since } \tilde{Y} \text{ is binary)} && (2.66)\\
&= \mathbb{E}(\theta \mid y). && && (2.67)
\end{aligned}
$$

En este caso la distribución posterior de la predicción es muy fácil de calcular y es una distribución Bernoulli con una probabilidad cierta probabilidad p. Sin embargo, cuando las distribuciones posteriores se complican sus distribuciones predictivas posteriores pueden requerir cálculos más complejos y pueden dar lugar a una familia diferente de distribuciones.

Es importante tener en cuenta que el uso de la expectativa en lugar de la moda es agradable, para ejemplos en los que se tiene una uniforme Beta$(1, 1)$ a priori y se observa $Y = 0$. Entonces,

$$
\begin{aligned}
\mathbb{E}(\theta \mid Y = 0) &= \frac{2}{2+n}\frac{1}{2} + \frac{n}{2+n}\frac{y}{n} = \frac{1}{2+n} && (2.68)\\
\theta_{MAP} &= \frac{y}{n} = 0 && (2.69)
\end{aligned}
$$

Y claramente la expectativa es más sensata como predictor de $\tilde{Y}$ futuro. Pero θ_{MAP} no es tan poco razonable cuando hay una previa no uniforme.

Ejercicio

Halle la distribución predictiva de la beta-binomial.

Algorithm 5 Simulation of Conjugate Poisson distribution

Input: n observations, λ rate parameter
Prior: Gamma distribution with parameters α and β: $f(\lambda) = \frac{\beta^\alpha}{\Gamma(\alpha)}\lambda^{\alpha-1}e^{-\beta\lambda}$
Likelihood: Poisson distribution with parameter λ: $L(\lambda|y) = \frac{\lambda^y e^{-\lambda}}{y!}$
Posterior: Gamma distribution with parameters $\alpha + y$ and $\beta + n$: $f(\lambda|y) = \frac{(\beta+n)^{\alpha+y}}{\Gamma(\alpha+y)}\lambda^{\alpha+y-1}e^{-(\beta+n)\lambda}$
Output: Plot of prior, likelihood, and posterior distributions
procedure PlotDistributions
    $\lambda \leftarrow$ sequence of values from 0 to 10
    $prior \leftarrow$ sequence of gamma values with parameters α and β
    $likelihood \leftarrow$ sequence of Poisson values with parameter λ
    $posterior \leftarrow$ sequence of gamma values with parameters $\alpha + y$ and $\beta + n$
    plot $prior$, $likelihood$, and $posterior$ on the same graph
end procedure

Predicción del modelo Poisson

La distribución de predicción de la distribución poisson se define:

$$p(\tilde{y} \mid y_1, \ldots, y_n) = \int_0^\infty p(\tilde{y} \mid \theta, y_1, \ldots, y_n) p(\theta \mid y_1, \ldots, y_n)\, d\theta \tag{2.70}$$

$$= \int_0^\infty p(\tilde{y} \mid \theta) p(\theta \mid y_1, \ldots, y_n)\, d\theta \tag{2.71}$$

$$= \int_0^\infty \left[\frac{\theta^{\tilde{y}} e^{-\theta}}{\tilde{y}!}\right] \times \left[\frac{(b+n)^{a+\sum y_i}}{\Gamma(a+\sum y_i)} \theta^{a+\sum y_i - 1} e^{-(b+n)\theta}\right] d\theta \tag{2.72}$$

$$= \int_0^\infty \left[\frac{\theta^{\tilde{y}+a+\sum y_i - 1} e^{-(b+n+1)\theta}}{\tilde{y}!}\right] \times \left[\frac{(b+n)^{a+\sum y_i}}{\Gamma(a+\sum y_i)}\right] d\theta \quad \text{Combine } \theta\text{s, } e\text{s} \tag{2.73}$$

$$= \frac{(b+n)^{a+\sum y_i}}{\Gamma(\tilde{y}+1)\Gamma(a+\sum y_i)} \int_0^\infty \theta^{\tilde{y}+a+\sum y_i - 1} e^{-(b+n+1)\theta}\, d\theta \tag{2.74}$$

La integral es proporcional a la densidad Gamma:

$$\int_0^\infty \frac{b^a}{\Gamma(a)} \theta^{a-1} e^{-b\theta}\, d\theta = 1 \tag{2.75}$$

$$\implies \int_0^\infty \theta^{a-1} e^{-b\theta}\, d\theta = \frac{\Gamma(a)}{b^a} \tag{2.76}$$

$$
\begin{aligned}
p(\tilde{y} \mid y_1, \ldots, y_n) &= \ldots && (2.77)\\
&= \left(\frac{(b+n)^{a+\sum y_i}}{\Gamma(\tilde{y}+1)\Gamma(a+\sum y_i)}\right)\left(\frac{\Gamma(\tilde{y}+a+\sum y_i)}{(b+n+1)^{\tilde{y}+a+\sum y_i}}\right) && (2.78)\\
&= \left(\frac{\Gamma(\tilde{y}+a+\sum y_i)}{\Gamma(\tilde{y}+1)\Gamma(a+\sum y_i)}\right)\left(\frac{(b+n)^{a+\sum y_i}}{(b+n+1)^{\tilde{y}+a+\sum y_i}}\right) && (2.79)\\
&= \left(\frac{\Gamma(\tilde{y}+a+\sum y_i)}{\Gamma(\tilde{y}+1)\Gamma(a+\sum y_i)}\right)\left(\frac{b+n}{b+n+1}\right)^{a+\sum y_i}\left(\frac{1}{b+n+1}\right)^{\tilde{y}} && (2.80)\\
&= negabinom(\tilde{y}, a+\sum y_i, b+n) && (2.81)
\end{aligned}
$$

La distribución binomial negativa aquí, cuyos parámetros se parecen a la Gamma posterior sobre θ, puede considerarse como una distribución de Poisson predictiva con mayor varianza debido al aumento de la incertidumbre sobre el valor de θ.

$$
\begin{aligned}
\mathbb{E}(\tilde{Y} \mid y_1, \ldots, y_n) &= \frac{a+\sum y_i}{b+n} = \mathbb{E}(\theta \mid y_1, \ldots, y_n) && (2.82)\\
\text{Var}(\tilde{Y} \mid y_1, \ldots, y_n) &= \frac{a+\sum y_i}{b+n}\frac{b+n+1}{b+n} = \mathbb{E}(\theta \mid y_1, \ldots, y_n) \times \frac{b+n+1}{b+n} && (2.83)
\end{aligned}
$$

A medida que n crece, la varianza de $\tilde{Y}$ se aproxima a la varianza de su expectativa $\mathbb{E}(\tilde{Y})$.

2.5.1. Regiones de confidencia

El intervalo de confianza bayesiano es un intervalo $[l(y), u(y)]$ que sigue las siguientes propiedades Hoff (2009) :

$$
P(l(y) < \theta < u(y) \mid Y = y) = ,95 \tag{2.84}
$$

Intuitivamente, un intervalo de confianza bayesiano cuantifica la incertidumbre sobre el verdadero valor del parámetro que se está estimando. Por otra parte, el intervalo de confianza frecuentista es un intervalo $[l(Y), u(Y)]$ con la siguiente propiedad:

$$P(l(Y) < \theta < u(Y) \mid theta) = ,95 \tag{2.85}$$

Intuitivamente, un intervalo de confianza frecuentista cuantifica nuestra incertidumbre sobre la medida que hemos hecho del parámetro con un valor verdadero fijo.

2.5.2. Inferencia sobre la distribución posterior

Las creencias posteriores son capturadas por una distribución entera $f(\theta \mid x)$. Para resumir esta parte se puede usar:

1. Gráficos y diagramas de la forma de la distribución.
2. Medidas de localización como la media, la mediana y la moda.
3. Medidas de dispersión como la varianza, los cuantiles, por ejemplo, cuartiles, rango intercuartílico.
4. Una región que capture la mayoría de los valores de θ.
5. Otros resúmenes pertinentes, por ejemplo, la probabilidad posterior de que θ sea mayor que algún valor.

2.5.3. Regiones HPD *Highest posterior density*

Las regiones *HPD* consisten en subconjuntos de espacio $s(y)$ con parámetro θ en donde Hoff (2009):

1. $P(\theta \in s(y)) \mid Y = y) = 1 - \alpha$.
2. Si $\theta_a \in s(y), y\theta_b \notin s(y)$ entonces $p(\theta_a \mid Y = y) > p(\theta_b \mid Y = y)$.

Así, para un HPD la densidad dentro de la región nunca es menor que fuera de la región. El HPD es la región con $100(1-\alpha)\,\%$ de probabilidad de contener θ con la longitud total más corta. Para distribuciones simétricas unimodales, el HPD y el intervalo creíble son lo mismo. Los intervalos creíbles suelen ser más fáciles de calcular y son invariables a las transformaciones de los parámetros. Los HPD son más complejos y existe una

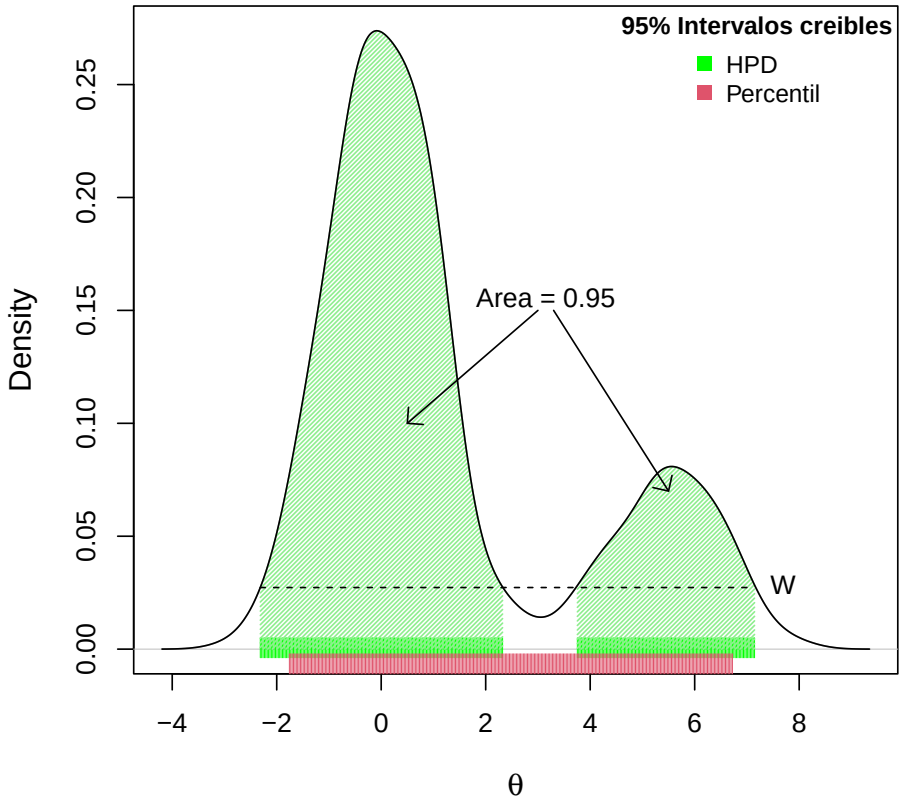

Figura 2.3: High Posterior Density

posible falta de invariancia bajo la transformación de los parámetros. Sin embargo, pueden ser más significativos para distribuciones multinomiales.

La figura 2.3 representa los intervalos creibles como resultado de la distribución posterior. Si se comprar el área roja con la verde, se observa que el espacio que mide cada uno de los intervalos es diferente y en el HPD depende del área de la densidad de las distribuciones.

Ejercicio

Genere una base de datos y con 30 observaciones. Use una distribución Poisson como likelihood y una distribución gamma como prior. Obtenga el HPD de su ejemplo püara un 95 %.

Ejercicio:

Encuentre el HPD de los ejercicios anteriores del capítulo 2.

Ejercicio:

Genere en una gráfica el siguiente algoritmo, usted es libre de escoger los parámetros de las distribuciones.

Algorithm 6 Simulation of High Credible Interval

Input: n observations, prior parameters α and β, posterior parameters α' and β'
Prior: Gamma distribution with parameters α and β: $f(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)}\theta^{\alpha-1}e^{-\beta\theta}$
Likelihood: Poisson distribution with parameter θ: $L(\theta|y) = \frac{\theta^y e^{-\theta}}{y!}$
Posterior: Gamma distribution with parameters $\alpha + y$ and $\beta + n$: $f(\theta|y) = \frac{(\beta+n)^{\alpha+y}}{\Gamma(\alpha+y)}\theta^{\alpha+y-1}e^{-(\beta+n)\theta}$
Output: Plot of posterior distribution with high posterior credible interval
procedure PlotPosterior
    $\theta \leftarrow$ sequence of values from 0 to 10
    $posterior \leftarrow$ sequence of gamma values with parameters α' and β'
    $lower \leftarrow$ value of θ such that $P(\theta \leq lower) = 0{,}025$
    $upper \leftarrow$ value of θ such that $P(\theta \leq upper) = 0{,}975$
    plot $posterior$ and shade the area between $lower$ and $upper$
end procedure

2.6. Distribuciones Continuas

Cuando las variables se distribuyen de forma continua, la medición se hace a través de otras herramientas como las integrales. La función para medir un evento incierto se conoce como función de densidad $f(y)$ para una variable aleatoria y. La distribución continua más usada es distribución normal con media μ y varianza σ^2. En este ejercicio θ se conocerá como μ. Existen dos casos: varianza conocida y desconocida.

2.6.1. Distribución Normal con varianza conocida

Una variable normal Y con media θ y varianza σ^2 (y por tanto desviación típica σ) se denota $Y \sim N(\theta, \sigma^2)$.

Debido al teorema del límite central, el modelo normal se utiliza todo el tiempo para estimar medias muestrales o valores que se sabe que son el resultado aditivo de varias variables aleatorias.
Usando la regla de bayes y unos hiperparámetros μ_0 y τ_0^2 conocidos, se ajusta una distribución previa para θ en donde la función de densidad $f(\theta)$ es proporcial a:

$$f(\theta) = \frac{1}{\sqrt{2\pi}\tau_0} exp\Big\{ -\frac{1}{2\tau_0^2}(\theta - \mu_0)^2 \Big\} \tag{2.86}$$
$$\propto exp\Big\{ -\frac{1}{2\tau_0^2}(\theta - \mu_0)^2 \Big\} \tag{2.87}$$
$$\propto exp\Big\{ -\frac{1}{2\tau_0^2}(\theta^2 - 2\mu_0\theta) \Big\} \tag{2.88}$$

A medida que se disponen de la función base para la distribución normal, al utilizar la función de verosimilitud (likelihood) se obtiene que:

$$f(y \mid \theta) = \frac{1}{\sqrt{2\pi}\sigma} exp\Big\{ -\frac{1}{2\sigma^2}(y - \theta)^2 \Big\} \tag{2.89}$$
$$\propto exp\Big\{ -\frac{1}{2\sigma^2}(\theta^2 - 2y\theta) \Big\} \tag{2.90}$$

Aplicando la regla de bayes, se puede usar 2.88 y 2.90 para encontrar la distribución posterior:

$$f(\theta \mid y) \propto exp\Big\{ -\frac{1}{2\sigma^2}(\theta^2 - 2y\theta) \Big\} exp\Big\{ -\frac{1}{2\tau_0^2}(\theta^2 - 2\mu_0\theta) \Big\} \tag{2.91}$$
$$= exp\Big\{ -\frac{1}{2}\Big(\frac{1}{\sigma^2} + \frac{1}{\tau_0^2}\Big)\Big[\theta^2 - 2\Big(\frac{1}{\sigma^2} + \frac{1}{\tau_0^2}\Big)^{-1}\Big(\frac{y}{\sigma^2} + \frac{\mu_0}{\tau_0^2}\Big)\theta\Big]\Big\} \tag{2.92}$$

la función base de la distribución normal tiene parámetros de la distribución posterior $\theta \mid y \sim N(\mu_n, \tau_n^2)$ donde:

$$\tau_n^2 = \Big(\frac{1}{\sigma^2} + \frac{1}{\tau_0^2}\Big)^{-1} \tag{2.93}$$
$$\mu_0 = \Big(\frac{1}{\sigma^2} + \frac{1}{\tau_0^2}\Big)^{-1}\Big(\frac{y}{\sigma^2} + \frac{\mu_0}{\tau_0^2}\Big) \tag{2.94}$$

La presición de la distribución posterior es la suma de la presición de los datos y la presición de la distribución previa.

Ejemplo

Teniendo $Y_1, ..., Y_n$ como un espacio finito de variables aleatorias que son intercambiables y que se distribuyen con media θ y varianza conocida σ^2 y usando la representación general 2.5. Se asume que $Y_i \mid \theta \sim N(\theta, \sigma^2)$ y que Y_i es independientemente condicional de θ. Por tanto, la especificación de una distribución previa para θ permite obtener la distribución conjunta de $X_1, ..., X_n$. Suponiendo que las creencias previas sobre θ puede expresarse mediante $\theta \sim N(\mu_0, \tau_0^2)$ para las constantes conocidas μ_0, τ_0^2. Calcule la distribución posterior de θ dado $y = (y_1, ..., y_n)$ Hoff (2009).

Hay dos parámetros en el modelo normal. Para simplificar, se supone primero que la varianza es conocida. Para hacer inferencia asumiendo que σ^2 es conocido, necesitamos identificar la distribución de muestreo y la distribución a priori ya que se debe calcular.

$$p(\theta \mid \sigma^2, y_1, \ldots, y_n) \propto p(y_1, \ldots, y_n \mid \theta, \sigma^2) \times p(\theta \mid \sigma^2) \tag{2.95}$$

Para la distribución muestral

$$\begin{aligned}
p(y_1, \ldots, y_n \mid \theta, \sigma^2) &= \prod_{i=1}^{n} p(y_i \mid \theta, \sigma^2) && (2.96)\\
&= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \text{exp}\left(-\frac{1}{2}\frac{(y_i-\theta)^2}{\sigma^2}\right) && (2.97)\\
&\propto \text{exp}\left[-\frac{1}{2}\sum_{i=1}^{n}\frac{(y_1-\theta)^2}{\sigma^2}\right] && (2.98)\\
&\propto \text{exp}\left[-\frac{1}{2}\left(\frac{\sum y_i^2}{\sigma^2} - 2\frac{\theta\sum y_i}{\sigma^2} + \frac{n\theta^2}{\sigma^2}\right)\right] && (2.99)\\
&\propto \text{exp}\left[-\frac{1}{2}\left(\frac{\sum y_i^2}{\sigma^2} - 2\frac{\theta\sum y_i}{\sigma^2} + \frac{n\theta^2}{\sigma^2}\right)\right] && (2.100)\\
&\propto \text{exp}\left[-\frac{1}{2}\left(\frac{\sum y_i^2}{\sigma^2} - 2\frac{\theta\sum y_i}{\sigma^2}\right)\right] && (2.101)
\end{aligned}$$

En donde se concluyen dos cosas

1. $p(\theta \mid \sigma^2, y_1, \ldots, y_n) \propto p(y_1, \ldots, y_n \mid \theta, \sigma^2) \times p(\theta \mid \sigma^2)$ depende solo de $\{\sum y_i^2, \sum y_i\}$, por lo que es un estadístico suficiente, como lo es $\{\bar{y}, s^2\}$.

2. Para que $p(\theta \mid \sigma^2)$ sea conjugada, la distribución posterior necesita tener términos cuadráticos en la función exponencial exp$(c_1(\theta - c_2)^2)$

En particular, es una nueva estrategia para tratar de identificar la anterior conjugada. Dado que los términos exponenciales en el modelo de muestreo y la distribución previa deben combinarse para producir la misma clase de distribución posterior, se debe elegir una distribución previa $\propto$ exp$(c_1, (\theta - c_2)^2)$. Convenientemente, las propias distribuciones normales tienen estos términos. Se puede comprobar que la familia normal es conjugada con el modelo de muestreo normal. Teniendo $\theta \mid \sigma^2 \sim \mathcal{N}(\mu_0, \tau_0^2)$:

$$p(\theta \mid \sigma^2, y_1, \ldots, y_n) \propto p(y_1, \ldots, y_n \mid \theta, \sigma^2) \times p(\theta \mid \sigma^2) \tag{2.102}$$

$$\propto \text{exp}\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - \theta)^2\right) \times \text{exp}\left(-\frac{1}{2\tau_0^2}(\theta - \mu_0)^2\right) \tag{2.103}$$

$$= \text{exp}\left[-\frac{1}{2}\left(\frac{1}{\tau_0^2}(\theta^2 - 2\theta\mu_0 + \mu_0^2) + \frac{1}{\sigma^2}\sum(y_i^2 - 2\theta y_i + n\theta^2)\right)\right] \tag{2.104}$$

$$= \text{exp}\left[-\frac{1}{2}\left(\left(\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}\right)\theta^2 + 2\left(\frac{\mu_0}{\tau_0^2} + \frac{\sum y_i}{\sigma^2}\right)\theta\right)\right] \tag{2.105}$$

$$\tag{2.106}$$

La simplificación de esto es:

- $a = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$
- $b = \frac{\mu_0}{\tau_0^2} + \frac{\sum y_i}{\sigma^2}$

Entonces

$$p(\theta \mid \sigma^2, y_1, \ldots, y_n) \propto \text{exp}\left[-\frac{1}{2}(a\theta^2 - 2b\theta)\right] \tag{2.107}$$

$$\propto \text{exp}\left[-\frac{1}{2}(a\theta^2 - 2b\theta + b^2/a) + \frac{1}{2}b^2/a\right] \quad \text{Completing the square} \tag{2.108}$$

$$\propto \text{exp}\left[-\frac{1}{2}(a\theta^2 - 2b\theta + b^2/a)\right] \quad \text{Throw away constants} \tag{2.109}$$

$$\propto \text{exp}\left[-\frac{1}{2}a(\theta^2 - 2b\theta/a + b^2/a^2)\right] \tag{2.110}$$

$$\propto \text{exp}\left[-\frac{1}{2}a(\theta - b/a)^2\right] \tag{2.111}$$

$$\propto \text{exp}\left[-\frac{1}{2}\left(\frac{\theta - b/a}{1/\sqrt{a}}\right)^2\right] \tag{2.112}$$

$$= N(\theta, b/a, 1/a). \tag{2.113}$$

Con los parámetros posteriores μ_n y τ_n^2 y los hiperparámetros que se denominan θ_0, los parámetros posteriores se denominan θ_n, es decir los parámetros actualizados tras una muestra de tamaño n.

$$\mu_n = b/a = \frac{\frac{1}{\tau_0^2}\mu_0 + \frac{n}{\sigma^2}\bar{y}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}} \tag{2.114}$$

$$\tau_n^2 = \frac{1}{a} = \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}. \tag{2.115}$$

Por lo tanto, $\theta \mid \sigma^2, y_1, \ldots, y_n \sim \mathcal{N}(\mu_n, \tau_n^2)$.

En los parámetros posteriores se tiene la frecuencia de varianzas inversas, es decir $\frac{1}{\tau_0^2}, \frac{n}{\sigma^2}$. Esto indica la importancia de utilizar precisión para entender y parametrizar las distribuciones normales previas y a posteriores. Específicamente, es mucho más conciso expresar los parámetros anteriores en términos de varianza. En concreto $\tilde{\tau_n^2} = 1/\tau_n^2$, es decir, la precisión posterior, y tildes similares para las predicciones,

$$\tilde{\tau_n^2} = \tilde{\tau_0^2} + n\tilde{\sigma^2}$$

Intuitivamente, la precisión posterior es una combinación de la creencia previa en la precisión de la verdadera media poblacional de los datos, más la (supuesta conocida) precisión, donde un mayor tamaño de muestra n aumenta esta precisión.

Utilizando la precisión, el hecho de que μ_n sea una media ponderada de la información a priori y muestral se hace más evidente.

$$\mu_n = \frac{\frac{1}{\tau_0^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\mu_0 + \frac{\frac{n}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\bar{y} \tag{2.116}$$

$$= \frac{\tilde{\tau_0^2}}{\tilde{\tau_0^2} + n\tilde{\sigma^2}}\mu_0 + \frac{n\tilde{\sigma^2}}{\tilde{\tau_0^2} + n\tilde{\sigma^2}}\bar{y} \tag{2.117}$$

Así que la media posterior es una media ponderada de la expectativa previa de la media μ_0 ponderada por la precisión de esa media $\tilde{\tau_0^2}$, y la media muestral observada $\bar{y}$ ponderada por el tamaño muestral n y la precisión (supuesta conocida) $\tilde{\sigma^2}$.

¿Cómo se selecciona τ_0^2? Una forma intuitiva de pensar en ello es tratar los parámetros previos para τ_0^2 como derivados de observaciones previas de κ_0 de la misma población (o similar) de la que se toman las muestras. Entonces μ_0 es la media de estas observaciones previas, y que $\tau_0^2 = \sigma^2/\kappa_0$ sea la varianza de la media de estas observaciones previas. Entonces la media posterior se simplifica bastante bien a:

$$\mu_n = \frac{\kappa_0}{\kappa_0 + n}\mu_0 + \frac{n}{\kappa_0 + n}\bar{y} \tag{2.118}$$

$$= \frac{\kappa_0}{\kappa_n}\mu_0 + \frac{n}{\kappa_n}\bar{y} \tag{2.119}$$

Que es una media ponderada de μ_0 y $\bar{y}$ dado el número de observaciones previas κ_0 y el tamaño de la muestra n. Aprovecharemos esto al estimar conjuntamente la media y la varianza para el modelo normal. La idea es estimar primero la varianza, y luego suponer que se conoce la varianza σ^2 de forma que se pueda estimar $\tau_0^2 = \sigma^2/\kappa_0$.

Ejercicio

Calcule los primeros cuatro momentos de la distribución normal.

2.6.2. Predicción de la distribución normal con varianza conocida

Para obtener la distribución predictiva posterior, en lugar de hacer una integración compleja, se puede utilizar un truco, $\tilde{Y}$ se distribuye normalmente con media θ y varianza σ^2. Esto equivale a decir

$$\tilde{Y} = \theta + \tilde{\epsilon}$$

Donde $\theta \sim \mathcal{N}(\mu_n, \tau_n^2$, $\tilde{\epsilon} \sim \mathcal{N}(0, \sigma^2)$. Así que sumando estas distribuciones normales se obtiene

$$\tilde{Y} \mid \sigma^2, y_1, \ldots, y_n \sim \mathcal{N}(\mu_n, \tau_n^2 + \sigma^2)$$

Ejercicio

Escriba la ecuación final de la predicción para la distribución normal con media y varianza conocida. Cómo funciona la función marginal para predecir el parámetro θ usando la distribución normal.

Ejercicio

Usando la siguiente `base de datos` genere un programa que determine lo siguiente:

- Distribución prior y likelihood.
- Distribución posterior.
- Distribución predictiva
- Obtenga los valores esperados.
- Grafique las distribuciones.

Ejercicio

Para $X_1, ..., X_n \mid \theta \sim N(\theta, \sigma^2)$ con varianza conocida y $\theta \sim U(-\infty, \infty)$ donde $\theta \sim U(-\infty, \infty)$ significa que $p(\theta) \propto 1$. Calcule la distribución posterior para θ.

2.6.3. Distribución Normal con varianza desconocida

Usando el ejemplo de Hoff (2009) Para la inferencia conjunta, se desea calcular la distribución de probabilidad conjunta de (θ, σ^2) dados los datos, que procede de manera muy similar a la anterior

$$p(\theta, \sigma^2 \mid y_1, \ldots, y_n) = \frac{p(y_1, \ldots, y_n \mid \theta, \sigma^2)p(\theta, \sigma^2)}{p(y_1, \ldots, y_n)} \tag{2.120}$$

Se puede observar que la única diferencia real en este caso de dos parámetros es la a priori conjunta $p(\theta, \sigma^2)$, para la que deberíamos seleccionar una distribución a priori conjugada para simplificar el cálculo posterior.

Si se divide $p(\theta, \sigma^2) = p(\theta \mid \sigma^2)p(\sigma^2)$ entonces, se sabe que la distribución normal es conjugada para $p(\theta \mid \sigma^2)$: $\mathcal{N}(\mu_0, \tau_0^2)$.

$$p(\theta, \sigma^2) = p(\theta \mid \sigma^2)p(\sigma^2) \tag{2.121}$$

$$= \text{dnorm}(\theta, \mu_0, \tau_0) \times p(\sigma^2) \tag{2.122}$$

Dejando que τ_0 dependa de σ^2 esto simplifica los cálculos. Si τ_0 no es proporcional a σ^2, entonces no hay una buena solución de forma cerrada para una distribución posterior, que es una "semiconjugada". En concreto, si dejamos que $\tau_0^2 = \sigma^2/\kappa_0 \implies \tau_0 = \sigma/\sqrt{\kappa_0}$, es decir, τ_0^2 es la varianza de la media de una muestra de tamaño κ_0 de una población con varianza σ^2:

$$p(\theta, \sigma^2) = \text{dnorm}(\theta, \mu_0, \tau_0 = \sigma/\sqrt{\kappa_0}) \times p(\sigma^2) \tag{2.123}$$

Especificando $p(\sigma^2)$. La distribución Gamma (con soporte en $(0, \infty)$) no es conjugada para la varianza normal, pero **es conjugada para la precisión normal** $1/\sigma^2$ cuando σ es desconocido.

Sea $1/\sigma^2 \sim$ Gamma(a, b). Se parametriza esta distribución de tal manera que se pueda interpretar las opciones de los parámetros de la prior, para tener alguna expectativa a priori sobre la precisión en este caso. Por lo tanto:

- $a = \nu_0/2$
- $b = a\sigma_0^2 = \frac{\nu_0}{2}\sigma_0^2$

Donde (σ_0^2, ν_0) son la varianza previa y el tamaño de la muestra previo.

Si $1/\sigma^2 \sim$ Gamma$(\nu_0/2, \sigma_0^2\nu_0/2)$, entonces se obtiene $\mathbb{E}(1/\sigma^2) \neq 1/\mathbb{E}(\sigma^2)$ siempre que la inversa no sea una función lineal. Para calcular $\mathbb{E}(\sigma^2)$ se puede usar la distribución inversa $\sigma^2 \sim$ Inverse-Gamma$(\nu_0/2, \sigma_0^2\nu_0/2)$, donde:

- $\mathbb{E}(\sigma^2) = \frac{\sigma_0^2\nu_0/2}{(\nu_0/2)-1}$
- mode$(\sigma^2) = \frac{\sigma_0^2\nu_0/2}{(\nu_0/2)+1}$
- Var(σ^2) decrece en la medida en que ν_0 se incrementa.

De esto ya se puede intuir cómo ν_0 es un tamaño de muestra, y σ_0^2 es una estimación inicial de la varianza de la muestra donde la expectativa de σ^2 se aproxima más a σ_0^2 a medida que ν_0 aumenta.

Con la distribución previa completamenta especificada, se puede proponer la distribución posterior:

$$1/\sigma^2 \sim \text{Gamma}(\nu_0/2, \sigma_0^2\nu_0/2) \tag{2.124}$$

$$\theta \mid \sigma^2 \sim \mathcal{N}(\mu_0, \sigma^2/\kappa_0), \tag{2.125}$$

En donde el modelo resultado es:

$$Y_1, \ldots, Y_n \mid \theta, \sigma^2 \sim \text{ i.i.d. } \mathcal{N}(\theta, \sigma^2) \tag{2.126}$$

Calculando $p(\theta, \sigma^2 \mid y_1, \ldots, y_n)$ Se puede obtener la probabilidad marginal y condicional:

$$p(\theta, \sigma^2 \mid y_1, \ldots, y_n) = p(\theta \mid \sigma^2, y_1, \ldots, y_n)p(\sigma^2 \mid y_1, \ldots, y_n) \tag{2.127}$$

Sabiendo que el resultado para un parámetro es $p(\theta \mid \sigma^2, y_1, \ldots, y_n)$ se obtiene:

$$\theta \mid \sigma^2, y_1, \ldots y_n \sim \mathcal{N}(\mu_n, \tau_n^2) \tag{2.128}$$

donde la media es:

$$\mu_n = \frac{\frac{1}{\tau_0^2}\mu_0 + \frac{n}{\sigma^2}\bar{y}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}} \tag{2.129}$$

$$= \frac{\frac{\kappa_0}{\sigma^2}\mu_0 + \frac{n}{\sigma^2}\bar{y}}{\frac{\kappa_0}{\sigma^2} + \frac{n}{\sigma^2}} \qquad \text{Sub } \tau_0^2 = \sigma^2/\kappa_0 \tag{2.130}$$

$$= \frac{\kappa_0\mu_0 + n\bar{y}}{\kappa_0 + n} \qquad \sigma^2\text{s cancel} \tag{2.131}$$

$$\tag{2.132}$$

y la varianza

$$\tau_n^2 = \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}} \tag{2.133}$$

$$= \frac{1}{\frac{\kappa_0}{\sigma^2} + \frac{n}{\sigma^2}} \qquad \text{Sub } \tau_0^2 = \sigma^2/\kappa_0 \tag{2.134}$$

$$= \frac{\sigma^2}{\kappa_0 + n}. \tag{2.135}$$

Con los parámetros de la distribución posterior $\kappa_n = \kappa_0 + n$ donde κ_0 es el tamaño de muestra previo y n es la muestra completa, entonces:

$$\theta \mid \sigma^2, y_1, \ldots y_n \sim \mathcal{N}(\mu_n, \sigma^2/\kappa_n) \tag{2.136}$$

Donde μ_n es un promedio ponderado de μ_0 y $\bar{y}$ que depende del tamaño de muestra "prior"κ_0 y de la muestra n, así como σ^2/κ_nes la varianza muestra del muestra media cuando se conoce la varianza σ^2 y el tamaño es κ_n.
Teniendo en cuenta la distribución posterior:

$$p(\theta, \sigma^2 \mid y_1, \ldots, y_n) = p(\theta \mid \sigma^2, y_1, \ldots, y_n)p(\sigma^2 \mid y_1, \ldots, y_n) \tag{2.137}$$

Una vez se calcula el segundo componente σ^2, se tiene el resultado completo para una distribución posterior conjunta.

$$p(\sigma^2 \mid y_1, \ldots, y_n) \propto p(\sigma^2) p(y_1, \ldots, y_n \mid \sigma^2) \tag{2.138}$$

$$= p(\sigma^2) \int p(y_1, \ldots, y_n \mid \theta, \sigma^2) p(\theta \mid \sigma^2) \, d\theta \tag{2.139}$$

$$= \text{Inverse-gamma}(\sigma^2, \nu_0/2, \sigma_0^2 \nu_0/2) \times \tag{2.140}$$

$$\int \left[\left(\prod_{i=1}^{n} p(y_i \mid \theta, \sigma^2) \right) \times N(\theta, \mu_0, \sigma^2/\kappa_0) \right] \, d\theta \tag{2.141}$$

Ejercicio

Realice la integral para obtener el siguiente resultado:

$$\sigma^2 \mid y_1, \ldots, y_n \sim \text{Inverse-Gamma}(\nu_n/2, \sigma_n^2 \nu_n/2) \tag{2.142}$$

$$1/\sigma^2 \mid y_1, \ldots, y_n \sim \text{Gamma}(\nu_n/2, \sigma_n^2 \nu_n/2) \tag{2.143}$$

donde $\nu_n = \nu_0 + n$, como κ_n y $\sigma_n^2 = \frac{1}{\nu_n} \left[\nu_0 \sigma_0^2 + (n-1)s^2 + \frac{\kappa_0 n}{\kappa_n} (\bar{y} - \mu_0)^2 \right]$
ν_n es bastante intuitivo, actúa como un tamaño muestral que es el "tamaño muestral previo tamaño"de la varianza más el tamaño de la muestra n. El σ_n^2 es un poco más difícil de entender. Aquí hay tres términos.

- El primero, $\nu_0 \sigma_0^2$, puede ser pensarse como una suma a priori de observaciones al cuadrado de la media muestral (ν_0 muestras a priori con varianza σ_0^2).
- Del mismo modo, $(n-1)s^2$, donde $s^2 = \sum_{i=1}^{n} (y_i - \bar{y})^2/(n-1)$, es literalmente la suma de las observaciones (realmente observadas) al cuadrado de la muestra.
- Por último, el tercer término aumenta la varianza posterior si la media muestral observada $(\bar{y})$ está lejos de la media a priori esperada μ_0, ya que esto sugeriría una mayor varianza.

Los tres términos de "suma de cuadrados"se combinan y se dividen por el número total de .ºbservaciones"$\nu_n = n + \nu_0$, como se suele hacer para estimar la varianza de una muestra.

Resumen de la inferencia de una distribución posterior:

Esto es mucho para manejar, ya que hay muchas partes móviles. En resumen, para inferencia con el modelo normal, hay que especificar cuatro parámetros a priori:

- σ_0^2,es el parámetro inicial para estimar la varianza
- ν_0, un "tamaño muestral previo.ª partir del cual se observa la estimación inicial de la varianza
- μ_0,parámetro inicial para estimar la media
- κ_0, un "tamaño muestral previo.ª partir del cual se observa la estimación inicial de la **media**

Entonces:

- $1/\sigma^2 \sim$ Gamma$(\nu_0/2, \sigma_0^2\nu_0/2)$
- $\implies \mathbb{E}(\sigma^2) = \sigma_0^2 \frac{\nu_0/2}{\nu_0/2-1}$
- $\theta \mid \sigma^2 \sim \mathcal{N}(\mu_0, \sigma^2/\kappa_0)$
- $\implies \mathbb{E}(\theta) = \mu_0$

Los parámetros que actualizan la información son:

- $\nu_n = \nu_0 + n$
- $\sigma_n^2 = \frac{1}{\nu_n}\left[\nu_0\sigma_0^2 + (n-1)s^2 + \frac{\kappa_0 n}{\kappa_n}(\bar{y}-\mu_0)^2\right]$
- $\mu_n = \frac{\kappa_0\mu_0 + n\bar{y}}{\kappa_n}$
- $\kappa_n = \kappa_0 + n$

Donde la distribución posterior es:

- $1/\sigma^2 \mid y_1, \ldots, y_n \sim$ Gamma$(\nu_n/2, \sigma_n^2\nu_n/2)$
- Donde $\mathbb{E}(\sigma^2 \mid y_1, \ldots, y_n) = \frac{\sigma_n^2\nu_n}{2(\nu_n/2-1)}$
- $\theta \mid \sigma^2, y_1, \ldots, y_n \sim \mathcal{N}(\mu_n, \sigma^2/\kappa_n)$
- donde $\mathbb{E}(\theta \mid y_1, \ldots, y_n, \sigma^2) = \mu_n = \frac{\kappa_0\mu_0 + n\bar{y}}{\kappa_n}$

Observe que los tamaños muestrales previos para la varianza y la media están desacoplados porque se actualizan de forma diferente. Sin embargo, es habitual establecer $\nu_0 = \kappa_0$.

2.6.4. Elección del modelo

Para un bayesiano, la distribución posterior es la base de cualquier inferencia, ya que integra tanto sus opiniones y conocimientos previos como la nueva información proporcionada por los datos. También contiene todo lo que cree sobre la distribución del parámetro desconocido de interés.

Sin embargo, la distribución posterior por sí sola no siempre es suficiente. A veces, la inferencia que queremos expresar es un intervalo creíble, porque indica un rango de valores probables para el parámetro. Esto sería útil si quisiéramos decir que estamos seguros al 95 % de que la probabilidad de un embarazo con RU-486 se encuentra entre un número L y un número U. En otras ocasiones, es necesario hacer una conjetura numérica sobre el valor del parámetro. Por ejemplo, es posible que desee declarar el pago medio de una reclamación al seguro o decirle a un paciente cuánto tiempo le queda de vida.

Una noción central en la elección de modelos bayesianos es el factor de Bayes Marin and Robert (2014) que corresponde al cociente de probabilidades clásico, con la diferencia de que los parámetros se integran en lugar de maximizarse en cada modelo. Aunque esta cantidad es una simple transformación uno a uno de la probabilidad posterior, puede utilizarse para la elección bayesiana de modelos sin recurrir primero a la determinación de los pesos prior de ambos modelos. Obviamente, el factor de Bayes depende de la información prior a través de la elección de los modelos a priori $P(\theta_1)$ y $P(\theta_2)$,

$$\frac{P(\theta_1 \mid Y)}{P(\theta_2 \mid Y)} = \frac{P(Y \mid \theta_1)P(\theta_1)/P(Y)}{P(Y \mid \theta_2)P(\theta_2)/P(Y)} \tag{2.144}$$

$$= \frac{P(Y \mid \theta_1)P(\theta_1)}{P(Y \mid \theta_2)P(\theta_2)} \tag{2.145}$$

$$= \frac{P(Y \mid \theta_1)}{P(Y \mid \theta_2)} \times \frac{P(\theta_1)}{P(\theta_2)} \tag{2.146}$$

Dependiendo del valor del cociente, así mismo se genera la eleacción del modelo en donde si el resultados indica valores pequeños por debajo de 1 el modelo θ_1 tiende a ser más debil que el modelo θ_2 y si este valor se encuentra por encima de 2, el modelo θ_1 es fuertemente decisivo comparado con θ_2.

Aunque esta escala dista mucho de estar justificada por principios estrictos, pro-

porciona una referencia para la evaluación de hipótesis sin necesidad de definir las probabilidades a priori de $H_0 : \theta \in \theta_0$ frente a $H_1 : \theta \in \theta_1$, que es una de las ventajas de utilizar el factor de Bayes. En general, el factor de Bayes depende obviamente de la información previa, pero se propone como una respuesta bayesiana objetiva, ya que elimina en parte la influencia de la modelización previa y hace hincapié en el papel de las observaciones. influencia de la modelización previa y destaca el papel de las observaciones. Alternativamente, puede percibirse como un cociente de probabilidades bayesiano, ya que, si $P(\theta_1)$ y $P(\theta_2)$ son las distribuciones priors para H_0 y H_1 y si $P(\theta \in \Theta_1) = P(\theta \in \Theta_1) = 0{,}5$ entonces el factor de bayes se puede escribir como:

$$BF = \frac{\int_{\Theta_1} f_\theta(y)P(\theta)d\theta}{\int_{\Theta_2} f_\theta(y)P(\theta)d\theta}. \tag{2.147}$$

Que es el cociente marginal para las hipótesis H_0 y H_1.

2.7. Distribuciones Multivariadas

En esta sección se trabajarán las distribuciones multivariadas que son aquellas que buscan medir la relación de diferentes variables de manera conjunta. Primero se abordán las distribuciones disctreas iniciando con la distribución multinomial en la que se estiman diferentes probabilidades para diferentes eventos al mismo tiempo. Para encontrar la distribución posterior se usa la versión prior Dirichtlet que es una versión multivariada de la distribución Beta.

En la segunda parte se aborda la versión multivariada de la distribución normal con y sin varianza conocida. La distribución wishart se introduce para estimar los parámetros de la varianza cuando esta no es conocida.

2.7.1. Distribución Multinomial

La distribución multinomial es una distribución común para caracterizar variables categóricas. Suponiendo que una variable aleatoria Z tiene k categorías, se puede codificar cada categoría como un número entero, lo que lleva a $Z \in \{1, 2, ..., k\}$. Suponiendo que $P(Z = k) = p_k$. El parámetro $\{p_1, ..., p_k\}$ describe toda la distribución de k (con la restricción de que $\sum_j p_j = 1$). Si se generan $Z_1, ..., Z_n$ iid a partir de las distribuciones anteriores Gelman et al. (2014).

$$Y_j = \sum_{i=1}^{n} I(Z_i = j) = \quad numero \quad de \quad observaciones \quad en \quad la \quad categoria \quad j.$$

Entonces un vector aleatorio $Y = (Y_1, ..., Y_k)$ tiene una forma multinomial con parámestros $(n, p_1, ..., p_k)$ se describe:

$$Y \sim M_k(n; p_1, ..., p_k)$$

La distribución Multinomial $M(p_1, ..., p_K, n)$, es una distribución discreta sobre K vectores enteros no negativos que tiene una función de masa definida de la siguiente forma:

$$f(y_1, ..., y_K; p_1, ..., P_K, n) = \frac{\Gamma(n+1)}{\prod_{i=1}^{K} \Gamma(y_i + 1)} \prod_{i=1}^{K} p_i^{y_i} \tag{2.148}$$

La interpretación es sencilla: una extracción y de $M(p_1, ..., p_K; n)$ puede interpretarse como la extracción de n valores iid de una distribución categórica con pmf $f(Y = i) = p_i$. Cada entrada y_i cuenta el número de veces que se ha extraído el valor i. El extraño aspecto de las funciones gamma en la pmf explica la combinatoria de un sorteo; es simplemente el número de formas de colocar n bolas en K contenedores. De hecho, dado que $\Gamma(n+1) = n!$ para n entero no negativo,

$$\frac{\Gamma(n+1)}{\prod_{i=1}^{K} \Gamma(y_i + 1)} = \frac{n!}{y_1!, ..., y_K!} \tag{2.149}$$

2.7.2. Distribución Dirichlet

La distribución Dirichlet es una distribución de probabilidad continua multidimensional utilizada comúnmente en estadística y teoría de probabilidades. Es una generalización de la distribución beta y se utiliza para modelar variables aleatorias que representan proporciones o probabilidades en un espacio multinomial. La distribución Dirichlet $Dir(\theta_1, ..., \theta_K)$ se parametriza con escalares positivos $\theta_i > 0$ para $i = 1, ..., K$ donde $K \leq 2$. La distribución Dirichlet tiene $(K - 1)$ dimensiones $\mathcal{S}_K$ que son los K vectores dimensionales para formar una probabilidad de distribución valida. La densidad de probabilidad de $\Theta = (\theta_1, ..., \theta_K)$ donde $\Theta \in \mathcal{S}_K$ es Gelman et al. (2014):

$$f(\theta_1, ..., \theta_K; \alpha_1, ..., \alpha_K) = \frac{\Gamma(\sum_{i=1}^{K} \alpha_i)}{\prod_{i=1}^{K} \Gamma(\alpha_i)} \prod_{i=1}^{K} \theta_i^{\alpha_i - 1} \tag{2.150}$$

Hay que tener en cuenta algunos aspectos pedagógicos. En primer lugar, la función $f(y)$ se define técnicamente sólo en el espacio $(K-1)$-dimensional y no en K; esto se debe a que $\mathcal{S}_K$ tiene medida cero en K dimensiones. En segundo lugar, el soporte es en realidad open simplex , es decir, todos los $\theta_i > 0$ (lo que implica que ningún $\theta_i = 1$).

2.7.3. Derivación

La distribución Dirichlet se puede derivar a partir de la distribución gamma. Supongamos que tenemos K variables aleatorias independientes $X_1, X_2, \ldots, X_K$, donde cada X_i sigue una distribución gamma con parámetros α_i y β.
La función de densidad de probabilidad de la distribución gamma es:

$$f(\theta_i \mid \alpha_i, \beta) = \frac{\beta^{\alpha_i}}{\Gamma(\alpha_i)} \theta^{\alpha_i - 1} e^{-\beta\theta_i} \tag{2.151}$$

Donde $\Gamma(\alpha_i)$ es la función gamma, que es una generalización del factorial para números reales positivos.

Si tomamos las K variables aleatorias $\theta_1, \theta_2, \ldots, \theta_K$ y las normalizamos, obtenemos las variables aleatorias $X_1, X_2, \ldots, X_K$ dadas por:

$$\theta_i = \frac{X_i}{\sum_{j=1}^{K} X_j} \tag{2.152}$$

La distribución de probabilidad conjunta de estas variables aleatorias normalizadas se puede obtener utilizando la técnica de cambio de variable y se encuentra que sigue una distribución Dirichlet con parámetros $\alpha_1, \alpha_2, \ldots, \alpha_K$:

$$f(y_1, y_2, ..., y_K \mid \alpha_1, \alpha_2, ..., \alpha_K) = \frac{1}{B(\alpha_1, \alpha_2, ..., \alpha_K)} \prod_{i=1}^{K} y_i^{\alpha_i - 1} \tag{2.153}$$

Donde $B(\alpha_1, \alpha_2, \ldots, \alpha_K)$ es la función beta multivariada, que es una constante de normalización dada por:

$$B(\alpha_1, \alpha_2, ..., \alpha_K) = \frac{\prod_{i=1}^{K} \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^{K} \alpha_i)} \tag{2.154}$$

2.7.4. Aproximación mediante la distribución beta

Cuando $K = 2$, la distribución Dirichlet se reduce a la distribución beta. La distribución beta es una distribución de probabilidad continua unidimensional que también se utiliza para modelar proporciones o probabilidades.

La función de densidad de probabilidad de la distribución beta es:

$$f(\theta \mid \alpha, \beta) = \frac{\theta\alpha - 1(1-\theta)^{\beta-1}}{B(\alpha, \beta)} \tag{2.155}$$

Donde $B(\alpha, \beta)$ es la función beta, que es una constante de normalización dada por:

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)} \tag{2.156}$$

La distribución Dirichlet con $K = 2$ puede aproximarse mediante la distribución beta tomando $\alpha_1 = \alpha$ y $\alpha_2 = \beta$. La aproximación es válida cuando el número de observaciones es grande.

2.7.5. Valor Esperado

El valor esperado de la distribución Dirichlet se puede calcular como el promedio ponderado de las variables aleatorias $\theta_1, \theta_2, \ldots, \theta_K$, y se define como:

$$\mathbb{E}[\theta_i] = \frac{\alpha_i}{\sum_{i=1}^{K} \alpha_i} \tag{2.157}$$

Esto significa que el valor esperado de cada θ_i es igual a la proporción del parámetro α_i con respecto a la suma de todos los parámetros α_j.

2.7.6. Varianza

La varianza de la distribución Dirichlet se puede calcular de manera similar a la aproximación de la distribución beta. Para la distribución Dirichlet con $K = 2$, la varianza se puede aproximar mediante la distribución beta y se calcula como:

$$\mathbb{V}\eth\setminus[\theta_i] = \frac{\alpha_i(\sum_{j=1}^{K} \alpha_j - \alpha_i)}{(\sum_{j=1}^{K} \alpha_j)^2(\sum_{j=1}^{K} \alpha_j + 1)} \tag{2.158}$$

La varianza representa la dispersión de las proporciones o probabilidades en el espacio

multinomial. Si todos los parámetros α_i son iguales, entonces la varianza se reduce y todas las variables aleatorias θ_i se vuelven más cercanas al promedio.

Algorithm 7 Dirichlet Distribution

Input: Parameters $\alpha_1, \alpha_2, \ldots, \alpha_K$
Input: Point in the simplex $x_1, x_2, \ldots, x_K$
Output: Probability density $f(x_1, x_2, \ldots, x_K)$
Compute the constant $c = \frac{\Gamma(\sum_{i=1}^{K} \alpha_i)}{\prod_{i=1}^{K} \Gamma(\alpha_i)}$
Compute the density: $f(x_1, x_2, \ldots, x_K) = c \cdot \prod_{i=1}^{K} x_i^{\alpha_i - 1}$
return $f(x_1, x_2, \ldots, x_K)$ *// Output the density*

Algorithm 8 Generate Random Numbers from Dirichlet Distribution

Input: Parameters $\alpha_1, \alpha_2, \ldots, \alpha_K$
Input: Number of samples N
Output: Samples $X_1, X_2, \ldots, X_N$ from Dirichlet distribution
Initialize an array X with dimensions $N \times K$
for $i = 1$ to N **do**
    Generate K random numbers $x_1, x_2, \ldots, x_K$ from gamma distribution with parameters $\alpha_1, \alpha_2, \ldots, \alpha_K$
    Compute the sum $s = x_1 + x_2 + \ldots + x_K$
    Normalize: $y_1 = \frac{x_1}{s}, y_2 = \frac{x_2}{s}, \ldots, y_K = \frac{x_K}{s}$
    Store $y_1, y_2, \ldots, y_K$ in the i-th row of X
end for
return X *// Output the samples*

2.7.7. Dirichlet-Multinomial

Siendo la distribución multinomial una generalización de la binomial y la Dirichlet una generalización de la Beta. Se pueden definir la distribución prior y likelihood para encontrar una distribución posterior que permita estimar el parámetro θ cuando este es multivariado.

$$p_1, ..., p_K \sim Dir(\alpha_1, ..., \alpha_K)$$

$$y_1, ..., y_K \sim M(p_1, ..., p_K)$$

Si la distribución posterior es $f(\theta \mid D) \propto f(\theta, D)$ donde D son los datos.

$$f(\theta \mid D) \propto f(p_1, .., p_K \mid \alpha_1, ..., \alpha_K) \prod_{y_i \in D} f(y_i \mid p_1, ..., p_K) \tag{2.159}$$

$$\propto \prod_{j=1}^{K} p_j^{\alpha_j - 1} \prod_{y_i \in D} \prod_{j=1}^{K} p_j^{y_i^{(j)}} \tag{2.160}$$

$$= \prod_{j=1}^{K} p_j^{\alpha_j - 1 + \sum_{y_i \in D} y_i^{(j)}} \tag{2.161}$$

La densidad the Dirichlet posterior tiene parámetro

$$\alpha_j^* = \alpha_j + \sum_{y_i \in D} y_i^{(j)}$$

Para $f(\theta \mid D) = Dir(\alpha_1^*, ..., \alpha_K^*)$

Distribución posterior predictiva

$$f(y = x \mid D) = \int f(y = x \mid \theta) f(\theta \mid D) d\theta \tag{2.162}$$

$$= \int f(y = x \mid p_1, ..., p_K) f(p_1, ..., p_K \mid D) d\mathcal{S}_K \tag{2.163}$$

$$= \int \frac{\Gamma(n+1)}{\prod_{j=1}^{K} \Gamma(y^{(j)} + 1)} \prod_{j=1}^{K} p_j^{y^{(j)}} \frac{\Gamma(\sum_{j=1}^{K} \alpha_j^*)}{\prod_{j=1}^{K} \Gamma(\alpha_j^*)} \prod_{j=1}^{K} p_j^{\alpha_j - 1} d\mathcal{S}_K \tag{2.164}$$

$$= \frac{\Gamma(n+1)}{\prod_{j=1}^{K} \Gamma(y^{(j)} + 1)} \frac{\Gamma(\sum_{j=1}^{K} \alpha_j^*)}{\prod_{j=1}^{K} \Gamma(\alpha_j^*)} \int \prod_{j=1}^{K} p_j^{y^{(j)} \alpha_j - 1} d\mathcal{S}_K \tag{2.165}$$

$$= \frac{\Gamma(n+1)}{\prod_{j=1}^{K} \Gamma(y^{(j)} + 1)} \frac{\Gamma(\sum_{j=1}^{K} \alpha_j^*)}{\prod_{j=1}^{K} \Gamma(\alpha_j^*)} \frac{\prod_{j=1}^{K} \Gamma(y^{(j)} + \alpha_j)}{\Gamma(n + \sum_{j=1}^{K} \alpha_j^*)} \tag{2.166}$$

En este caso se uso el hecho de que $\Gamma(n+1) = n\Gamma(n)$ para simplificar.

Distribución Marginal

$$f(D) = \int f(\theta \mid \alpha) \prod_{y_i \in D} f(y_i \mid \theta) d\theta \tag{2.167}$$

$$= \int f(p_1, ..., p_K \mid \alpha_1, ..., \alpha_K) \prod_{y_i \in D} f(y_i \mid p_1, ..., p_K) d\mathcal{S}_K \tag{2.168}$$

$$= \int \frac{\Gamma(\sum_{j=1}^K \alpha_j)}{\prod_{j=1}^K \Gamma(\alpha_j)} \prod_{j=1}^K p_j^{\alpha_j - 1} \prod_{y_i \in D} \frac{\Gamma(n+1)}{\prod_{j=1}^K \Gamma(y^{(j)}+1)} \prod_{j=1}^K p_j^{y^{(j)}} d\mathcal{S}_K \tag{2.169}$$

$$= \frac{\Gamma(\sum_{j=1}^K \alpha_j)}{\prod_{j=1}^K \Gamma(\alpha_j)} \Big[\prod_{y_i \in D} \frac{\Gamma(n+1)}{\prod_{j=1}^K \Gamma(y^{(j)}+1)} \Big] \int \prod_{j=1}^K p_j^{\sum_{y_i \in D} y_i^{(j)} \alpha_j - 1} d\mathcal{S}_K \tag{2.170}$$

$$= \frac{\Gamma(\sum_{j=1}^K \alpha_j)}{\prod_{j=1}^K \Gamma(\alpha_j)} \Big[\prod_{y_i \in D} \frac{\Gamma(n+1)}{\prod_{j=1}^K \Gamma(y^{(j)}+1)} \Big] \frac{\prod_{j=1}^K \Gamma(\sum_{y_i \in D} y_i^{(j)} + \alpha_j)}{\Gamma(\mid D \mid n + \sum_{j=1}^K \alpha_j)} \tag{2.171}$$

La distribución categórica $Cat(p_1, ..., p_K)$ es una distribución discreta sonbre $\{1, .., K\}$, con $\imath = (p_1, .., p_K) \in \mathcal{S}_K$ con una probabilidad de masa:

$$f(x = i) = p_i$$

La fuente de confusión con la distribución Multinomial se debe a que a menudo se utiliza la popular codificación 1-de-K para codificar un valor extraído de la distribución Categórica, y en este caso, en realidad podemos ver que la distribución Categórica es sólo una Multinomial con n = 1. En forma escalar, la distribución Categórica es una generalización de la distribución Bernoulli (lanzamiento de una moneda).

Ejercicio

Con la anterior definición calcule la distribución posterior, la predicción y la marginal de una **Dirichlet-Categorical**.

2.7.8. Distribución Normal Multivariada con Varianza Conocida

La distribución normal multivariada es una generalización multidimensional de la distribución normal univariada . Representa la distribución de una variable aleatoria multivariante formada por múltiples variables aleatorias que pueden estar correlacionadas entre sí.

Al igual que la distribución normal, la normal multivariada se define por conjuntos de parámetros: el vector media θ que es el valor esperado de la distribución, y la matriz de covarianza Σ que mide la dependencia de dos variables aleatorias y cómo cambian juntas. La covarianza entre la variable X y Y como $C(X, Y)$. Usando un vector Y,

$$\mathbf{Y}_i = \begin{pmatrix} Y_{i,1} \\ Y_{i,2} \end{pmatrix} \tag{2.172}$$

Con una correlación entre las variables X y Y

$$\begin{aligned} \text{Cor}(X, Y) &= \frac{\text{Cov}(X, Y)}{\text{SD}(X)\text{SD}(Y)} && (2.173) \\ &= \frac{\sigma_{1,2}}{\sigma_1 \sigma_2} && (2.174) \\ &= \frac{\sigma_{1,2}}{\sqrt{\sigma_1^2 \sigma_2^2}} && (2.175) \end{aligned}$$

Se tiene una densidad normal multivariada si

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\theta}, \Sigma) \tag{2.176}$$

Donde

$$\boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_p \end{pmatrix} \tag{2.177}$$

y

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{1,2} & \cdots & \sigma_{1,p} \\ \sigma_{1,2} & \sigma_2^2 & \cdots & \sigma_{2,p} \\ \vdots & \vdots & & \vdots \\ \sigma_{1,p} & \cdots & \cdots & \sigma_p^2 \end{pmatrix} \tag{2.178}$$

Por lo tanto

$$p(\mathbf{y} \mid \boldsymbol{\theta}, \Sigma) = (2\pi)^{-p/2}|\Sigma|^{-1/2}\text{exp}\left(\frac{1}{2} - (\mathbf{y} - \boldsymbol{\theta})^T\Sigma^{-1}(\mathbf{y} - \boldsymbol{\theta})\right) \tag{2.179}$$

2.7.9. Una distribución semiconjugada previa de la media

Una solución completa de forma cerrada para la posterior es difícil de obtener. En su lugar, se pueden calcular priors conjugadas y posteriors para las distribuciones condicionales completas del $\boldsymbol{\theta}$ y Σ de forma separada. Usando el muestreo de Gibbs que se verá más adelante se puede estimar de forma sencilla la distribución posterior conjunta de $\boldsymbol{\theta}$.

La distribución previa en el caso multivariado así como en el univarido es la distribución normal para la media lo que la convierte en una distribución conjugada.
Para la media previa $\boldsymbol{\mu}_0$, y Λ_0 como la matriz de covarianza de $\boldsymbol{\mu}_0$. Entonces $\boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\mu}_0, \Lambda_0)$. Por lo tanto la distribución previa es:

$$\begin{aligned}
p(\boldsymbol{\theta} \mid \Sigma) &\propto \text{exp}\left[-\frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^T\Lambda_0^{-1}(\boldsymbol{\theta} - \boldsymbol{\mu}_0)\right] && (2.180)\\
&= \text{exp}\left[-\frac{1}{2}(\boldsymbol{\theta}^T - \boldsymbol{\mu}_0^T)(\Lambda_0^{-1}\boldsymbol{\theta} - \Lambda_0^{-1}\boldsymbol{\mu}_0)\right] && (2.181)\\
&= \text{exp}\left[-\frac{1}{2}(\boldsymbol{\theta}^T\Lambda_0^{-1}\boldsymbol{\theta} - \boldsymbol{\mu}_0^T\Lambda_0^{-1}\boldsymbol{\theta} - \boldsymbol{\theta}^T\Lambda_0^{-1}\boldsymbol{\mu}_0 + \boldsymbol{\mu}_0^T\Lambda_0^{-1}\boldsymbol{\mu}_0)\right] && (2.182)\\
&= \text{exp}\left[-\frac{1}{2}(\boldsymbol{\theta}^T\Lambda_0^{-1}\boldsymbol{\theta} - 2\boldsymbol{\theta}^T\Lambda_0^{-1}\boldsymbol{\mu}_0 + \boldsymbol{\mu}_0^T\Lambda_0^{-1}\boldsymbol{\mu}_0)\right] && (2.183)\\
&\propto \text{exp}\left[-\frac{1}{2}\boldsymbol{\theta}^T\Lambda_0^{-1}\boldsymbol{\theta} + \boldsymbol{\theta}^T\Lambda_0^{-1}\boldsymbol{\mu}_0\right] && (2.184)
\end{aligned}$$

Si se tiene previamente $\mathbf{A}_0 = \Lambda_0^{-1}$, por ejemplo la matriz de precisión y $\mathbf{b}_0 = \Lambda_0^{-1}\boldsymbol{\mu}_0$,

esto se puede simplificar a

$$p(\boldsymbol{\theta}) = \text{exp}\left(-\frac{1}{2}\boldsymbol{\theta}^T\mathbf{A}_0\boldsymbol{\theta} + \boldsymbol{\theta}^T\mathbf{b}_0\right) \tag{2.185}$$

$$\tag{2.186}$$

Esta simplificación es valida también para la distribución posterior. Implementando esta simplificación se puede observar:

$$p(\boldsymbol{\theta}, \Sigma \mid \mathbf{y}_1, \ldots, \mathbf{y}_n) \propto \text{exp}(-\frac{1}{2}\boldsymbol{\theta}^T\mathbf{A}_1\boldsymbol{\theta} + \boldsymbol{\theta}^T\mathbf{b}_1) \tag{2.187}$$

Donde $\mathbf{A}_1 = n\Sigma^{-1}$ and $\mathbf{b}_1 = n\Sigma^{-1}\bar{\mathbf{y}}$. $\bar{\mathbf{y}}$ es el vector que contiene los promedios de cada una de las variables. Con esta información se puede calcular la distribución posterior.

$$\begin{aligned}
p(\boldsymbol{\theta} \mid \mathbf{y}_1, \ldots, \mathbf{y}_n, \Sigma) &= p(\boldsymbol{\theta} \mid \Sigma)p(\mathbf{y}_1, \ldots, \mathbf{y}_n \mid \boldsymbol{\theta}, \Sigma)/p(\mathbf{y}_1, \ldots, \mathbf{y}_n \mid \Sigma) && (2.188)\\
&\propto p(\boldsymbol{\theta} \mid \Sigma)p(\mathbf{y}_1, \ldots, \mathbf{y}_n \mid \boldsymbol{\theta}, \Sigma) && (2.189)\\
&\propto \text{exp}\left(-\frac{1}{2}\boldsymbol{\theta}^T\mathbf{A}_0\boldsymbol{\theta} + \boldsymbol{\theta}^T\mathbf{b}_0\right) \times \text{exp}(-\frac{1}{2}\boldsymbol{\theta}^T\mathbf{A}_1\boldsymbol{\theta} + \boldsymbol{\theta}^T\mathbf{b}_1) && (2.190)\\
&= \text{exp}\left(-\frac{1}{2}\boldsymbol{\theta}^T\mathbf{A}_n\boldsymbol{\theta} + \boldsymbol{\theta}^T\mathbf{b}_n\right) && (2.191)
\end{aligned}$$

En donde los terminos $\mathbf{A}_n = \mathbf{A}_0 + \mathbf{A}_1 = \Lambda_0^{-1} + n\Sigma^{-1}$ and $\mathbf{b}_n = \mathbf{b}_0 + \mathbf{b}_1 = \Lambda_0^{-1}\boldsymbol{\mu}_0 + n\Sigma^{-1}\bar{\mathbf{y}}$, se simplifican.

Por lo tanto $\boldsymbol{\theta} \mid \Sigma \sim \mathcal{N}(\boldsymbol{\mu}_0, \Lambda_0)$, then $\boldsymbol{\theta} \mid \mathbf{y}_1, \ldots, \mathbf{y}_n, \Sigma \sim \mathcal{N}(\boldsymbol{\mu}_n, \Lambda_n)$ donde los parámetros se definieron anteriormente. Como en el caso univariado el caso multivariado es:

- Cov$(\boldsymbol{\theta} \mid \mathbf{y}_1, \ldots, \mathbf{y}_n, \Sigma) = \Lambda_n = (A_0^{-1} + n\Sigma^{-1})^{-1}$, es una combinación de la prior y la posterior
- $\mathbb{E}(\boldsymbol{\theta} \mid \mathbf{y}_1, \ldots, \mathbf{y}_n, \Sigma) = \boldsymbol{\mu}_n = (A_0^{-1} + n\Sigma^{-1})^{-1}(\Lambda_0^{-1}\boldsymbol{\mu}_0 + n\Sigma^{-1}\bar{\boldsymbol{y}})$, que es el promedio ponderado de una estimación previa de la media y de la muestra de la media.

2.7.10. Distribución Normal Multivariada con Varianza no Conocida

En esta sección se aborda igualmente que en el caso univariado, el evento en el que la varianza no es conocida y que para la distribución multivariada es la matriz de covarianza Σ. Así como en la versión univariada la distribución inverse-gamma, sirvió para calcular una distribución full conditional posterior de la distribución normal, en este caso se usa su versión multivariada que es la distribución Wishart.

2.7.11. Distribución Wishart

La distribución de Wishart es una familia de distribuciones para matrices simétricas definidas positivas. Para una variable independiente $Y_1, ..., Y_n$ que se distribuye $N_p(\mathbf{0}, \Sigma)$ y una matriz $p \times n$ para $\boldsymbol{Y} = [\boldsymbol{Y}_1, ..., \boldsymbol{Y}_n]$. La distribución de $p \times p$ tiene una matriza aleatoria $\boldsymbol{M} = \boldsymbol{Y}\boldsymbol{Y}^{\boldsymbol{T}} = \sum_{i=1}^{n} \boldsymbol{Y}_i \boldsymbol{Y}_i^{\boldsymbol{T}}$ que sigue una distribución Wishart.

Lo anterior implica que la matriz $\boldsymbol{M}_{p\times p} = \sum_{i=1}^{n} \boldsymbol{Y}_i \boldsymbol{Y}_i^{\boldsymbol{T}}$ tiene una distribución Wishart con n grados de libertad y una matriz de covarianza Σ que se denota $\boldsymbol{M} \sim W_p(n, \Sigma)$.

$$f(\boldsymbol{M}) = \frac{1}{2^{np/2}\Gamma_p(\frac{n}{2}) \mid \Sigma \mid^{n/2}} \mid \boldsymbol{M} \mid^{(n-p-1)/2} exp[-\frac{1}{2} trace(\Sigma^{-1}\boldsymbol{M})]$$

Las propiedades de la distribución Wishart son las siguientes:

- Si $\nu_0 > p$ entonces $\boldsymbol{Y}^T\boldsymbol{Y}$ es positiva.
- $\boldsymbol{Y}^T\boldsymbol{Y}$ es simétrica
- $\mathbb{E}(\boldsymbol{Y}^T\boldsymbol{Y}) = \nu_0\Sigma_0$

La forma precisa de la densidad rara vez se utiliza. Dos excepciones son que i) en el cálculo bayesiano, la distribución de Wishart se utiliza a menudo como una prior conjugada para la inversa de la matriz de covarianza normal y que ii) cuando las matrices simétricas definidas positivas son los elementos aleatorios de interés en el estudio del tensor de difusión.

2.7.12. Distribución Wishart Inversa

Por ahora se abordó la distribución previa y posterior para la media. Ahora a la matriz de covarianza Σ necesita una distribución a priori semi-conjugada para la varianza era la distribución Wishart. De forma similar que en el caso univariado, se requiere

una distribución a priori semi conjugada para la matriz de covarianza que es la inversa de Wishart.

La generación de muestras a partir de una distribución Wishart es análoga al muestreo de un conjunto de variables a partir de una distribución normal multivariante y calcular la matriz de covarianza empírica de las muestras. Más concretamente, con los parámetros $\nu_0 \in \mathbb{Z}^+$ y Φ_0 (una matriz de covarianza $\mathbf{\Sigma}_{p\times p}$),

- Se muestrea $z_1, \ldots, z_{\nu_0} \sim \mathcal{N}(\mathbf{0}, \Phi_0)$
- Se calcula $\boldsymbol{Z}^T\boldsymbol{Z} = \sum_{i=1}^{\nu_0} z_i z_i^T$

Por lo tanto $\boldsymbol{Z}_1^T\boldsymbol{Z}_1, \ldots, \boldsymbol{Z}_S^T\boldsymbol{Z} \sim$ Wishart(ν_0, Φ_0).

Como la Gamma no es la prior conjugada de la varianza para la Normal,la Wishart no conjuagada a priori de la varianza para la normal multivariante, sino la inversa de Wishart. El muestreo de una inversa-Wishart sólo implica tomar $\Sigma^{(s)} = (\boldsymbol{Z}^{(s)T}\boldsymbol{Z}^{(s)})^{-1}$

Si se muestrea de una Wishart inversa, se ronembra Φ_0 a $\mathbf{S}_0^{-1}$ tal que

- (en lugar de $\mathbb{E}(\Sigma^{-1}) = \nu_0\mathbf{S}_0^{-1}$)
- $\mathbb{E}(\Sigma) = \frac{1}{\nu_0-p-1}\mathbf{S}_0$ (por lo que no es exactamente la inversa de $\mathbf{S}_0^{-1}$)

Existe un prorblema con la distribución Wishart que es la gran cantidad de parámetros. En este caso se debe especificar toda la matriz de covarianza. Si existe una expectativa a priori de una matriz de covarianza Σ_0, entonces se puede centrar la prior en torno a ella de dos maneras sugeridas:

- Establecer ν_0 grande y $\mathbf{S}_0 = (\nu_0 - p - 1)\Sigma_0$, tal que $\mathbb{E}(\Sigma) = \frac{\nu_0-p-1}{\nu_0-p-1}\Sigma_0 = \Sigma_0$ y (debido al gran ν_0) la prioridad está bastante concentrada alrededor de Σ_0;
- Fijar $\nu_0 = p + 2$ y dejar que $\mathbf{S}_0 = \Sigma_0$, tal que $\mathbb{E}(\Sigma) = \frac{1}{p+2-p-1}\Sigma_0 = \Sigma_0$ pero sólo vagamente centrada alrededor de Σ_0 (debido a ν_0 bastante pequeño)

Para un enfoque de "Bayes empírico", se centra la prior en torno a la matriz de covarianza empírica de la muestra.

2.7.13. Distribución condicional completa (Full Conditional)

Para $\Sigma \mid \boldsymbol{y}_1, \ldots, \boldsymbol{y}_n, \boldsymbol{\theta}$, es importante saber que $\Sigma \sim$ inverse-Wishart$(\nu_0, \mathbf{S}_0^{-1})$,

$$p(\Sigma) \propto |\Sigma|^{-(\nu_0+p+1)/2} \times \exp\left(-\text{tr}(\mathbf{S}_0\Sigma^{-1})/2\right) \tag{2.192}$$

Substituyendo $\mathbf{A}_1$ y $\boldsymbol{b}_1$ la forma simplifiacada es:

$$p(\mathbf{y}_1, \ldots, \mathbf{y}_n \mid \boldsymbol{\theta}, \Sigma) = (2\pi)^{-np/2}|\Sigma|^{-n/2} \exp\left(-\sum_{i=1}^{n}(\boldsymbol{y}_i - \boldsymbol{\theta})^T\Sigma^{-1}(\boldsymbol{y}_i - \boldsymbol{\theta})/2\right) \tag{2.193}$$

Haciendo algunos cálculos matriciales

$$\sum_{i=1}^{n}(\boldsymbol{y}_i - \boldsymbol{\theta})^T\Sigma^{-1}(\boldsymbol{y}_i - \boldsymbol{\theta}) = \text{tr}\left(\left(\sum_{i=1}^{n}(\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^T\right)\Sigma^{-1}\right) \text{tr}\left(\mathbf{S}_\theta\Sigma^{-1}\right) \tag{2.194}$$

Donde $\mathbf{S}_\theta = \sum_{i=1}^{n}(\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^T$ es el residuo de la suma cuadrada de las matrices para los vectores $\boldsymbol{y}_1, \ldots,$ (Para obtener la matriz de suma de cuadrados residual, se calcula la suma de cuadrados de los vectores residuales $\boldsymbol{y}_n$. $\boldsymbol{y}_i - \boldsymbol{\theta}$)
Entonces

$$p(\mathbf{y}_1, \ldots, \mathbf{y}_n \mid \boldsymbol{\theta}, \Sigma) = (2\pi)^{-np/2}|\Sigma|^{-n/2} \exp\left(-\text{tr}(\mathbf{S}_\theta\Sigma^{-1})/2\right) \tag{2.195}$$

Por lo tando la Full conditional distribution para Σ es:

$$\begin{aligned}
p(\Sigma \mid \boldsymbol{y}_1, \ldots, \boldsymbol{y}_n, \boldsymbol{\theta}) &\propto p(\Sigma) \times p(\boldsymbol{y}_1, \ldots, \boldsymbol{y}_n \mid \boldsymbol{\theta}, \Sigma) && (2.196)\\
&\propto \left[|\Sigma|^{-(\nu_0+p+1)/2} \times \exp\left(-\text{tr}(\mathbf{S}_0\Sigma^{-1})/2\right)\right] \times \left[|\Sigma|^{-n/2} \exp\left(-\text{tr}(\mathbf{S}_\theta\Sigma^{-1})/2\right)\right] && (2.197)\\
&= |\Sigma|^{-(\nu_0+n+p+1)/2} \exp\left(-\text{tr}((\mathbf{S}_0 + \mathbf{S}_\theta)\,\Sigma^{-1})/2\right) && (2.198)\\
&\propto \text{dinverse-Wishart}\left(\nu_0 + n, [\mathbf{S}_0 + \mathbf{S}_\theta]^{-1}\right) && (2.199)\\
&= \text{dinverse-Wishart}\left(\nu_n, \mathbf{S}_n^{-1}\right) && (2.200)
\end{aligned}$$

Donde$\nu_n = \nu_0 + n$ y $\mathbf{S}_n = \mathbf{S}_0 + \mathbf{S}_\theta$.

Como en el caso univariado, la distribución condicional de Σ depende de $\nu_0 + n$, una suma del tamaño de la muestra previa y el tamaño de la muestra de datos, $\mathbf{S}_0 + \mathbf{S}_\theta$, la suma de la suma de cuadrados residuales previa y la suma de cuadrados empírica.
Recuerde que las matrices inversas de Wishart implican el muestreo a partir de una distribución normal normal con media $\mathbf{0}$, $\mathbf{S}_0$ pueden tratarse como una covarianza residual, dado que $\mathbb{E}(\boldsymbol{y}_i - \boldsymbol{\theta}) = \mathbf{0}$.
Por último, la expectativa condicional de la matriz de covarianza es una media ponderada de la expectativa previa $\frac{1}{\nu_0 - p - 1}\mathbf{S}_0$ y el estimador insesgado $\frac{1}{n}\mathbf{S}_\theta$:

$$\mathbb{E}(\Sigma \mid \boldsymbol{y}_1, \ldots, \boldsymbol{y}_n, \boldsymbol{\theta}) = \frac{1}{\nu_0 + n - p - 1}(\mathbf{S}_0 + \mathbf{S}_\theta) \tag{2.201}$$

$$= \frac{\nu_0 - p - 1}{\nu_0 + n - p - 1}\frac{1}{\nu_0 - p - 1}\mathbf{S}_0 + \frac{n}{\nu_0 + n - p - 1}\frac{1}{n}\mathbf{S}_\theta. \tag{2.202}$$

Así que el estimador bayesiano es un estimador sesgado, pero sigue siendo demostrablemente consistente a medida que $n \to \infty$.

Ejercicio

Información unitaria previa: Dejando $\Psi = \Sigma^{-1}$, demuestre que la información unitaria previa para $(\boldsymbol{\theta}, \Psi)$ viene dada por $\boldsymbol{\theta} \mid \Psi \sim normal \quad multivariada(\overline{\boldsymbol{y}}, \Psi^{-1})$ y $\Phi \sim Wishart(p+1, \boldsymbol{S}^{-1})$, donde $\boldsymbol{S} = \sum(\boldsymbol{y}_i - \overline{\boldsymbol{y}})(\boldsymbol{y}_i - \overline{\boldsymbol{y}})^T/n$. El siguiente proceso le puede ayudar:

a Reparametrizar el modelo normal multivariante en términos de la matriz de precisión $\Psi = \Sigma^{-1}$. Escriba la log verosimilitud resultante y encuentre una densidad de probabilidad $p_U(\boldsymbol{\theta}, \Psi) = p_U(\boldsymbol{\theta} \mid \Psi)p_U(\Psi)$ tal que $logp(\boldsymbol{\theta}, \Psi) = l(\boldsymbol{\theta}, \Psi \mid Y)/n + c$, donde c no depende de $\boldsymbol{\theta}$ ni de Ψ.Sugerencia: Escriba $(y_i - \boldsymbol{\theta})$ como $(\boldsymbol{y}_i - \overline{\boldsymbol{y}} + \overline{\boldsymbol{y}} - \boldsymbol{\theta})$, y observe que$\sum \boldsymbol{a}_i^T \boldsymbol{B} \boldsymbol{a}_i$puede escribirse como $tr(\boldsymbol{AB})$, donde $\boldsymbol{A} = \boldsymbol{a}_i \boldsymbol{a}_i^T$.

b Sea $p_U(\Sigma)$ la densidad inversa de Wishart inducida por $p_U(\Psi)$. Obtenga una densidad $p_U(\boldsymbol{\theta}, \Sigma \mid y_1, ..., y_n) \propto p_U(\boldsymbol{\theta} \mid \Sigma)p_U(\Sigma)p(y_1, ..., y_n \mid p_U(\boldsymbol{\theta}, \Sigma)$. ¿Puede interpretarse como una distribución posterior para $\boldsymbol{\theta}$ y Σ?

2.7.14. Resumen

Para comprender un poco mejor el proceso de inferencia de un modelo multivariado que se distribuye de manera normal, se debe tener en cuenta:

- $\mathbf{S}_0$ para la inversa de Wishart que se relacionado con la estimación previa de la covarianza entre las variables.
- Sólo relacionada con Θ porque, como se ha mencionado anteriormente, existen algunas directrices sobre qué utilizar para ν_0 y $\mathbf{S}_0$ de forma que la distribución previa se centre en Σ_0 para encontrar la estimación previa de la matriz de covarianza que se busca.
- ν_0 para la inversa de Wishart es un tamaño de muestra previo a partir del cual se observa la estimación inicial de la varianza.
- $\boldsymbol{mu}_0$ para la normal multivariante es una estimación inicial de la media de la población
- Λ_0 para la normal multivariante es la covarianza (es decir, la incertidumbre) de la estimación inicial de la media de la población

Cuadro 2.2: Distribuciones conjugadas en estadística bayesiana

Distribución	**Prior**	**Likelihood**	**Posterior**
Normal	N(μ_0, σ_0^2)	N(μ, σ^2)	N(μ_n, τ_n^2)
Beta	Beta(α_0, β_0)	Binomial(n, θ)	Beta$(\alpha_0 + \sum y_i, \beta_0 + n - \sum y_i)$
Gamma	Gamma(α_0, β_0)	Poisson(λ)	Gamma$(\alpha_0 + \sum y_i, \beta_0 + \lambda)$
Exponencial	Gamma(α_0, β_0)	Exponencial(λ)	Gamma$(\alpha_0 + 1, \beta_0 + \lambda)$
Dirichlet	Dirichlet$(\boldsymbol{\alpha}_0)$	Multinomial$(\mathbf{n}, \boldsymbol{\theta})$	Dirichlet$(\boldsymbol{\alpha}_0 + \sum \mathbf{y_i})$
Normal Multivariada	MVN$(\mu_0, \boldsymbol{\Sigma}_0)$	MVN$(\mu, \boldsymbol{\Sigma})$	MVN$(\mu_n, \boldsymbol{\Sigma}_n)$
Inverse Wishart	IW$(\nu_0, \mathbf{S}_0)$	MVN$(\boldsymbol{\mu}, \boldsymbol{\Sigma})$	IW$(\nu_0 + n, \mathbf{S}_n)$

2.8. Conclusión

El capítulo 2 fue Inferencia Estadística Bayesiana, un paso que se debe abordar antes de iniciar el proceso compuacional. Se abordó de manera general las distribuciones discretas y continuas. De manera transversal se trabajaron las diferentes disribuciones

conjugadas que tienen la misma forma en información previa y en la posterior. La distribución (Likelihood) se usa para tener y el resultado de la unión de las dos. Este segmento se abordó de forma paramétrica, esto quiere decir que la inferencia se realizó sobre parámetros de distribuciones conocidas.

Para pasar a la siguiente sección, usted debe estar en la capacidad de encontrar cualquier distribución posterior. Debe recordar que en este curso se abordaron las más importantes pero en los ejercicios se enunciaron otras que pueden ayudar a resolver problemas de forma paramétrica.

Capítulo 3

Métodos de Simulación

La idea principal es la simulación iterativa. Se generan muestras de valores de una variable aleatoria a partir de una secuencia de distribuciones que convergen hacia una distribución objetivo a medida que continúan las iteraciones. Los valores simulados son generados por una cadena de Markov cuya distribución estacionaria es la distribución objetivo, es decir, la distribución posterior.

Monte Carlo es un término general para las técnicas computacionales que utilizan números aleatorios. Monte Carlo puede utilizarse en estadística clásica y bayesiana. Un tipo especial de Monte Carlo denominado Monte Carlo de Cadenas de Markov (MCMC) fue una de las principales razones del renacimiento de la estadística bayesiana en la segunda mitad del siglo XX. Antes de que MCMC se popularizara, uno de los principales inconvenientes del enfoque bayesiano era que algunos de los cálculos eran demasiado difíciles de realizar. MCMC permite resolver una amplia gama de problemas bayesianos que no pueden resolverse mediante métodos analíticos.

3.1. Transformación de las distribuciones

La importancia de la transformación de funciones y el papel que juega la distribución uniforme en la búsqueda de una distribución son fundamentales en los métodos de Monte Carlo. La transformación de funciones permite mapear variables aleatorias uniformes a otras distribuciones mediante el uso de la función de distribución acumulada (CDF) de la distribución deseada y su inversa. Este proceso es conocido como el método de la transformada inversa.

La distribución uniforme U[0,1] es esencial en estos métodos porque sirve como punto

de partida para generar variables aleatorias de cualquier otra distribución, siempre que se conozca la función de distribución acumulativa inversa de la distribución objetivo. En la práctica, muchos algoritmos de simulación comienzan con números aleatorios generados de manera uniforme y luego los transforman para obtener muestras de la distribución deseada.

3.1.1. Aceptación-Rechazo

Existe una variedad de distribuciones para las cuales el método de la transformada inversa e incluso las transformaciones generales no pueden generar las variables aleatorias requeridas. Para estos casos, debemos recurrir a métodos indirectos; es decir, métodos en los cuales generamos una variable aleatoria candidata y solo la aceptamos si pasa una prueba. Como veremos, esta clase de métodos es extremadamente poderosa y nos permitirá simular prácticamente cualquier distribución.

Algorithm 9 Método de Aceptación-Rechazo

1: Generar $Y \sim g$, $U \sim U[0,1]$
2: Aceptar $X = Y$ si $U \leq \frac{f(Y)}{Mg(Y)}$
3: Regresar a 1 de lo contrario

Estos métodos, conocidos como de Aceptación-Rechazo, solo requieren que conozcamos la forma funcional de la densidad f de interés (llamada densidad objetivo) hasta una constante multiplicativa. Utilizamos una densidad más simple (para simular) g, llamada densidad instrumental o candidata, para generar la variable aleatoria para la cual se realiza la simulación. Las únicas restricciones que imponemos a esta densidad candidata g. Los métodos de Cadena de Markov Monte Carlo (MCMC) utilizan el principio de Aceptación-Rechazo como un componente central para generar muestras que reflejan la distribución deseada. En el algoritmo de Metropolis-Hastings, por ejemplo, este principio se utiliza para decidir si se acepta un nuevo estado en la cadena de Markov o si se permanece en el estado actual. La decisión se basa en una comparación entre la densidad de probabilidad en el nuevo estado propuesto y el estado actual, ajustada por la probabilidad de transición entre estos estados.

El papel de los métodos de Aceptación-Rechazo dentro de los algoritmos MCMC permite garantizar la convergencia al estado estacionario que representa la distribución objetivo. A través de un proceso iterativo de propuestas y aceptaciones o rechazos,

la cadena de Markov construida tiene la propiedad de que, en el límite, las muestras generadas son de la distribución deseada, independientemente de la distribución de la que se originaron las propuestas.

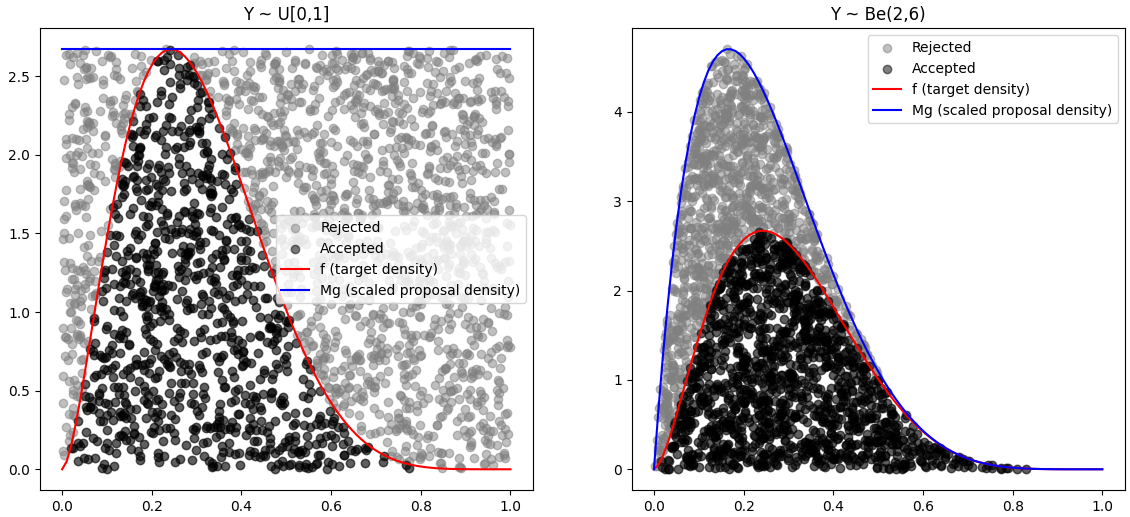

Figura 3.1: Regiones de Aceptación y Rechazo

3.2. Modelos Montecarlo

El método Monte Carlo es una técnica que permite resolver de forma numérica problemas complejos en los que se necesita de un número de iteraciones alto para encontrar una solución. Dos clases principales de problemas numéricos que surgen en la inferencia estadística son los problemas de optimización y los problemas de integración. En efecto, numerosos ejemplos muestran que no siempre es posible calcular analíticamente los estimadores asociados a un paradigma dado (máxima verosimilitud, Bayes, método de los momentos, etc.).

Así pues, sea cual sea el tipo de inferencia estadística, a menudo nos vemos abocados a considerar soluciones numéricas. En efecto, una solución general consiste en utilizar la simulación, ya sea de la distribución real o de una distribución simulada, para calcular las cantidades de interés. En la configuración de la teoría de la decisión, ya sea clásica o bayesiana, esta solución es natural, ya que los riesgos y los estimadores de Bayes implican integrales con respecto a distribuciones de probabilidad.

La posibilidad de producir un número casi infinito de variables aleatorias según una dis-

tribución permite obtener resultados frecuentistas y asintóticos mucho más fácilmente que en los entornos inferenciales habituales, donde el tamaño de la muestra suele ser fijo. Así, se pueden aplicar resultados probabilísticos como la Ley de los Grandes Números o el Teorema del Límite Central, ya que permiten evaluar la convergencia de los métodos de simulación (lo que equivale a los límites deterministas utilizados por los enfoques numéricos).

Antes de entrar en la descripción de las técnicas de Monte Carlo Robert et al. (1999), hay que tener en cuenta que una alternativa aparentemente obvia al uso de métodos de simulación para aproximar integrales de la forma

$$\boldsymbol{E}_f[h(Y)] = \int_Y h(y)f(y)dy \tag{3.1}$$

Esta es una integral genérica en la que se calcula un valor esperado para una variable aleatoria Y. Como el valor esperado es un promedio empírico, la aproximación discreta que se propone a la función de densidad f es:

$$\overline{h}_n = \frac{1}{n}\sum_{j=1}^{n} h(y_j) \tag{3.2}$$

Si $\overline{h}_n$ se aproxima a $\boldsymbol{E}_f[h(Y)]$, se puede decir que converge bajo la ley de los grandes números. Además si $h^2(Y)$ tiene una expectativa finita bajo f, la velocidad de convergencia de $\overline{h}_n$ puede evaluarse ya que la convergencia se produce a una velocidad $O(\sqrt{n})$ la varianza asimptótica de la aproximación es:

$$V\overline{h}_n = \frac{1}{n}\int_Y (h(y) - \boldsymbol{E}_f[h(Y)])^2 f(y)dy \tag{3.3}$$

La ecuación **??** tiene una forma discreta que es:

$$v_n = \frac{1}{n^2}\sum_{i=1}^{n}[h(y_j) - \overline{h}_n]^2 \tag{3.4}$$

Ejercicio

Para un estimador normal Cauchy Bayes, resuelva el ejercicio para $y = 0, 2, 4$

$$\delta(y) = \int_{-\infty}^{\infty} \frac{\theta}{1+\theta^2} e^{-(y-\theta)^2}/2d\theta / \int_{-\infty}^{\infty} \frac{1}{1+\theta^2} e^{-(y-\theta)^2}/2d\theta$$

- Grafique las integrales y use integración Monte Carlo basado en una simulación Cauchy para calcular las integrales.
- Monitoree la convergencia con un error estándar de la estimación. Obtenga tres dígitos de precisión con probabilidad 0.95.
- Repita el ejercicio de la integración Monte Carlo basado en una simulación normal y compare con el ejercicio anterior.

Ejercicio

Dada una muestra de una variable aleatoria Y que sigue una distribución $N(0,1)$ con tamaño n, presente su aproximación usando método Monte Carlo y cree una tabla que presente las posibles probabilidades generadas a partir de una distribución normal con 6 tamaños de muestra diferentes.

Ejercicio

Para la cola de la probabilidad $P(X > 20)$ cuando $Y \sim N(0,1)$. Exprese la probabilidad como una integral y use el cambio de la variable para reescribir la integral como un valor esperado para una distribución $U(0, 1/20)$. Deduzca la aproximación Monte Carlo para $P(X > 20)$ con un nivel de error.

3.3. Cadena de Markov

Una cadena de Markov es un proceso aleatorio con la propiedad de que, condicionado a su valor actual, los valores futuros son independientes del pasado. En determinadas condiciones, una cadena de este tipo convergerá a una distribución estacionaria, de modo que los valores futuros pueden tratarse como una muestra de la distribución estacionaria.

La idea básica de las técnicas MCMC para la estadística bayesiana es:

1. Construir una cadena de Markov que tenga como distribución estacionaria la distribución posterior requerida. A veces se denomina distribución objetivo.
2. A partir de un punto de partida, generar valores secuenciales de la cadena hasta la convergencia (aproximada). (Una de las dificultades del planteamiento es saber cuándo se ha producido).

3. Seguir generando valores a partir de la cadena, que ahora se consideran una muestra de valores de la distribución posterior. (Como la cadena ha convergido, ahora estamos tomando muestras de la distribución estacionaria).

4. Utilice la muestra resultante (de la distribución estacionaria) para estimar las propiedades de la distribución posterior.

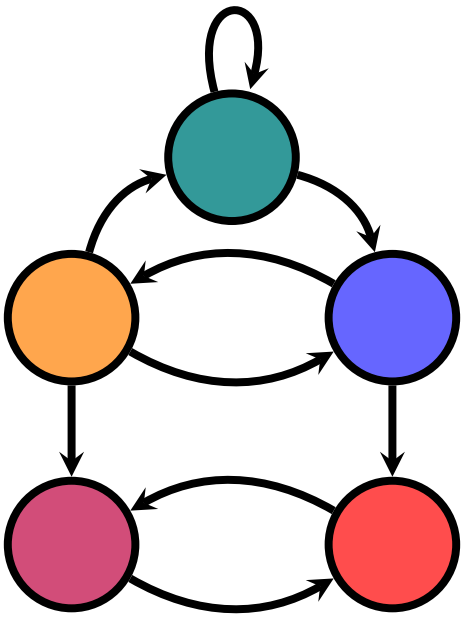

Figura 3.2: Cadena de Markov

3.3.1. Cadenas de Markov

La teoría de las cadenas de Markov proporciona varios resultados sobre la existencia y unicidad de las distribuciones estacionarias. Un resultado específico es que bajo condiciones bastante generales que se satisfacen típicamente en la práctica, si existe una distribución estacionaria f, entonces f es la distribución límite de $\{Y(t)\}$ es f para casi cualquier valor inicial o distribución de $Y(0)$. Esta propiedad se denomina ergodicidad. Desde el punto de vista de la simulación, significa que si un kernel K dado produce una cadena de Markov ergódica con distribución estacionaria f, generar una cadena a partir de este kernel producirá finalmente simulaciones que son aproximadamente de f.

Una cadena de Markov es un proceso estocástico de tiempo discreto $\{Y_0, Y_1, ...\}$ con la propiedad de que la distribución de Y_t dados todos los valores anteriores del proceso solo depende de X_{t-1}. Es decir:

$$P(Y_t \in A \mid Y_0 = y_0, Y_1 = y_1, ..., Y_{t-1} = y_{t-1}) = P(Y_t \in A \mid Y_{t-1} = y_{t-1})$$

Para cualquier conjunto A.

La probabilidad de una transición, o salto, de y_{t-1} en el tiempo $t-1$ a Y_t en el tiempo t viene dada por el kernel de transición. Si Y_t es discreto, el kernel de transición es una matriz de transición con (i, j) elementos.

$$P_{ij} = P(Y_t = j \mid Y_{t-1} = i) \tag{3.5}$$

Esto representa la probabilidad de moverse del estado i al estado j. Para un caso continuo:

$$P(Y_t \in A \mid Y_{t-1} = y_{t-1}) \int_A q(y \mid y_{t-1}) dy \tag{3.6}$$

El kernel de transición es $q(y \mid y_{t-1})$. Es habitual ver el kernel de transición escrito como $q(y_{t-1}, y)$ para indicar la transición de y_{t-1} a y; $q(y_{t-1}, y)$ no representa la densidad conjunta de y_{t-1} y y.

Una cadena de Markov es irreducible si para cada i, j existe un k que:

$$P(Y_{t+k} = j \mid Y_t = i) > 0 \tag{3.7}$$

Esto significa que cada estado se puede alcanzar desde otro estado en un número de movimientos finitos.

Un estado es periódico d_i si al iniciar del estado i la cadena retorna dentro de un número fijo de pasos d_i:

$$d_i = gcd\{t : P(Y_t = i \mid Y_0 = i) > 0\} \tag{3.8}$$

Donde gcd es el mayor común divisor. Una cadena de Markov es irreducible si todos los estados tienen el mismo periodo. Una cadena de Markov no es periódica si uno o todos los estados no son periódicos.

Finalmente, una cadena de Markov converge si esta es irreducible y no es periódica

con una distribución estacionaria.

3.3.2. Algoritmo EM

El algoritmo EM se utiliza para obtener estimaciones de máxima verosimilitud de los parámetros cuando faltan algunos datos. Sin embargo, de forma más general, el algoritmo EM también puede aplicarse cuando hay datos latentes, es decir, no observados, que nunca se pretendió observar en primer lugar. En ese caso, simplemente suponemos que faltan los datos latentes y procedemos a aplicar el algoritmo EM. El algoritmo EM tiene muchas aplicaciones en estadística. Se utiliza a menudo, por ejemplo, en aplicaciones de aprendizaje automático y minería de datos, y en estadística bayesiana, donde suele emplearse para obtener la moda de las distribuciones marginales posteriores de los parámetros.

Una dificultad de la aplicación del algoritmo EM es que cada paso E requiere el cálculo de la log-verosimilitud esperada $Q(\theta \mid \theta_0, \boldsymbol{y})$. Además de casos estándar en los que la función Q está disponible en forma cerrada, ya que Q se expresa de forma natural como una expectativa, puede aproximarse mediante Monte Carlo. Esto significa, por ejemplo, simular $\boldsymbol{Z}_1, ..., \boldsymbol{Z}_T$ a partir de la distribución condicional $k(\boldsymbol{z} \mid \boldsymbol{y}, \hat{\theta}_m)$ y luego maximizar la log-verosimilitud aproximada de los datos completos:

$$\hat{Q}(\theta \mid \theta_0, \boldsymbol{y}) = \frac{1}{T} \sum_{i=1}^{T} \log L^c(\theta \mid \boldsymbol{y}, \boldsymbol{y}_i) \tag{3.9}$$

El algoritmo EM suele enunciarse de forma más general utilizando el lenguaje de la teoría de la información. Como antes, el objetivo es maximizar la función de verosimilitud, $L(\theta; \boldsymbol{Y})$, que viene dada por:

$$L(\theta; Y) = p(Y \mid \theta) = \int_x p(Y, x \mid \theta) dx \tag{3.10}$$

El supuesto implícito en el que se basa el algoritmo EM es que es difícil optimizar $p(Y \mid \theta)$ con respecto a θ, pero que es mucho más fácil optimizar $p(Y, X \mid \theta)$. Primero introducimos una distribución arbitraria, $q(X)$, sobre las variables latentes, X, y observamos que podemos descomponer la log-verosimilitud, $l(\theta; Y)$, en dos términos (el primero de los cuales se denomina a veces término de .energía") según:

$$l(\theta; Y) = p(Y \mid \theta) = \underbrace{\mathcal{L}(q, \theta)}_{\text{energia}} + KLp(q \mid\mid p_{x|y}) \tag{3.11}$$

Paso E: El paso E maximiza el límite inferior, $\mathcal{L}(q, \theta)$, con respecto a $q(.)$ manteniendo θ_{old} fijo. En principio, se trata de un problema variacional, ya que estamos optimizando una función, pero la solución es fácil de encontrar.

Paso M: En el paso M mantenemos $q(X)$ fija y maximizamos $\mathcal{L}(q, \theta)$ sobre θ para obtener θ_{new}. Esto hará que el límite inferior aumente (si no está ya en un máximo), lo que a su vez significa que la log-verosimilitud también debe aumentar. Por otra parte, en este nuevo valor θ_{new}, ya no será el caso de que $KL(q \mid\mid pX \mid Y) = \theta$ y así el aumento de la log-verosimilitud será mayor que el aumento en el límite inferior.

El algoritmo EM también se puede utilizar para calcular la moda de la distribución posterior, $p(\theta \mid Y)$, en un entorno bayesiano en el que se nos da una prior, $p(\theta)$, sobre el parámetro desconocido (vector), θ. Para ver esto, en primer lugar, tenga en cuenta que podemos escribir $p(\theta \mid Y) = p(Y \mid \theta)p(\theta)/p(Y)$ que al tomar logaritmos da como resultado:

$$\ln p(\theta \mid Y) = \ln p(Y \mid \theta) + \ln p(\theta) - \ln p(Y) \tag{3.12}$$

Sustituyendo con 3.11 se tiene que 3.12 es igual a:

$$\ln p(\theta \mid Y) = \underbrace{\mathcal{L}(q, \theta)}_{\text{energia}} + KLp(q \mid\mid p_{x|y}) + \ln p(\theta) - \ln p(Y) \tag{3.13}$$

Ahora se puede encontrar la moda posterior de $\ln p(\theta \mid Y)$ utilizando una versión del algoritmo EM. El paso E es exactamente el mismo que antes, ya que los dos últimos términos del lado derecho de 3.13 no dependen de $q(.)$. Sin embargo, el paso M, en el que mantiene $q(.)$ fija se optimiza sobre θ, debe modificarse para incluir el término $\ln p(\theta)$.

Ejemplo

Solución problema de genética.

Ejercicio

Diseñe un EM para el ejemplo de clase.

Ejercicio

Genere el siguiente algoritmo de una beta-binomial:

Algorithm 10 EM algorithm for the beta-binomial distribution

Require: Observed data $\mathbf{x} = (x_1, x_2, \ldots, x_n)$, number of trials n, and batch size m
Ensure: Maximum likelihood estimates of the parameters α, β, and p
Initialize the parameters α, β, and p
repeat
E-step: Compute the expected value of the missing data z_i given the observed data x_i and the current parameter estimates:

$$\mathbb{E}(z_i) = \frac{m}{n} \sum_{j=1}^{n} \frac{x_j}{m} \frac{B(\alpha + z_j, \beta + m - z_j)}{B(\alpha, \beta)}$$

where $B(\cdot, \cdot)$ is the beta function.
M-step: Maximize the expected log-likelihood with respect to the parameters α, β, and p:

$$\alpha^{(t+1)}, \beta^{(t+1)} = \arg\max_{\alpha,\beta} \sum_{i=1}^{n} \mathbb{E}(\log p(x_i, z_i; \alpha, \beta))$$
$$p^{(t+1)} = \arg\max_{p} \sum_{i=1}^{n} \mathbb{E}(\log p(x_i, z_i; p))$$

where t is the current iteration.
until convergence

3.3.3. Importance Sampling

Aunque los métodos computacionales pueden ayudar a resolver elementos analíticos, algunas veces estos no son eficientes y se deben implementar otras técnicas como el ïmportance sampling"que son distribuciones instrumentales usadas para representar las distribuciones originales. Este se basa en la representación de 3.1. Usando una densidad arbitraria g que es estrictamente positiva $h \times f$, se puede re escribir 3.1:

$$\boldsymbol{E}_f[h(Y)] = \int_Y h(y) \frac{f(y)}{g(y)} g(y) dy = \boldsymbol{E}_g\Big[\frac{h(Y)f(Y)}{g(Y)}\Big] \tag{3.14}$$

Esta función es un cambio arbitrario de la meddia y se puede transformar en la siguiente función:

$$\frac{1}{n}\sum_{j=1}^{n}\frac{f(Y_j)}{g(Y_j)}h(Y_j) \to \boldsymbol{E}_f[h(Y)] \tag{3.15}$$

Para una muestra $Y_1, ..., Y_n$ generada de g. Los estimadores de esta muestra convergen hacia los estimadores poblacionales en la misma medida en queel estimador $\overline{h}_n$ converge sin importar la elección de la muestra para g.

Ejercicio

Suponga que usted está interesado en hallar la probabilidad de un evento extremo $P(Y > 4{,}5)$ de una función f para $Y \sim N(0,1)$ con $\boldsymbol{E}_f[I_{Y>4{,}5}]$. Si g tiene una densidad exponencial $Exp(\lambda)$ truncada en 4.5, encuentre el ïmportance sampling", su respectiva varianza y examine la convergencia del estimador λ con 10, 40 y 100 simulaciones.

3.3.4. Importance sampling y resampling

La técnica de muestreo de importancia hace algo más que aproximar integrales, ya que proporciona una forma alternativa de simular a partir de distribuciones complejas. Una muestra $Y_1, ..., Y_n$ simulada desde g se puede reciclar con un remuestreo multinomial en una muestra parecida a f.

El proceso de remuestro se realiza con una ponderación de la población escogiendo Y_i de $\{Y_1, ..., Y_n\}$ con una probabilidad de $f(X_i)/ng(X_i)$ el resultado es:

$$P(Y^* \in A) = \sum_{i=1}^{n} P(Y^* \in A \quad y \quad Y^* = X_i) \tag{3.16}$$

$$= \int_A \frac{f(y)}{g(y)} g(y)dy = \int_A f(y)dy. \tag{3.17}$$

Siendo f el mismo valor, sin embargo la probabilidad se debe normalizar para que de exactamente 1.

$$\omega_i = \frac{1}{n}\{f(Y_i/g(Y_i))\}/\frac{1}{n}\sum_{j=1}^{n}\{f(Y_j)/g(Y_j)\} \tag{3.18}$$

Estas ponderaciones ayudan a obtener los estimadores insesggados y dependen de la función que se esté utilizando para obtener las variables que se desean usar en el

proceso de muestreo.

Dentro del proceso de muestro y remuestreo se encuentra uno en el que se debe elegir una función para lograr el proceso, a esa función se le llama **importance function** y ayuda a reducir la varianza. Esto permite obtener unos estimadores mas aproximados a los parámetros poblacionales. Uno de los problemas del muestreo es la representación de la importance function, que debería ser muy parecida a la distribución posterior conjunta. La versatilidad de la técnica de muestreo de importancia es alta, pero el inconveniente de esta versatilidad es que una mala elección de la función de importancia g puede producir resultados muy pobres. No obstante este planteamiento es teórico por lo tanto son los pesos los que ayudan a determinar el mejor estimador dependiendo del comportamiento de la varianza.

La convergencia puede ocurrir en la medida en que la varianza sea finita y esto ocurre cuando la espernaza es:

$$\boldsymbol{E}_g\Big[h^2(Y)\frac{f^2(Y)}{g^2(Y)}\Big] = \boldsymbol{E}_f\Big[h^2(Y)\frac{f(Y)}{g(Y)}\Big] = \int_Y h^2(y)\frac{f^2(y)}{g(y)}dy < \infty$$

Ejercicio

Genere un gráfico en el que se pueda ver los saltos en el promedio acumulado para una distribución normal estándar con una función Cauchy $C(0,1)$ como objetivo f donde $f(y)/g(y) \propto exp(y^2/2)/(1+y^2)$, analice el efecto de los saltos, cuando estos son altos o bajos y su relación con la varianza y las variables.

Ejemplo

Aproximación del muestreo.

Ejercicio

Aplique el siguiente algortimo en el ejemplo de clase.

Ejemplo

Aproximación al factor de bayes.

Algorithm 11 Important Sampling

```
for i = 1, 2, ..., N do
    Simulate y_i ~ γ(y)
    Compute ω_i = g̃(y_i)/γ(y_i)
end for
Take Θ̃_N = Σ_{i=1}^N ω_i h(y_i) / Σ_{i=1}^N
to approximate Θ
```

3.3.5. Movimiento Browniano

El movimiento Browniano es un proceso estocástico $W_t \sim N(0,t)$ quw se distribuye con media cero y varianza t. Eso significa que la estandarización del model es $Z = \frac{W(t)-0}{\sqrt{t}}$.

Algorithm 12 Brownian Motion

```
Initialize position x at time t = 0
for t = 1, 2, ..., T do
    Draw a random number from a normal distribution with mean 0 and standard deviation √t
    Set x ← x + √t Z
end for
```

3.3.6. Movimiento Geométrico Browniano

El incremento geométrico de una variable temporal es igual:

$$S(t) = S(0)e^{X(t)} \tag{3.19}$$

Donde la integral estocástica se define como:

$$S(t) = S(0)exp\left\{ \int_0^t \sigma(s)dW(s) + \int_0^t (\mu(s) - \frac{1}{2}\sigma^2(s))ds \right\} \tag{3.20}$$

Algorithm 13 Geometric Brownian Motion

```
Initialize position x at time t = 0
for t = 1, 2, ..., T do
    Draw a random number from a normal distribution with geometric mean μ − σ²/2 and standard deviation σ
    Set x ← x · exp((μ − σ²/2) · t + σ · √t Z)
end for
```

3.4. Muestreo de Gibbs

El objetivo del muestreo de Gibbs es hacer que el muestreo de una distribución de alta dimensión sea más manejable mediante el muestreo de una colección de distribuciones de menor dimensión.

Un punto importante es que el muestreo de Gibbs no es un modelo bayesiano. Estos dos conceptos deben separarse: El muestreo de Gibbs es un marco general para **observar** la distribución de probabilidad posterior, sea cual sea esa distribución.

Por lo tanto, el muestreo de Gibbs es un esquema MCMC en el que el kernel de transición está formado por las distribuciones condicionales completas. Suponga que la distribución de interés es $\pi(\theta)$ donde $\theta = (\theta_1, ..., \theta_d)$. En este caso se busca:

- Por lo general se busca $\pi(\theta) = f(\theta \mid y)$.
- La forma de θ puede ser un escalar, un vector o una matriz.

3.4.1. Dos pasos muestreo de Gibbs

El muestreo de Gibbs en dos etapas crea una cadena de Markov a partir de una distribución conjunta de la siguiente manera. Si dos variables aleatorias θ e Y tienen una densidad conjunta $f(\theta, y)$, con las correspondientes densidades condicionales $f_y \mid \theta$ y $f_\theta \mid Y$, el muestreo de Gibbs en dos etapas Gibbs genera una cadena de Markov (θ_t, Y_t).

Algorithm 14 Gibbs Sampling (Two Stages)

```
Initialize current states θ_0 and y_0
for t = 1, 2, ..., T do
    Sample Y_t from the distribution p(y | θ_{t-1})
    Sample θ_t from the distribution p(θ | y_t)
end for
```

Ejemplo

Considere una distribución normal bivariada con variables Y y X:

$$(X, Y) \sim N_2\Big(0, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}\Big) \tag{3.21}$$

Usando el muestro de Gibbs, se puede generar x_t usando la relación que hay entre las dos variables aleatorias.

$$Y_{t+1} \mid x_t =\sim N(\rho x_t, 1-\rho^2) \tag{3.22}$$
$$X_{t+1} \mid y_{t+1} =\sim N(\rho y_{t+1}, 1-\rho^2 \tag{3.23}$$

Donde la subcadena $(X_t)_t$ es:

$$X_{t+1} \mid X_t = x_t \sim N(\rho^2 x_t, 1-\rho^4) \tag{3.24}$$

Con una recursión:

$$X_t \mid X_0 = x_0 \sim N(\rho^{2t} x_0, 1-\rho^{4t}) \tag{3.25}$$

Que converge a $N(0,1)$ en la medida en que t tiende a infinito.

Ejercicio

Use el algoritmo de dos pasos de Gibbs para representar el anterior ejemplo. Grafique los resultados para X y Y.

Ejemplo

Considere las siguientes distribuciones:

$$Y \mid \theta \sim Binom(n, \theta), \quad \theta \sim Beta(a, b) \tag{3.26}$$

Con la siguiente distribución conjunta:

$$f(y, \theta) = \binom{n}{y} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{y+a-1}(1-\theta)^{n-y+b-1} \tag{3.27}$$

El muestreo de Gibbs arroja el siguiente resultado:

Algorithm 15 Gibbs Sampling (Two Stages)

```
Nsim=10000
n=15
a=3
b=7
Y = T = matrix(0, Nsim × 1)
T[1] = Beta(1, a, b)
Y[1] = Binom(1, n, T[1])
for in  in  2 : Nsim do
    Y[i] = Binom(1, n, T[i − 1])
    T[i] = Beta(1, a + Y[i], n − Y[i] + b)
end for
```

Ejercicio

Genere un ejemplo para la distribución poisson gamma y grafique los resultados para θ y Y.

Ejercicio

Considere la siguiente distribucuón posterior con parámetros (θ, σ^2) con el siguiente modelo conjunto:

$$Y_i \sim N(\theta, \sigma^2), \quad i = 1, ..., n \tag{3.28}$$

$$\theta \sim N(\theta_0, \tau^2), \quad \sigma^2 \sim IG(a, b) \tag{3.29}$$

Donde $IG(a, b)$ es la distribución gamma inversa con una densidad $b^a(1/y)^{a+1}e^{-b/y}/\Gamma(a)$ y con θ_0, τ^2, a, b como parámetros para calcular θ.Realice los siguientes pasos:

- Escriba la distribución posterior sobre (θ, σ^2).
- Obtenga la full conditional de θ y σ^2
- Escriba los parámetros de la distribución posterior para hallar θ y σ^2.
- Genere el Gibbs sampling de los parámetros de la distribución normal.

¿Por qué las densidades posteriores son difíciles de calcular para priores no conjugados utilizando regla de Bayes?

$$p(\boldsymbol{\theta} \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \theta)p(\boldsymbol{\theta})}{\int p(\mathbf{y} \mid \boldsymbol{\theta}')p(\boldsymbol{\theta}')\, d\boldsymbol{\theta}'} \tag{3.30}$$

El numerador suele ser fácil de calcular, pero el denominador suele ser prohibitivamente difícil de calcular. difícil de calcular. Cuando no se sabe que el numerador es proporcional a una distribución de probabilidad conocida, no podemos obtener toda la conjunta sin el denominador.

Nótese, sin embargo, que todavía podemos evaluar las probabilidades relativas de $\boldsymbol{\theta}_a$ y $\boldsymbol{\theta}_b$, ya que su relación anula la la integral. De forma más general, podemos crear una aproximación discreta de las evaluando el numerador de esta densidad para valores de $\boldsymbol{\theta}$ a través de una cuadrícula n-dimensional, a continuación, dividiendo cada uno de estas densidades no normalizadas por la suma de toda la cuadrícula.

De nuevo, para proceder con el muestreo de Gibbs, sólo tenemos que calcular las distribuciones condicionales completas de los parámetros. las distribuciones condicionales completas de los parámetros. Ya hemos calculado la condicional completa para $\theta \mid \sigma^2, y_1, \ldots, y_n$ en 5.2. Para $\theta\mathcal{N}(\mu_0, \tau_0^2)$, entonces $\theta \mid \sigma^2, y_1, \ldots, y_n \sim \mathcal{N}(\mu_n, \tau_n^2)$, donde μ_n y τ_n^2.

Ahora se puede estimar la full conditional σ^2

$$p(\sigma^2 \mid \theta, y_1, \ldots, y_n) \propto \left[(\sigma^2)^{-n/2}\text{exp}\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\theta)^2\right)\right] \times \left[(\sigma^2)^{-\nu_0/2-1}\text{exp}\left(-\frac{\sigma_0^2\nu_0/2}{\sigma^2}\right)\right] \tag{3.31}$$

$$\propto (\sigma^2)^{-(\nu_0+1)/2-1} \times \text{exp}\left(-\frac{1}{\sigma^2} \times \frac{1}{2}\left(\sigma_0^2\nu_0 + \sum_{i=1}^{n}(y_i-\theta)^2\right)\right) \tag{3.32}$$

Entonces $\sigma^2 \sim$ inverse-gamma$(\nu_n/2, \nu_n\sigma_n^2(\theta)/2)$, and $\tilde{\sigma^2} \sim$ gamma$(\cdot,\cdot))$, con los parámetros:

- $\nu_n = \nu_0 + n$
- $\sigma_n^2(\theta) = (\sigma_0^n\nu_0 + ns_n^2(\theta))/\nu_n$

Se puede ver $\sigma_n^2(\theta)$, $s_n^2(\theta)$ para indicar que σ_n^2 es dependiente de θ que se asume conocido.

Un atajo para pensar en condicionales completos, en lugar de descomponer explícitamente descomponer la probabilidad de acuerdo con la regla de Bayes cada vez, es escribir el numerador de la posterior conjunta completa $p(\boldsymbol{\theta} \mid \mathbf{y})$.

Entonces, si está interesado en la condicional completa de $p(\theta_i \mid \mathbf{y})$, simplemente evalúe la posterior conjunta completa mientras trata todos los θ_j para $j \neq i$ como constantes (y por tanto descartables para mantener la proporcionalidad).

Ejercicio

Genera un modelo de Gibbs para la full conditional posterior de Beta. Puede usar una base de datos de Casas de Boston, seleccione la variable que más se acomode al ejercicio, argumente su respuesta y obtenga la simulación de la distribución posterior. Grafique los resutlado, el algoritmo no puede ser ejectuado por ningún paquete o libreria.

3.5. Metropolitan y Metropolitan Hastings

El algoritmo Metrópolis-Hastings genera variables correlacionadas a partir de una cadena de Markov. Con ayuda de las propiedades de convergencia de las cadenas de Markov tienen diferentes propiedades de convergencia se pueden proporcionar propuestas más sencillas en casos en los que el muestreo de importancia genérico no se aplica fácilmente. Por un lado, los requisitos sobre el objetivo f son bastante mínimos, lo que permite entornos en los que se sabe muy poco sobre f. Otra razón, es que esta perspectiva de Markov conduce a descomposiciones eficientes de problemas de alta dimensión en una secuencia de problemas más pequeños que son mucho más fáciles de resolver.

Suponga que el objetivo es extraer muestras de una distribución $f(\theta \mid y) = cg(\theta)$, donde c es la constante de normalización, que puede ser desconocida o muy difícil de calcular. El algoritmo Metrópolis-Hastings proporciona una forma de muestreo de $f(\theta \mid y)$ sin necesidad de conocer c.

Sea $q(\psi \mid \theta)$ un kernel de transición arbitrario: es decir, la probabilidad de pasar, o saltar, del estado actual θ al nuevo estado propuesto ψ. A veces se denomina **proposal distribution**. El siguiente algoritmo generará una secuencia de valores $\theta^1, \theta^2, \ldots$ que forman una cadena de Markov con una distribución estacionaria dada por $f(\theta \mid y)$.

Algorithm 16 Metropolis-Hastings Algorithm

Input: Proposal distribution $q(\theta^* \mid \theta^{t-1})$ and target distribution $p(\theta)$
for $t = 1$ to T **do**
  Sample θ^* from $q(\theta^* \mid \theta^{t-1})$, Proposal distribution.
  Calculate the **acceptance probability**

$$\alpha(\theta^{t-1}, \theta^*) = min\Big(1, \frac{f(\theta* \mid y)q(\theta^{(t-1)} \mid \theta^*)}{f(\theta^{(t-1)} \mid y)q(\theta^* \mid \theta^{(t-1)})}\Big) \tag{3.33}$$

  Sample $u \sim$ Uniform$(0, 1)$
  if $u \leq \alpha(\theta^{(t-1),\theta^*})$ **then**
    accept the proposal and set $\theta^{(t)} = \theta^*$.
  else
    Otherwhise, **reject the proposal** and set $\theta^{(t)} = \theta^{t-1}$
  end if
end for
Output: $\{\theta_t\}$

La distribución q se denomina distribución instrumental (o propuesta o candidata) y la probabilidad $\rho(x, y)$ es la probabilidad de aceptación de Metropolis-Hastings. Hay que distinguirla de la tasa de aceptación, que es la media de la probabilidad de aceptación a lo largo de las iteraciones,

$$\overline{\rho} = \lim_{T\to\infty} \frac{1}{T} \sum_{t=0}^{T} \rho(\theta^t, Y_t) = \int \rho(\theta, y) f(\theta) q(y \mid \theta) dy d\theta \tag{3.34}$$

Con este promedio se puede evaular la eficiencia del algoritmo.

Ejercicio

Genere un algoritmo para simular la distribución beta donde la densidad objetivo f es $Beta(2{,}7, 6{,}3)$ y la función candidata q es uniforme sobre $[0, 1]$. Grafique el resultado para 10000 simulaciones. Genere el etst de Kolmogorov para evaluar la simulación con respecto a una distribución Beta.

En el caso simétrico (es decir, cuando $q(\theta|y) = q(y|\theta)$), la probabilidad de aceptación $\rho(\theta_t, y_t)$ viene determinada por la relación objetivo $f(y_t)/f(\theta^{(t)})$ y, por tanto, incluso la probabilidad de aceptación es independiente de q. Los algoritmos siempre aceptan valores de y_t tales que la relación $f(y_t)/q(y_t \mid \theta^{(t)})$ aumenta con el valor .ªnterior"$f(\theta^{(t)})/q(\theta^{(t)} \mid y_t)$.

Ejercicio

Sunponga que se quiere una muestra $\theta \mid\sim N(0,1)$, use el Metropolis Hastings con la distribución candidata $q(\phi \mid \theta)$ con una densidad $N(\theta, \sigma^2)$ para cualquier σ^2. Grafiquela función de densidad para θ y la convergencia hacia cero. Genere una tabla con las iteraciones que aceptan o rechazan el valor de θ

3.5.1. Algoritmo Metropolitan Hastings Independiente

El algoritmo Metropolis-Hastings permite una distribución candidata q que sólo depende del estado actual de la cadena. Si se necesita que el candidato q sea independiente de este estado actual de la cadena (es decir, $q(y|\theta) = g(y)$), es un caso especial del algoritmo original:

Algorithm 17 Independent Metropolis–Hastings

```
Initialize current state x_0
for t = 1, 2, ..., T do
    Propose a new state θ from proposal distribution q(θ* | θ_{t-1})
    Calculate the acceptance ratio α = p(θ*)/p(θ_{t-1}) · q(θ_{t-1}|θ*)/q(θ*|θ_{t-1})
    Draw a random number u from the uniform distribution on the interval [0, 1]
    if u ≤ α then
        Set θ_t ← θ*
    else
        Set θ_t ← θ_{t-1}
    end if
end for
```

Este método aparece entonces como una generalización directa del método Accept-Reject en el sentido de que la distribución instrumental es la misma densidad g que en el método Accept-Reject. Así, los valores propuestos Y_t son los mismos, si no los aceptados.

Los algoritmos Metrópolis-Hastings y los métodos Accept-Reject, al ser ambos métodos de simulación genéricos, tienen similitudes entre sí que permiten la comparación, aunque es bastante raro plantearse utilizar una solución Metrópolis-Hastings cuando se dispone de un algoritmo Accept-Reject.

- La muestra Accept-Reject es iid, mientras que la muestra Metropolis-Hastings no lo es. Aunque los θ_t se generan independientemente, la muestra resultante

no es iid, aunque sólo sea porque la probabilidad de aceptación de θ_t depende de $X^{(t)}$ (excepto en el caso trivial en que $f = g$).

- La muestra de Metrópolis-Hastings implicará repeticiones del mismo valor, ya que el rechazo de Yt conduce a la repetición de $X^{(t)}$ en el tiempo $t + 1$. Esto tendrá un impacto en pruebas como la de la probabilidad de θ_t. Esto tendrá un impacto en pruebas como ks.test que no aceptan empates.
- El paso de aceptación Aceptar-Rechazar requiere el cálculo de la cota superior $M \geq sup_x f(x)/g(x)$, que no requiere el algoritmo Metrópolis-Hastings. Esta es una característica atractiva de Metropolis-Hastings si calcular M lleva mucho tiempo o si la M existente es imprecisa y, por tanto, induce un desperdicio de simulaciones.

3.5.2. Algoritmo Metropolitan Hastings Aleatoria

Un enfoque más natural para la construcción práctica de una propuesta Metrópolis-Hastings es, por tanto, tener en cuenta el valor simulado previamente para generar el valor siguiente; es decir, considerar una exploración local de la vecindad del valor actual de la cadena de Markov.

Suponga que una caminata aleatoria se define como:

$$\theta_t = Y^t + \epsilon_t \tag{3.35}$$

En general, si $q(\theta, y) = q(y, \theta)$ es una densidad simétrica, la función de aceptación se simplifica a

$$a(\theta, y) = min\Big\{1, \frac{\pi(\theta)}{\pi(y)}\Big\} \tag{3.36}$$

Esta es la forma original del algoritmo de Metropolis (1953). La definición habitual de paseo aleatorio para $q(\theta, y)$ en R^d supone $q(\theta, y) = q(y - \theta)$, o equivalentemente que la variable aleatoria propuesta Y satisface

$$\{\theta \mid Y = y\} \equiv y + \epsilon \tag{3.37}$$

Como se ha indicado anteriormente, la probabilidad de aceptación no depende de g. Esto significa que, para un par dado $(y(t), \theta_t)$, la probabilidad de aceptación es la

Algorithm 18 Random Walk Metropolis-Hastings

```
Initialize starting point y_0
for i = 1 to N do
    Generate a proposal y from a symmetric proposal distribution
    Compute the acceptance ratio α = mín(1, p(θ)/p(y_{i-1}))
    Generate a random number u from a uniform distribution U(0,1)
    if u ≤ α then
        Set y_i = θ
    else
        Set y_i = y_{i-1}
    end if
end for
    return Samples {y_1, y_2, ..., y_N}
```

misma si yt se genera a partir de una distribución normal o de una distribución Cauchy. Obviamente, el cambio de g dará lugar a diferentes rangos de valores para los Y_t y una tasa de aceptación diferente, por lo que esto no quiere decir que la elección de g no tiene ningún impacto en el comportamiento del algoritmo, pero esta invariabilidad de la probabilidad de aceptación es digna de mención. En realidad, está vinculada al hecho de que, para cualquier densidad (simétrica) g, la medida invariante asociada al paseo aleatorio es la medida de Lebesgue en el espacio correspondiente.

3.6. Hamiltoniano Monte Carlo (HMC)

3.6.1. Introducción a Métodos Monte Carlo

- Los métodos Monte Carlo se utilizan para integración numérica y muestreo probabilístico.
- Idea central: Estimar las propiedades de una distribución examinando muestras aleatorias de la distribución.
- Los métodos MCMC extienden esta idea para muestrear de distribuciones que no se pueden muestrear directamente.

3.6.2. Motivación para Hamiltoniano Monte Carlo

- Los métodos clásicos de MCMC (e.g., Random Walk Metropolis-Hastings) pueden ser ineficientes, especialmente en espacios de alta dimensión.
- Problemas incluyen:
  - Comportamiento de caminata aleatoria: exploración ineficiente del espacio.
  - Alta autocorrelación: más muestras necesarias para información independiente.
- Solución: Hamiltoniano Monte Carlo (HMC), que utiliza gradientes para proponer nuevos estados, permitiendo una exploración más eficiente.

3.6.3. Dinámica Hamiltoniana

- La dinámica hamiltoniana describe la evolución de un sistema en mecánica clásica.
- El estado de un sistema se representa por posición q y momento p.
- El Hamiltoniano $H(q, p)$ es la suma de la energía potencial $U(q)$ y la energía cinética $K(p)$.
- Las ecuaciones de Hamilton son:

$$\dot{q} = \frac{\partial H}{\partial p}$$
$$\dot{p} = -\frac{\partial H}{\partial q}$$

3.6.4. Del Física a la Estadística: El Método Leapfrog

- HMC utiliza la dinámica hamiltoniana para explorar la distribución objetivo.
- Integración leapfrog: un método numérico para resolver las ecuaciones de Hamilton.

- Esquema iterativo con tamaño de paso ϵ y L pasos:

$$
\begin{aligned}
p(t+\frac{\epsilon}{2}) &= p(t) - \frac{\epsilon}{2}\nabla U(q(t)) \\
q(t+\epsilon) &= q(t) + \epsilon \nabla K(p(t+\frac{\epsilon}{2})) \\
p(t+\epsilon) &= p(t+\frac{\epsilon}{2}) - \frac{\epsilon}{2}\nabla U(q(t+\epsilon))
\end{aligned}
$$

- Equilibra estabilidad numérica y eficiencia computacional.

3.6.5. Algoritmo HMC: Integración y Aceptación

- Partiendo de la posición actual q, simular la dinámica por L pasos leapfrog para proponer q'.
- Calcular el nuevo Hamiltoniano $H(q', p')$ y comparar con el original $H(q, p)$.
- Aceptar o rechazar el nuevo estado q' basado en el criterio de Metropolis:
  - Aceptar con probabilidad $\min(1, \exp(-H(q', p') + H(q, p)))$.
  - Garantiza balance detallado y por lo tanto la distribución estacionaria correcta.
- Propuestas eficientes significan menos rechazos y mezcla más rápida.

3.6.6. El Papel de la Energía en HMC

- La energía potencial $U(q)$ corresponde a la log-probabilidad negativa de los datos dados los parámetros.
- La energía cinética $K(p)$ típicamente se elige cuadrática en p:

$$K(p) = \frac{1}{2}p^T M^{-1} p$$

- M es una matriz de masa (a menudo se configura como la identidad para simplicidad).
- La elección de U y K influye en la trayectoria a través del espacio de parámetros.

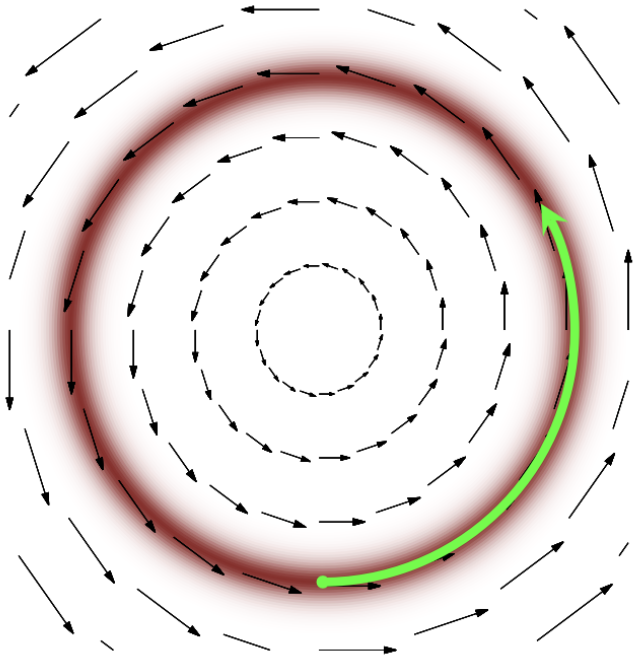

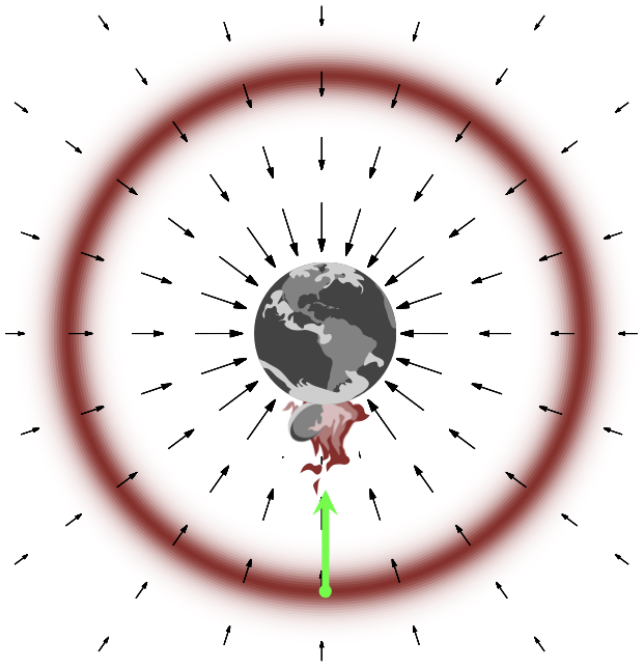

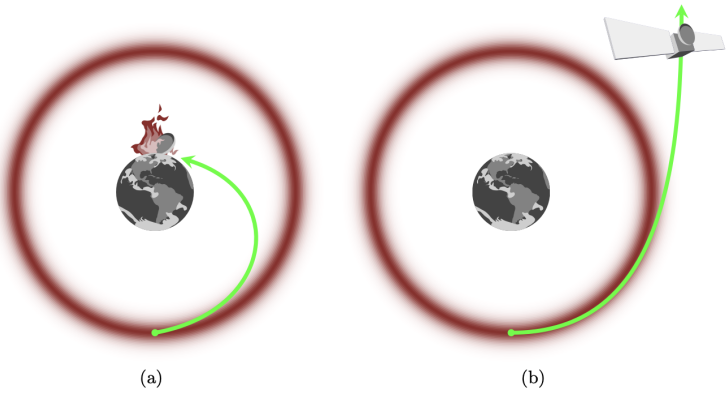
(a)
(b)

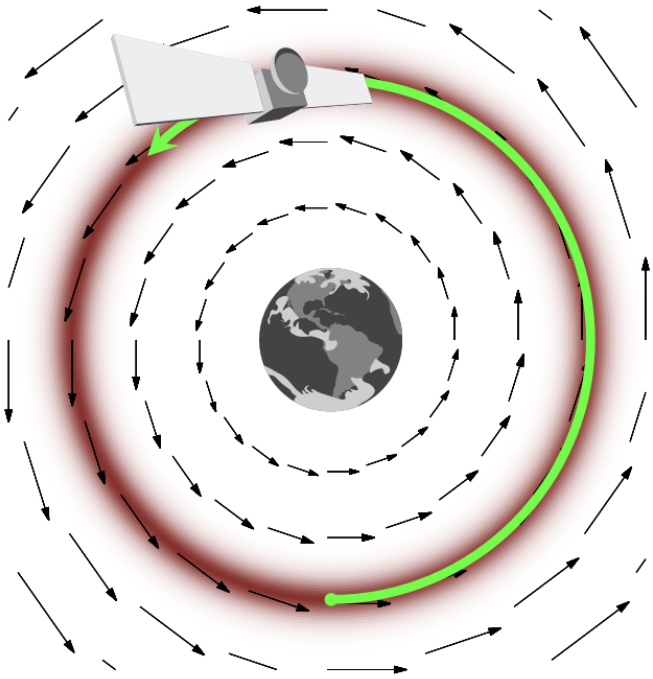

3.6.7. Ajuste y Consideraciones Prácticas

- Parámetros críticos de HMC: tamaño de paso ϵ y pasos leapfrog L.
- Requiere ajuste cuidadoso: equilibrio entre la tasa de aceptación y el tiempo de integración.
- Los diagnósticos son cruciales:
  - Gráficos de trazado para verificar mezcla y convergencia.
  - Autocorrelación para medir la independencia de las muestras.

3.7. Resumen de Métodos de Simulación

Este documento proporciona un resumen de los principales métodos de simulación discutidos, destacando sus ventajas y desventajas.

3.8. Métodos Monte Carlo

3.8.1. Ventajas

- **Flexibilidad**: Pueden aplicarse a una amplia gama de problemas de integración y optimización.
- **Simplicidad**: Fácil de entender e implementar.
- **Escalabilidad**: Puede manejar problemas de alta dimensión con un gran número de variables aleatorias.

3.8.2. Desventajas

- **Eficiencia**: Puede ser ineficiente para distribuciones complejas o problemas de alta dimensión sin técnicas adicionales.
- **Convergencia lenta**: La convergencia a la distribución objetivo puede ser lenta, requiriendo muchas muestras.

3.9. Método de Aceptación-Rechazo

3.9.1. Ventajas

- **Generalidad**: Puede aplicarse a cualquier distribución siempre que se conozca la forma funcional de la densidad objetivo.
- **Independencia**: Genera muestras independientes de la distribución objetivo.

3.9.2. Desventajas

- **Ineficiencia**: Puede ser ineficiente si la constante de normalización M es muy alta, ya que muchas muestras propuestas serán rechazadas.
- **Dificultad de implementación**: Requiere encontrar una densidad instrumental adecuada y una constante de normalización, lo cual puede ser complicado.

3.10. Métodos MCMC (Cadena de Markov Monte Carlo)

3.10.1. Ventajas

- **Versatilidad**: Puede aplicarse a distribuciones complejas y de alta dimensión.
- **Eficiencia**: Métodos como HMC pueden ser muy eficientes en la exploración del espacio de parámetros.

3.10.2. Desventajas

- **Dependencia de las muestras**: Las muestras generadas están correlacionadas, lo que puede requerir un mayor número de iteraciones para obtener muestras independientes.
- **Dificultad en la evaluación de convergencia**: Determinar cuándo la cadena ha convergido a la distribución estacionaria puede ser difícil.

3.11. Hamiltoniano Monte Carlo (HMC)

3.11.1. Ventajas

- **Exploración eficiente**: Utiliza información del gradiente para realizar saltos más grandes y eficientes en el espacio de parámetros.
- **Reducción de autocorrelación**: Las muestras son menos correlacionadas en comparación con otros métodos MCMC.

3.11.2. Desventajas

- **Complejidad computacional**: Requiere el cálculo del gradiente de la densidad objetivo, lo que puede ser costoso.
- **Ajuste de parámetros**: Necesita un ajuste cuidadoso de los parámetros del algoritmo (tamaño de paso y número de pasos leapfrog).

3.12. Algoritmo EM (Expectation-Maximization)

3.12.1. Ventajas

- **Robustez**: Puede manejar datos faltantes o latentes.
- **Aplicabilidad**: Utilizado ampliamente en estadística, aprendizaje automático y minería de datos.

3.12.2. Desventajas

- **Convergencia a óptimos locales**: Puede converger a un óptimo local en lugar del global.
- **Cálculo intensivo**: Cada paso E puede requerir una integración que a menudo debe aproximarse mediante Monte Carlo.

3.13. Conclusión

En este capítulo se abordó el modelamiento bayesiano. Existen diferentes técnicas que permiten resolver de forma numérica las distribuciones posteriores que no se pueden resolver de forma analítica.

La aplicación de los métodos de Monte Carlo se reduce a la generación de variables aleatorias a partir de distribuciones dadas. Por lo tanto, queda diseñar algoritmos para generar variables y vectores aleatorios que tengan las distribuciones deseadas.

Los paquetes de software estadístico como SAS, R, Splus, SPSS, Minitab y otros tienen incorporados procedimientos para la generación de variables aleatorias a partir de las distribuciones discretas y continuas más comunes. Herramientas similares se encuentran en versiones recientes de MATLAB, Microsoft Excel y algunas bibliotecas.

La mayoría de los lenguajes informáticos tienen un generador de números aleatorios que sólo devuelve variables aleatorias independientes distribuidas uniformemente.

Capítulo 4

Aplicaciones

En este capítulo nos concentramos en algunas aplicaciones que son base de muchos modelos de machine learning y deep learning. Iniciamos con el modelo de regresión lineal en su versión frecuentista y bayesiana. Esto servira para entender la diferencia en el proceso de estimación. Luego se introducen las distribuciones mixtas una aplicación muy importante cuando los problemas requieren de la combinación de dos o mas distribuciones.

En la parte final del curso se abordan los modelos no paramétricos en donde se asume que los parámetros de un modelo son infinitos y por lo tanto se requieren de técnicas específicas para llegar a la solución de la distribución posterior.

Para complementar el aprendizaje, se abordan las series de tiempo, sus propiedas y diferencias con las observaciones que no dependen del tiempo en donde variables como los precios, la inflación o cualquiera otra en la que su valor dependa de los cambios temporales, se modela a partir de unas metodologías específicas.

Cada método de simulación tiene sus propias ventajas y desventajas, y la elección del método adecuado depende del problema específico que se esté abordando. Los métodos Monte Carlo son flexibles y fáciles de implementar pero pueden ser ineficientes. El método de Aceptación-Rechazo es general pero puede ser ineficiente si la densidad instrumental no se elige adecuadamente. Los métodos MCMC son versátiles y eficientes para distribuciones complejas, aunque pueden requerir un mayor número de iteraciones para obtener muestras independientes. HMC es muy eficiente en la exploración del espacio de parámetros pero requiere un cálculo complejo y un ajuste cuidadoso de los parámetros. El algoritmo EM es robusto y ampliamente aplicable, pero puede converger a óptimos locales y ser computacionalmente intensivo.

4.1. Regresión Lineal Múltiple

4.1.1. Versión frequentista

En un modelo lineal múltiple se asume que Y es una función lineal de sus predictores mas un ruido blanco:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots \beta_p X_p + \epsilon \tag{4.1}$$

4.1.2. Supuestos

1. Todos los parámetros son lineales
2. La muestra de n observaciones sigue el modelo poblacional del primer supuesto
3. No existe perfecta colinealidad
4. EL error tiene un valor esperado de cero dado por variables independientes.
5. Homocedasticidad: El error tiene la misma varianza que los valores de las variables explicativas.

No hacemos suposiciones sobre las distribuciones (marginales o conjuntas) de X_i, pero suponemos que $E[\epsilon|X] = 0$, $V[\epsilon|X] = \sigma^2$, y ese ϵ no está correlacionado entre las mediciones. La forma matricial del modelo es:

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon \tag{4.2}$$

Donde $\mathbf{X}$ incluye una columna inicial de 1.
Cuando se incluye se asume que este debe tener un comportamiento normal como se ve en la siguiente ecuación:

$$\epsilon \sim MVN(\mathbf{0}, \sigma^2 \mathbf{I}) \tag{4.3}$$

independiente de $\mathbf{X}$.

Los coeficientes se estiman de la siguiente forma:

$$\widehat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} \tag{4.4}$$

Bajo el supuesto de ruido blanco, este es el mismo resultado que la estimación por máxima verosimilitud

$$\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\beta} = \mathbf{HY} \tag{4.5}$$

Donde $\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$

Que es simétrico e idempotente. Los residuales se obtienen así:

$$SSE = \mathbf{Y}^T(\mathbf{I} - \mathbf{H})\mathbf{Y} \tag{4.6}$$

donde $\mathbf{I} - \mathbf{H}$ es simétrico e idempotente

4.1.3. Derivación de los Estimadores

$$\widehat{\beta}_{OLS} = argmin_{\beta \in \mathbb{R}^2}(\mathbf{Y} - \mathbf{X}\beta)^T(\mathbf{Y} - \mathbf{X}\beta) \tag{4.7}$$

$$\frac{\partial}{\partial \beta} = (\mathbf{Y}^T\mathbf{Y} - 2\mathbf{Y}^T(\mathbf{X}\beta + \beta^T\mathbf{X}^T\mathbf{X}\beta)) \tag{4.8}$$

$$\frac{\partial}{\partial \beta} = -2\mathbf{X}^T\mathbf{Y} + 2\mathbf{X}^T\mathbf{X}\hat{\beta} = 0 \tag{4.9}$$

$$\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} \tag{4.10}$$

4.1.4. Propiedades de los Estimadores

Insesgamiento del estimador mínimo cuadrado

$$\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} \tag{4.11}$$

$$\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{X}^T(\mathbf{X}\beta + \epsilon) \tag{4.12}$$

$$\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{X})\beta \tag{4.13}$$

$$\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} + (\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\epsilon) \tag{4.14}$$

$$= \beta + (\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\epsilon) \tag{4.15}$$

$$E[\hat{\beta}|x] = \beta \tag{4.16}$$

Varianza de los errores estandar: Suponiendo Homocedasticidad

$$V[\hat{\beta}|\mathbf{X}] = V[\beta + (\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\epsilon)/\mathbf{X}] \tag{4.17}$$
$$V[\hat{\beta}|\mathbf{X}] = V[(\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\epsilon)/\mathbf{X}] \tag{4.18}$$
$$V[\hat{\beta}|\mathbf{X}] = (\mathbf{X}^T\mathbf{X})^{-1}V[\mathbf{X}^T\epsilon/\mathbf{X}](\mathbf{X}^T\mathbf{X})^{-1} \tag{4.19}$$
$$V[\hat{\beta}|\mathbf{X}] = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^TV[\epsilon/\mathbf{X}]\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1} \tag{4.20}$$
$$V[\hat{\beta}|\mathbf{X}] = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\sigma^2\mathbf{I}\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1} \tag{4.21}$$
$$V[\hat{\beta}|\mathbf{X}] = \sigma^2(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1} \tag{4.22}$$

$$V[\hat{\beta}|\mathbf{X}] = \sigma^2(\mathbf{X}^T\mathbf{X})^{-1} \tag{4.23}$$

Consistencia

- Ley de los grandes números
- Teorema Límite Central

Tenemos que $\hat{\beta} = \beta + (\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\epsilon)$ y se desea ver si $\hat{\beta}$ es consistente. $\lim_{n\to p}(\hat{\beta} - \beta) = 0$

Eficiencia: Bajo los supuestos de linealidad, muestreo aleatorio, no colinealidad perfecta, media condicional cero de los errores y homocedasticidad, $\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$ es el mejor estimador lineal insesgado.

Además $\hat{\beta}_1 = \beta_1 + (\mathbf{X}_1^T\mathbf{X}_1)^{-1}(\mathbf{X}_1^T\epsilon_2)$.

4.1.5. Enfoque Bayesiano

Ahora se puede considerar ahora el enfoque bayesiano de este modelo, es necesario un análisis cuidadoso de la construcción de las distribuciones prior correspondientes. A partir de lo que ahora es posible que se te ocurran algunas razones por las que la solución estándar de mínimos cuadrados es insatisfactoria. Un problema evidente es que los datos casi nunca van a ser lo suficientemente buenos como para decir con certeza que una pendiente y una intercepción determinadas son correctas (la excepción sería si tres o más puntos se encuentran perfectamente en una línea recta, sin dispersión). En principio, casi siempre existirá incertidumbre sobre la pendiente y el intercepto. Desde una perspectiva bayesiana, el objetivo no es encontrar una estimación puntual de la pendiente y el intercepto. En su lugar, se debe calcular la

distribución posterior de la pendiente y el intercepto, dados los datos. La distribución posterior dirá exactamente cuánta incertidumbre existe.Marin et al. (2007)

Para analisar este modelo, primero se puede iniciar con la distribución de verosimilitud de la regresión en donde se asume una distribución normal de las distribuciones dados unos parámetros β_i para $i = 1, .., n$ y una varianza del modelo σ^2.

$$\mathcal{L}(\boldsymbol{\beta}, \sigma^2 \mid \boldsymbol{y}, \boldsymbol{X}) = (2\pi\sigma^2)^{-n/2} exp\Big[-\frac{1}{2\sigma^2}(\boldsymbol{y}-\boldsymbol{X}\hat{\beta})^T(\boldsymbol{y}-\boldsymbol{X}\hat{\boldsymbol{\beta}})-\frac{1}{2\sigma^2}(\boldsymbol{\beta}-\hat{\boldsymbol{\beta}})^T(\boldsymbol{X}^T\boldsymbol{X})(\boldsymbol{\beta}-\hat{\boldsymbol{\beta}})\Big] \tag{4.24}$$

La forma de la verosimilitud es Gaussiana/Gamma Inversa: En concreto, β dada σ^2 aparece en una expresión de tipo Gaussiano, mientras que σ^2 sugiere una expresión Gamma Inversa. Por tanto, la prior conjugada puede construirse dentro de esta familia. Especificando tanto la prior condicional sobre β,

$$\boldsymbol{\beta} \mid \sigma^2, \boldsymbol{X} \sim N_{k+1}(\tilde{\boldsymbol{\beta}}, \sigma^2 \boldsymbol{M}^{-1}) \tag{4.25}$$

Donde $\boldsymbol{M}$ es $(k+1, k+1)$ matriz simétrica definida positiva, y la prior marginal de σ^2

$$\sigma^2 \mid \boldsymbol{X} \sim IG(a, b) \quad a, b > 0 \tag{4.26}$$

Donde la prior conjugada se encuentra la distribución posterior condicional $\pi(\beta \mid \sigma^2, \boldsymbol{y}, \boldsymbol{X})$ es:

$$N_{k+1}\Big((\boldsymbol{M} + \boldsymbol{X}^T\boldsymbol{X})^{-1}\{(\boldsymbol{X}^T\boldsymbol{X})\hat{\boldsymbol{\beta}} + \boldsymbol{M}\tilde{\boldsymbol{\beta}}\}, \sigma^2(\boldsymbol{M} + \boldsymbol{X}^T\boldsymbol{X})^{-1}\Big) \tag{4.27}$$

Donde la distribución margina posterior $\pi(\sigma^2 \mid \boldsymbol{y}, \boldsymbol{X})$ es

$$IG\Big(\frac{n}{2} + a, b + \frac{s^2}{2} + \frac{(\tilde{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}})^T(\boldsymbol{M}^{-1} + (\boldsymbol{X}^T\boldsymbol{X})^{-1}(\tilde{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}})}{2}\Big) \tag{4.28}$$

Ejercicio

Compruebe cada una de las ecuaciones anteriores, use las identidades matriciales para resolver el ejercicio.
En este contexto, los estimadores de Bayes de β y σ^2 asociados a las pérdidas por error cuadrático, es decir, las medias posteriores de β y σ^2, pueden calcularse de forma cerrada. De hecho, un simple cálculo muestra que están dados por:

$$\mathbb{E}[\beta \mid \boldsymbol{y}, \boldsymbol{X}] = \mathbb{E}[\mathbb{E}(\beta \mid \sigma^2, \boldsymbol{y}, \boldsymbol{X}) \mid \boldsymbol{y}, \boldsymbol{X}] \tag{4.29}$$

$$= (\boldsymbol{M} + \boldsymbol{X}^T\boldsymbol{X})^{-1}\{(\boldsymbol{X}^T\boldsymbol{X})\hat{\boldsymbol{\beta}} + \boldsymbol{M}\tilde{\boldsymbol{\beta}}\}) \tag{4.30}$$

El valor esperado de la varianza es:

$$\mathbb{E}[\sigma^2 \mid \boldsymbol{y}, \boldsymbol{X}] = \frac{2b + s^2 + (\tilde{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}})^T(\boldsymbol{M}^{-1} + (\boldsymbol{X}^T\boldsymbol{X})^{-1}(\tilde{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}})}{n + 2a - 2} \tag{4.31}$$

Ejercicio

Genere el modelo para una prior no informativa(Use Jefrrey Prior)

Bibliografía

Gelman, A., Carlin, J. B., Stern, H. S., and Rubin, D. B. (2014). Bayesian data analysis (vol. 2).

Hoff, P. D. (2009). *A first course in Bayesian statistical methods*, volume 580. Springer.

Kass, R. E. and Wasserman, L. (1996). The selection of prior distributions by formal rules. *Journal of the American statistical Association*, 91(435):1343–1370.

Llinás Solano, H. (2015). *Introducción a la teoría de la probabilidad*. Universidad del Norte.

Llinás Solano, H. (2016). *Introducción a la estadística matemática*. Universidad del Norte.

Marin, J.-M. and Robert, C. P. (2014). *Bayesian essentials with R*, volume 48. Springer.

Marin, J.-M., Robert, C. P., et al. (2007). *Bayesian core: a practical approach to computational Bayesian statistics*, volume 268. Springer.

Peña, D. (2014). *Fundamentos de estadística*. Alianza editorial.

Robert, C. P., Casella, G., and Casella, G. (1999). *Monte Carlo statistical methods*, volume 2. Springer.

Wackerly, D. D., Muñoz, R., Humbertotr, J., et al. (2010). *Estadística matemática con aplicaciones*. Number 519.5 W3.